CHƯƠNG TRÌNH FORECASTING CHO CHUỖI CUNG ỨNG

LECTURE NOTES

Giáo trình lý thuyết đầy đủ — 10 buổi học

Từ đọc hình dạng nhu cầu đến trình bày kết quả cho ban lãnh đạo

GDMN — Chương trình đào tạo Demand Planning

Thư Nguyễn

MSc Logistics and Supply Chain Analytics — University of Southampton, UK

thu.minh090997@gmail.com

Biên soạn theo chương trình 10 buổi
Cập nhật: Ngày 13 tháng 9 năm 2026

Mục lục

1 Đọc Hình Dạng Nhu Cầu **1**

1.1 Chuỗi thời gian và biến động . . . 1

1.2 Phân rã chuỗi thời gian: Trend, Seasonal, Residual . . . 2

1.2.1 Xu hướng và Mùa vụ: Cộng hay Nhân? . . . 3

1.2.2 Áp dụng chẩn đoán lên SKU thật: Nồi cơm điện . . . 4

1.2.3 Chỉ số mùa vụ: cách tính cơ bản và cách tính bằng Solver . . . 5

1.3 Đo tính chu kỳ bằng ACF . . . 6

1.4 Bốn hình dạng nhu cầu cơ bản . . . 6

1.5 Ba chỉ số định lượng phân loại . . . 7

1.5.1 Bảng tính tay minh hoạ: CV và SLOPE trên 6 tháng đầu . . . 8

1.6 Ma trận Pegels . . . 8

1.6.1 Hình dạng trực quan của cả chín ô . . . 9

1.7 Ví dụ minh hoạ trên bốn SKU thực tế . . . 10

1.8 Case Study Thực Tế: Nike và cái giá 100 triệu USD của việc đọc sai nhu cầu (2001) . . . 10

2 Đo Lường Độ Chính Xác **12**

2.1 Hai phương pháp Naive làm mốc chuẩn . . . 12

2.2 Năm chỉ số sai số . . . 13

2.2.1 ME chính là Forecast Bias trong ngành . . . 13

2.2.2 WMAPE: khi các kỳ có quy mô doanh số chênh lệch lớn . . . 14

2.3 Khoảng tin cậy dự báo . . . 14

2.4 Ví dụ minh hoạ thực tế: NF1 và NF2 trên hai SKU . . . 15

2.4.1 Bảng tính tay: năm chỉ số sai số cho NF1 . . . 15

2.5 Case Study Thực Tế: Google Flu Trends — khi "dữ liệu lớn" tự tin sai gần gấp đôi (2013) . . . 16

3 Exponential Smoothing **17**

3.1 Moving Average (Trung bình trượt) . . . 17

3.1.1 Bảng tính tay: MA(3) trên 4 tháng đầu tiên . . . 18

3.2 Weighted Moving Average (WMA) . . . 18

3.2.1 Bảng tính tay: WMA(3) với trọng số 1:2:3 . . . 19
3.3 Double Moving Average . . . 19
3.4 Kết quả thực nghiệm: khi nào các biến thể MA hoạt động tốt . . . 20
3.5 Simple Exponential Smoothing (SES) . . . 21
3.5.1 Bảng tính tay: SES đệ quy với alpha=0,1 . . . 21
3.6 Holt (Double Exponential Smoothing) . . . 22
3.6.1 Bảng tính tay: Holt đệ quy với alpha=0,3, beta=0,1 . . . 23
3.7 Holt-Winters (Triple Exponential Smoothing) . . . 24
3.8 Kết quả thực nghiệm trên Nồi cơm điện 1.8L . . . 25
3.9 Case Study Thực Tế: Cuộc thi M-Competitions — vì sao mô hình đơn giản vẫn "sống khỏe" suốt 40 năm? . . . 26

4 ARIMA 28
4.1 Tính dừng và kiểm định ADF . . . 28
4.2 Thành phần AR và MA . . . 29
4.3 Đọc biểu đồ ACF và PACF . . . 29
4.3.1 Bảng tính tay: ACF cho 4 lag đầu trên dữ liệu thật . . . 30
4.4 Tiêu chí lựa chọn mô hình: AIC . . . 31
4.4.1 Bảng kết quả thật: 6 tổ hợp đầu tiên trong grid search . . . 31
4.4.2 Trực quan hoá toàn bộ lưới AIC bằng bản đồ nhiệt . . . 31
4.4.3 Kiểm định Ljung-Box: xác nhận phần dư bằng con số, không chỉ bằng mắt 32
4.5 Kết quả thực nghiệm: khi nào ARIMA không thắng . . . 33
4.6 Case Study Thực Tế: ARIMA không chỉ là bài tập học thuật — nó chạy ngầm trong số liệu kinh tế quốc gia . . . 34

5 Regression-Based Forecasting 35
5.1 Mô hình hồi quy tuyến tính đa biến . . . 35
5.2 Biến giả (Dummy Variables) . . . 36
5.2.1 Bảng minh hoạ: cấu trúc dữ liệu biến giả cho 6 tháng đầu . . . 36
5.3 Mô hình áp dụng cho Nồi cơm điện 1.8L . . . 37
5.4 Quadratic Trend: khi xu hướng thẳng chưa đủ . . . 37
5.5 Đánh giá mô hình: R-squared và F-test . . . 38
5.6 Hồi quy đa biến với yếu tố ngoại sinh LIÊN TỤC: vượt ra ngoài biến giả nhị phân 39
5.6.1 Mở rộng mô hình Nồi cơm điện với hai yếu tố ngoại sinh liên tục . . . 39
5.7 Giới hạn của phương pháp hồi quy trong dự báo . . . 42
5.7.1 Có biến giải thích chưa đủ: ví dụ mở rộng điểm bán . . . 42

5.8 Case Study Thực Tế: Vì sao Walmart luôn chất đầy Pop-Tarts vị dâu trước mỗi cơn bão? . . . 43

6 Từ Forecast Đến Quyết Định Vận Hành 44

6.1 Tồn kho an toàn (Safety Stock) . . . 44
6.1.1 Bảng tính tay: Safety Stock theo mức phục vụ mong muốn . . . 46
6.1.2 Điểm đặt hàng lại (Reorder Point) . . . 46
6.2 Quy đổi chi phí vốn tồn kho . . . 47
6.3 Vòng quay tồn kho: thước đo hiệu quả sau Safety Stock . . . 48
6.4 Newsvendor: quyết định lượng đặt cho SKU bán một mùa duy nhất . . . 48
6.5 Tracking Signal — giám sát mô hình theo thời gian . . . 49
6.5.1 Bảng tính tay: Tracking Signal khi mô hình thiên lệch hệ thống . . . 49
6.6 Hiệu ứng Bullwhip trong chuỗi cung ứng . . . 51
6.7 Kiến trúc ERP/APS: forecast nằm ở đâu trong hệ thống doanh nghiệp? . . . 51
6.8 Dự báo Xác suất (Probabilistic Forecasting): khóa học này đang ở đâu so với phần mềm hàng đầu? . . . 52
6.8.1 Vậy học xong 10 buổi này, bạn đang ở đâu? . . . 54
6.8.2 Lộ trình học tiếp theo, nếu muốn tiến lên cấp "Semi-genuine"trở lên . . . 54
6.9 S&OP: quy trình thống nhất một con số duy nhất . . . 55
6.9.1 Ví dụ minh hoạ: từ Baseline đến Kế hoạch bị giới hạn . . . 55
6.9.2 Forecast Value Added: con người có đang thêm giá trị? . . . 56
6.10 Ma trận ABC/XYZ: ưu tiên nguồn lực hoạch định . . . 57
6.11 Kraljic Matrix: chiến lược mua hàng theo rủi ro nguồn cung . . . 57
6.12 Nhu cầu rời rạc: họ phương pháp Croston . . . 58
6.12.1 Vì sao Exponential Smoothing thất bại với nhu cầu rời rạc . . . 59
6.12.2 Croston (1972): tách kích thước và khoảng cách nhu cầu . . . 59
6.12.3 Thiên lệch của Croston gốc và bản sửa lỗi SBA . . . 60
6.12.4 TSB: theo dõi xác suất phát sinh thay vì khoảng cách . . . 60
6.12.5 Vì sao Naive Forecast thất bại nghiêm trọng hơn cả ba phương pháp trên 62
6.12.6 SBA hay TSB? Ma trận quyết định . . . 62
6.13 Mười chỉ số Demand & Supply Planner cần nắm . . . 63
6.14 Case Study Thực Tế: Hiệu ứng Bullwhip của P&G — vì sao đơn hàng tã giấy dao động dữ dội hơn cả nhu cầu thật? . . . 65
6.15 Tổng kết chương: bản đồ ảnh hưởng liên phòng ban . . . 65

7 Kiểm Tra Quá Khớp Và Ôn Tập 67

7.1 Hiện tượng quá khớp (Overfitting) . . . 67
7.2 Adjusted R-squared . . . 67
7.2.1 Bảng tính tay: hai mô hình cùng số tham số, kết luận trái ngược . . . 68
7.3 Quy tắc kinh nghiệm và ví dụ thực nghiệm . . . 68
7.4 Train/Test Split — tiêu chuẩn vàng để kiểm tra quá khớp . . . 68
7.4.1 Vấn đề: mọi MAPE trong giáo trình đến nay đều tính trong mẫu . . . 69
7.4.2 Cách làm đúng: chia dữ liệu trước khi làm bất kỳ điều gì khác . . . 69
7.4.3 Cạm bẫy thường gặp: Random Split cho chuỗi thời gian . . . 69
7.4.4 Kết quả thật: chia 30 tháng Train, 6 tháng Test trên Nồi cơm điện . . . 70
7.4.5 Walk-Forward Validation: đánh giá qua nhiều vòng . . . 72
7.4.6 Trường hợp đặc biệt: lợi thế của Regression phụ thuộc vào biết trước biến giải thích . . . 73
7.5 Case Study Thực Tế: Zillow Offers — khi mô hình định giá nhà "quá khớp" với quá khứ sụp đổ trước tương lai (2021) . . . 73

8 Xử Lý Dữ Liệu Khó Trong Thực Tế 75
8.1 Phân loại outlier: lỗi dữ liệu và sự kiện thật . . . 75
8.2 Phương pháp IQR (Interquartile Range) . . . 75
8.2.1 Bảng tính tay: ngưỡng IQR trên 36 tháng Nồi cơm điện . . . 75
8.3 Phương pháp Z-score . . . 76
8.3.1 Bảng tính tay: Z-score cho điểm nghi ngờ . . . 76
8.4 Xử lý dữ liệu thiếu bằng nội suy . . . 76
8.5 Tác động định lượng của việc làm sạch dữ liệu . . . 77
8.6 Case Study Thực Tế: Cú sốc giấy vệ sinh 2020 — khi một outlier không phải lỗi dữ liệu, mà là sự kiện có thật . . . 78

9 Trình Bày Kết Quả Forecast Hiệu Quả 79
9.1 Nguyên tắc kim tự tháp ngược . . . 79
9.2 Biểu đồ TỆ và biểu đồ TỐT: cùng dữ liệu, khác cách trình bày . . . 79
9.3 Dịch thuật ngữ kỹ thuật sang ngôn ngữ kinh doanh . . . 80
9.4 Nguyên tắc thiết kế biểu đồ hiệu quả . . . 81
9.5 Cấu trúc kể chuyện bằng số liệu . . . 81
9.6 Case Study Thực Tế: Biểu đồ Challenger — khi cách trình bày dữ liệu liên quan tới sinh mạng . . . 81

10 Framework Tổng Hợp Và Bảng Công Thức 83
10.1 Framework sáu bước . . . 83

10.2 Kỹ thuật nâng cao: kết hợp nhiều phương pháp dự báo 84
10.2.1 Bảng tính tay: kết hợp Regression và Holt-Winters 84
10.3 Bảng tra cứu công thức toàn khóa học 85
10.4 Bảng tổng hợp: hình dạng nhu cầu nào dùng phương pháp nào 86
10.5 Case Study Thực Tế: Nate Silver và 50/50 bang — sức mạnh của việc KẾT HỢP nhiều dự báo 87
10.6 Kết luận giáo trình 87

Code & Demo **88**

CHƯƠNG 1

Đọc Hình Dạng Nhu Cầu

TỆP ĐÍNH KÈM — Chương 1

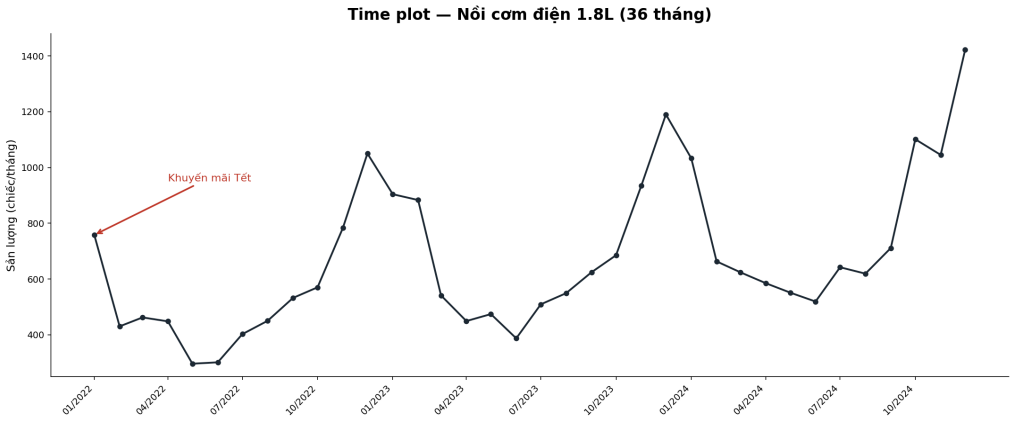
Python: `Buoi1/Buoi1_01_BieuDo.py` (vẽ 4 hình dạng nhu cầu), `Buoi1/Buoi1_02_ExcelDapAn.py`, `Buoi1/Buoi1_03_ExcelSheet_PhanTachMuaVu.py`, `Buoi1/Buoi1_04_ExcelSheet_PhanTachMuaVu_NangCao.py` (Solver), `Buoi1/Buoi1_05_XuHuongMuaVu_CongNhan.py` (chẩn đoán cộng/nhân), `Buoi1/Buoi1_06_MaTranPegels_3x3.py` (lưới 9 ô trực quan). **Excel:** `ERP_4SKU_DapAn_Buoi1.xlsx` — sheet `Du_Lieu_ERP` (dữ liệu gốc 4 SKU), `Tinh_Chi_So` (CV, %kỳ=0, SLOPE), `Phan_Tach_Mua_Vu`, `Bieu_Do`. **Slide:** `Buoi1_Forecasting_ChuoiCungUng.pptx`.

Chương này trình bày nền tảng của toàn bộ giáo trình: trước khi áp dụng bất kỳ phương pháp dự báo nào, người phân tích cần xác định được đặc điểm thống kê cơ bản của chuỗi dữ liệu. Việc phân loại đúng hình dạng nhu cầu quyết định trực tiếp phương pháp nào sẽ được sử dụng ở các chương sau.

1.1 Chuỗi thời gian và biến động

Chuỗi thời gian (time series) là một dãy giá trị quan sát được sắp xếp theo thứ tự thời gian, ký hiệu Y1, Y2, ..., Yn, trong đó chỉ số dưới biểu thị thứ tự kỳ quan sát (thường là tháng). Trong khóa học, mỗi chuỗi thời gian tương ứng với doanh số bán hàng hàng tháng của một SKU (Stock Keeping Unit — mã quản lý một loại sản phẩm cụ thể).

Bước đầu tiên, bắt buộc trước khi làm bất kỳ điều gì khác, là vẽ **time plot** — biểu đồ đường thể hiện toàn bộ chuỗi theo thời gian. Mắt người rất giỏi phát hiện xu hướng, mùa vụ và điểm bất thường, nhưng cảm nhận trực quan phụ thuộc vào tỷ lệ trục và có thể khác nhau giữa những người quan sát — đây là lý do các chỉ số định lượng ở Mục 1.3 vẫn cần thiết dù đã nhìn biểu đồ.



Kết quả thật

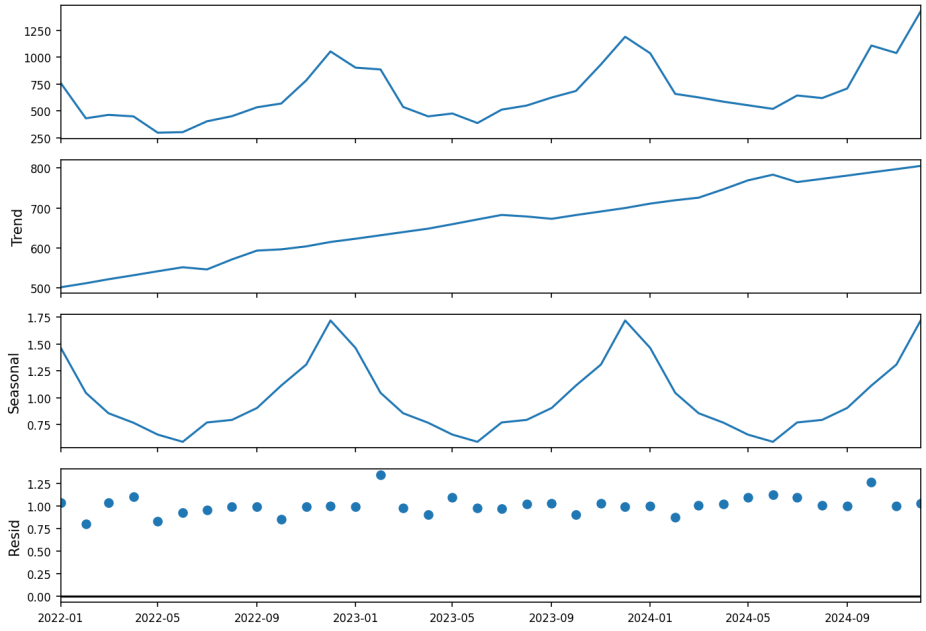
Nồi cơm điện 1.8L cho thấy ba đặc điểm cùng lúc: xu hướng tăng nhẹ theo thời gian, đỉnh lặp lại vào dịp Tết và quý 4 mỗi năm, và một điểm bất thường do khuyến mãi (tháng 01/2022) — biến động này KHÔNG phải nhiễu ngẫu nhiên vì nguyên nhân đã biết trước, sẽ xử lý bằng biến giải thích ở Chương 5.

1.2 Phân rã chuỗi thời gian: Trend, Seasonal, Residual

Mọi chuỗi thời gian có thể phân rã thành ba thành phần cộng hoặc nhân với nhau:

$$Y_t = T_t \times S_t \times E_t \quad \text{(nhân)} \qquad\qquad Y_t = T_t + S_t + E_t \quad \text{(cộng)}$$

trong đó T_t là xu hướng (trend) — thành phần dài hạn, biến đổi mượt theo thời gian; S_t là chỉ số mùa vụ (seasonal) — mẫu hình lặp lại đều đặn theo chu kỳ cố định (thường 12 tháng); và E_t là phần dư (residual/error) — biến động ngẫu nhiên còn lại sau khi đã tách hai thành phần trên. Mục tiêu của mọi phương pháp dự báo, xuyên suốt Chương 3 đến Chương 5, thực chất là ước lượng T_t và S_t càng chính xác càng tốt, để phần E_t còn lại càng nhỏ và càng giống nhiễu ngẫu nhiên thuần túy càng tốt.

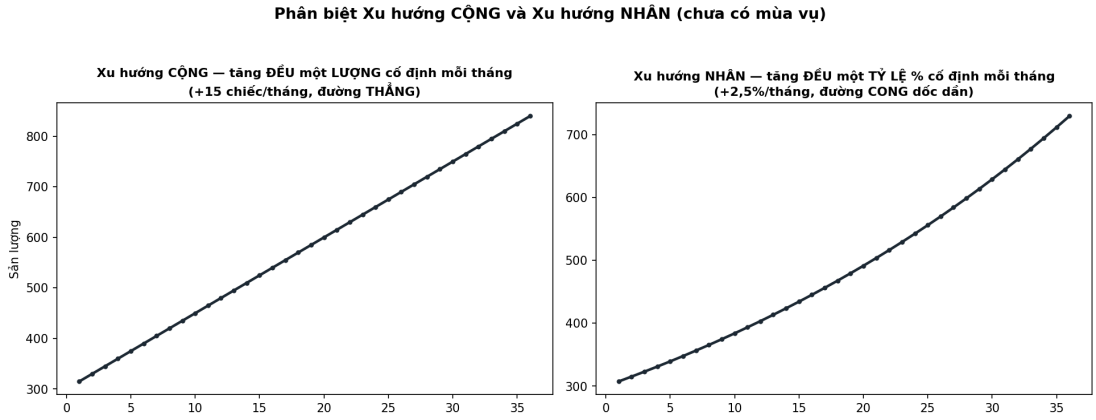


Panel Seasonal cho thấy hình dạng sóng lặp lại giống hệt nhau mỗi 12 tháng — bằng chứng trực quan cho mùa vụ. Panel Resid (dạng nhân, dao động quanh 1.0) không còn mẫu hình rõ rệt — dấu hiệu tốt cho thấy phần lớn thông tin có thể khai thác đã được Trend và Seasonal nắm bắt.

1.2.1 Xu hướng và Mùa vụ: Cộng hay Nhân?

Trước khi tính toán bất kỳ chỉ số nào, cần trả lời một câu hỏi định tính quan trọng: xu hướng và mùa vụ của chuỗi dữ liệu thuộc dạng CỘNG hay NHÂN? Câu trả lời quyết định trực tiếp công thức sẽ dùng — không chỉ ở mục này, mà xuyên suốt Chương 3 khi chọn đúng biến thể Holt-Winters. Đây là kỹ năng CHẨN ĐOÁN TRỰC QUAN mà học viên cần tự làm được trên dữ liệu của chính công ty mình, không chỉ trên bốn SKU mẫu của khóa học.

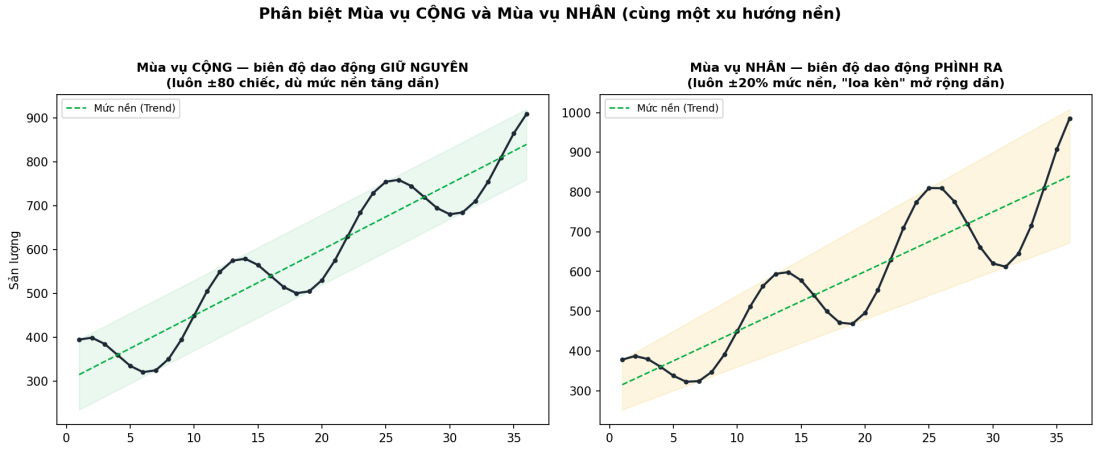
Xu hướng Cộng và Xu hướng Nhân. Xu hướng CỘNG tăng (hoặc giảm) một LƯỢNG TUYỆT ĐỐI cố định mỗi kỳ — ví dụ luôn tăng thêm 15 chiếc mỗi tháng, bất kể mức nền hiện tại đang là 300 hay 800. Khi vẽ ra, đây là một ĐƯỜNG THẲNG. Xu hướng NHÂN tăng một TỶ LỆ PHẦN TRĂM cố định mỗi kỳ — ví dụ luôn tăng thêm 2,5% mỗi tháng. Vì 2,5% của một con số lớn hơn về giá trị tuyệt đối lớn hơn 2,5% của một con số nhỏ, đường xu hướng NHÂN luôn là một ĐƯỜNG CONG dốc dần lên theo thời gian — giống lãi suất kép.



Cách chẩn đoán nhanh trên dữ liệu công ty bạn

Kẻ một đường thẳng nối điểm đầu và điểm cuối của chuỗi. Nếu dữ liệu thực tế BÁM SÁT đường thẳng đó — xu hướng CỘNG. Nếu dữ liệu VÒNG LÊN TRÊN đường thẳng ở đoạn giữa (như mặt cười) — xu hướng NHÂN, tăng trưởng đang tăng tốc theo thời gian.

Mùa vụ Cộng và Mùa vụ Nhân. Đây là phân biệt quan trọng hơn — và dễ nhầm lẫn hơn — so với xu hướng. Mùa vụ CỘNG có biên độ dao động (khoảng cách từ đáy đến đỉnh) GIỮ NGUYÊN một giá trị tuyệt đối, bất kể mức nền đang cao hay thấp. Mùa vụ NHÂN có biên độ dao động TỶ LỆ THUẬN với mức nền tại thời điểm đó — khi mức nền tăng gấp đôi, biên độ mùa vụ cũng tăng gấp đôi theo số tuyệt đối (dù tỷ lệ phần trăm vẫn giữ nguyên).

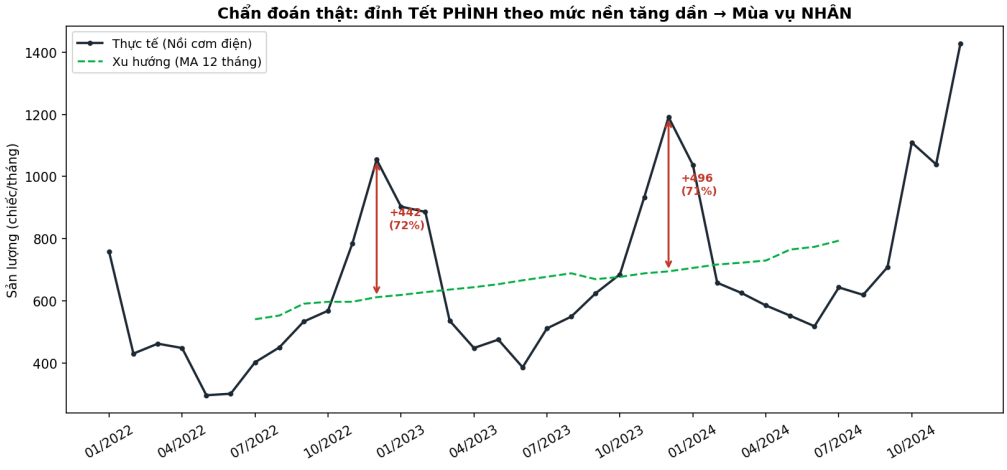


Hình dạng "loa kèn"(funnel shape) — biên độ dao động mở rộng dần theo thời gian, tạo thành hình phễu khi nhìn tổng thể — là dấu hiệu ĐẶC TRƯNG NHẤT của mùa vụ NHÂN, dễ nhận ra bằng mắt hơn nhiều so với việc tính toán chỉ số.

Cách chẩn đoán nhanh trên dữ liệu công ty bạn

So sánh CHIỀU CAO của đỉnh mùa vụ (từ đáy lân cận lên đỉnh) giữa GIAI ĐOẠN ĐẦU và GIAI ĐOẠN CUỐI của chuỗi dữ liệu. Nếu chiều cao TUYỆT ĐỐI gần bằng nhau — mùa vụ CỘNG. Nếu chiều cao tuyệt đối lớn dần theo thời gian NHƯNG tỷ lệ phần trăm so với mức nền tại thời điểm đó gần như không đổi — mùa vụ NHÂN.

1.2.2 Áp dụng chẩn đoán lên SKU thật: Nồi cơm điện



So sánh hai đỉnh Tết cách nhau đúng 12 tháng: đỉnh thứ nhất (12/2022) cao hơn xu hướng nền 442 chiếc (72,3%); đỉnh thứ hai (12/2023) cao hơn xu hướng nền 496 chiếc (71,4%). Chiều cao TUYỆT ĐỐI khác nhau đáng kể (442 so với 496) nhưng tỷ lệ PHẦN TRĂM gần như giống hệt nhau (72,3% so với 71,4%) — xác nhận rõ ràng đây là mùa vụ NHÂN, đúng như giả định đã dùng xuyên suốt khóa học khi chọn Holt-Winters biến thể nhân ở Chương 3 và mô hình nhân Trend×Seasonal ở mục 1.4 vừa trình bày.

Lưu ý thực hành

Trong thực tế, dữ liệu hiếm khi "sạch"tuyệt đối như ví dụ minh hoạ — luôn có nhiễu khiến tỷ lệ phần trăm giữa các đỉnh không giống hệt nhau một cách hoàn hảo. Quy tắc thực hành: nếu chênh lệch phần trăm giữa các đỉnh nhỏ hơn nhiều so với chênh lệch số tuyệt đối, nghiêng về mùa vụ NHÂN; ngược lại nghiêng về mùa vụ CỘNG. Khi không chắc chắn, có thể thử cả hai biến thể trong Holt-Winters (Chương 3) và so sánh MAPE thực nghiệm — đây là cách kiểm chứng chắc chắn nhất.

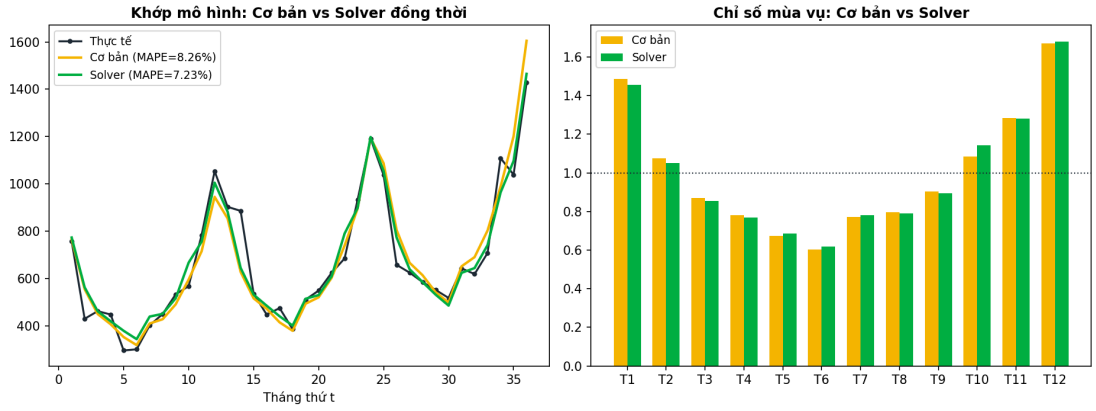
1.2.3 Chỉ số mùa vụ: cách tính cơ bản và cách tính bằng Solver

Cách tính **cơ bản** thực hiện theo hai bước tách rời: (1) ước lượng Trend bằng hồi quy Y_t theo t (có thể bậc 1 hoặc bậc 2), (2) với mỗi tháng, tính chỉ số mùa vụ bằng trung bình của tỷ số Y_t/T_t trên tất cả các năm có cùng tháng đó, rồi chuẩn hoá sao cho tổng 12 chỉ số bằng 12 (mức trung bình là 1,0).

$$S_m = \frac{1}{k}\sum_{i}\frac{Y_{m,i}}{T_{m,i}} \times \frac{12}{\sum_{j=1}^{12} S_j} \qquad (m = 1, \ldots, 12)$$

Nhược điểm của cách làm hai bước: Trend được ước lượng *trước*, không biết đến chỉ số mùa vụ, nên có thể bị chính biến động mùa vụ làm lệch nhẹ — rồi chỉ số mùa vụ lại được tính từ một Trend chưa hoàn hảo. Cách tính **bằng Solver** khắc phục nhược điểm này bằng cách tối ưu hoá *đồng thời* cả hệ số Trend lẫn 12 chỉ số mùa vụ, sao cho tổng bình phương sai số giữa mô hình và thực tế là nhỏ nhất:

$$\min_{b_0, b_1, b_2,\, S_1, \ldots, S_{12}} \sum_{t=1}^{n} \Big(Y_t - (b_0 + b_1 t + b_2 t^2) \times S_{m(t)}\Big)^2 \quad \text{ràng buộc} \quad \sum_{m=1}^{12} S_m = 12$$



Kết quả thật

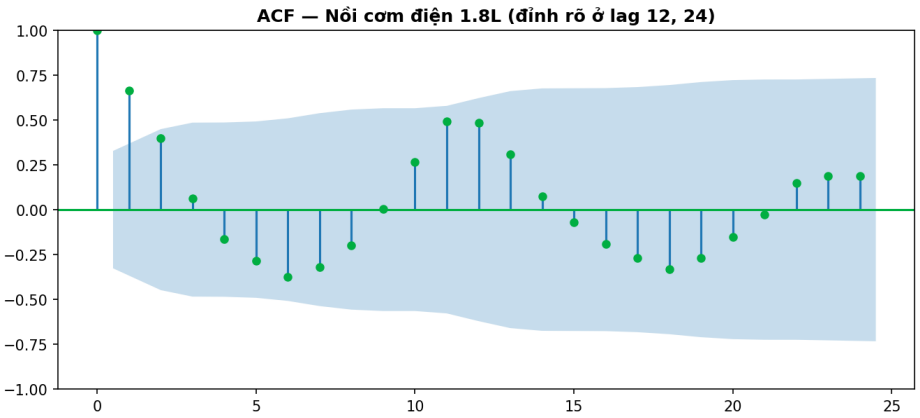
Trên Nồi cơm điện, cách tính cơ bản cho MAPE 8,26%. Tối ưu đồng thời bằng Solver giảm MSE khoảng 32%, đưa MAPE xuống 7,23% — gần bằng kết quả Holt-Winters

sẽ học ở Chương 3 (đây không phải trùng hợp: cả hai đều là mô hình nhân Trend × Seasonal, chỉ khác cách ước lượng tham số). Trong Excel, thực hiện bằng Solver với Set Objective = ô MSE, By Changing = tất cả ô hệ số Trend và 12 ô chỉ số mùa vụ cùng lúc, Constraint: tổng 12 chỉ số = 12.

1.3 Đo tính chu kỳ bằng ACF

Autocorrelation Function (ACF) đo hệ số tương quan giữa Y_t và Y_{t-k} (giá trị cách k kỳ trước), với k gọi là *lag*. Đây là công cụ *định lượng* để xác nhận mùa vụ, bổ sung cho việc quan sát time plot bằng mắt — và sẽ quay lại nhiều lần trong giáo trình: kiểm tra phần dư ở Chương 2, kiểm định tính dừng ở Chương 4.

$$\text{Ngưỡng tin cậy} = \pm\frac{1{,}96}{\sqrt{n}}$$



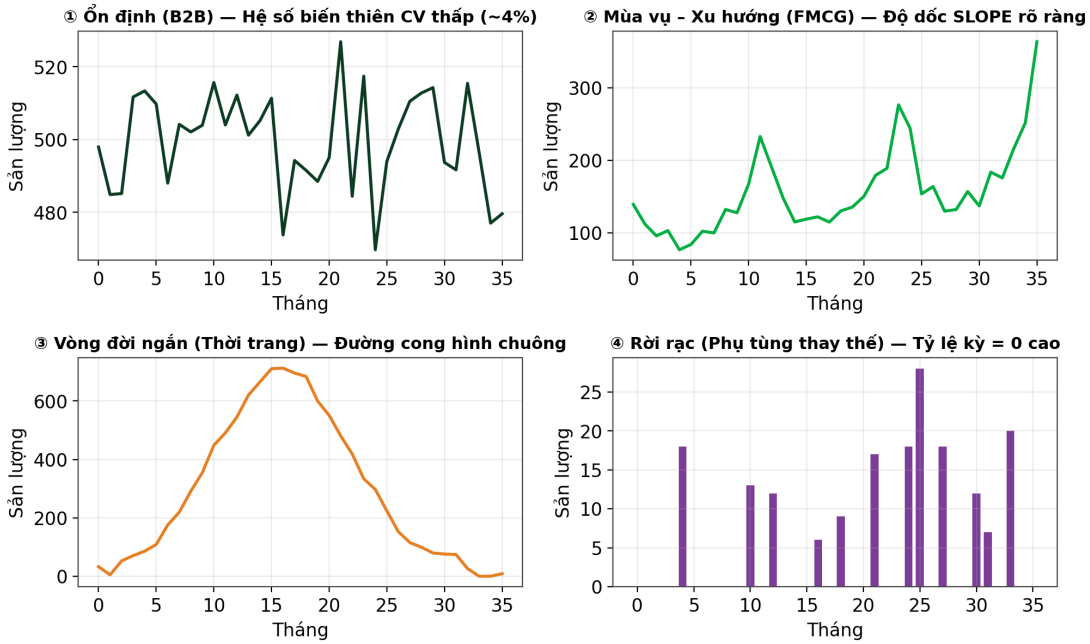
Đỉnh vượt ngưỡng rõ rệt tại lag 12 và lag 24 là bằng chứng định lượng cho mùa vụ chu kỳ 12 tháng — chắc chắn hơn nhiều so với chỉ nhìn time plot rồi suy đoán. Hằng số 1,96 trong công thức ngưỡng chính là giá trị z ứng với độ tin cậy 95%, sẽ gặp lại ở công thức khoảng tin cậy (Chương 2) và Safety Stock (Chương 6).

1.4 Bốn hình dạng nhu cầu cơ bản

Phần lớn các SKU trong thực tế chuỗi cung ứng có thể được phân loại vào một trong bốn nhóm hình dạng nhu cầu sau:

- **Ổn định (Stable):** doanh số dao động nhẹ quanh một mức trung bình không đổi, không có xu hướng tăng/giảm hệ thống và không có mẫu hình lặp lại theo mùa.
- **Mùa vụ – Xu hướng (Trend-Seasonal):** doanh số vừa tăng trưởng dần theo thời gian, vừa lặp lại theo chu kỳ trong năm (ví dụ cao điểm vào một số tháng cố định hàng năm).

- **Rời rạc (Intermittent):** tỷ lệ đáng kể các kỳ quan sát có giá trị bằng không, phản ánh nhu cầu không phát sinh đều đặn mà chỉ xuất hiện khi có sự kiện cụ thể (ví dụ nhu cầu sửa chữa, thay thế linh kiện).
- **Vòng đời ngắn (Short Life-cycle):** sản phẩm mới hoặc có tính thời vụ rất ngắn, chưa tích lũy đủ lịch sử dữ liệu để xác lập một mẫu hình ổn định.



1.5 Ba chỉ số định lượng phân loại

Để phân loại một cách khách quan, ba chỉ số sau được sử dụng, đều có thể tính bằng công thức Excel tiêu chuẩn.

Hệ số biến thiên (Coefficient of Variation):

$$CV = \frac{\sigma}{\mu}$$

trong đó σ là độ lệch chuẩn của chuỗi dữ liệu và μ là giá trị trung bình. CV đo mức biến động TƯƠNG ĐỐI so với quy mô của chính chuỗi số, cho phép so sánh mức độ ổn định giữa các SKU có quy mô doanh số khác nhau. Ngưỡng tham khảo: CV nhỏ hơn 0.5 được coi là ổn định; CV lớn hơn 1.0 phản ánh biến động rất mạnh.

Tỷ lệ kỳ có giá trị bằng không:

$$\%\text{kỳ} = 0 \;=\; \frac{\text{số kỳ có } Y_t = 0}{\text{tổng số kỳ quan sát}}$$

Chỉ số này đo mức độ "rời rạc" của nhu cầu. Khi %kỳ=0 vượt quá khoảng 30-50%, phần lớn

các phương pháp dự báo tiêu chuẩn (trình bày ở Chương 3-5) sẽ cho kết quả không đáng tin cậy, do các phương pháp này giả định ngầm về tính liên tục của dữ liệu.

Độ dốc xu hướng tuyến tính (SLOPE):

$$\text{SLOPE} = \frac{\sum(t-\bar{t})(Y_t-\bar{Y})}{\sum(t-\bar{t})^2}$$

SLOPE là hệ số góc của đường hồi quy tuyến tính đơn giản giữa Y_t và thứ tự thời gian t, đo tốc độ thay đổi trung bình của chuỗi theo mỗi đơn vị thời gian. SLOPE dương và có ý nghĩa (so với quy mô dữ liệu) cho thấy xu hướng tăng trưởng hệ thống, không phải biến động ngẫu nhiên.

1.5.1 Bảng tính tay minh hoạ: CV và SLOPE trên 6 tháng đầu

t	Y_t	$t-\bar{t}$	$Y_t-\bar{Y}$	$(t-\bar{t})(Y_t-\bar{Y})$	$(t-\bar{t})^2$
1	758	−2,5	308,8	−772,1	6,25
2	430	−1,5	−19,2	28,8	2,25
3	462	−0,5	12,8	−6,4	0,25
4	448	0,5	−1,2	−0,6	0,25
5	296	1,5	−153,2	−229,8	2,25
6	301	2,5	−148,2	−370,4	6,25
			Tổng	−1350,5	**17,5**

Với $\bar{t} = 3{,}5$ và $\bar{Y} = 449{,}17$: $\sigma = 153{,}47$, nên $CV = 153{,}47/449{,}17 = 0{,}342$. SLOPE $= \sum(t-\bar{t})(Y_t-\bar{Y})/\sum(t-\bar{t})^2 = -1350{,}5/17{,}5 = -77{,}2$ — âm vì chỉ tính trên 6 tháng đầu (giai đoạn giảm trước khi phục hồi), khác với SLOPE dương trên toàn bộ 36 tháng đã nêu ở bảng cuối chương — minh hoạ vì sao SLOPE luôn nên tính trên TOÀN BỘ lịch sử, không phải một đoạn ngắn.

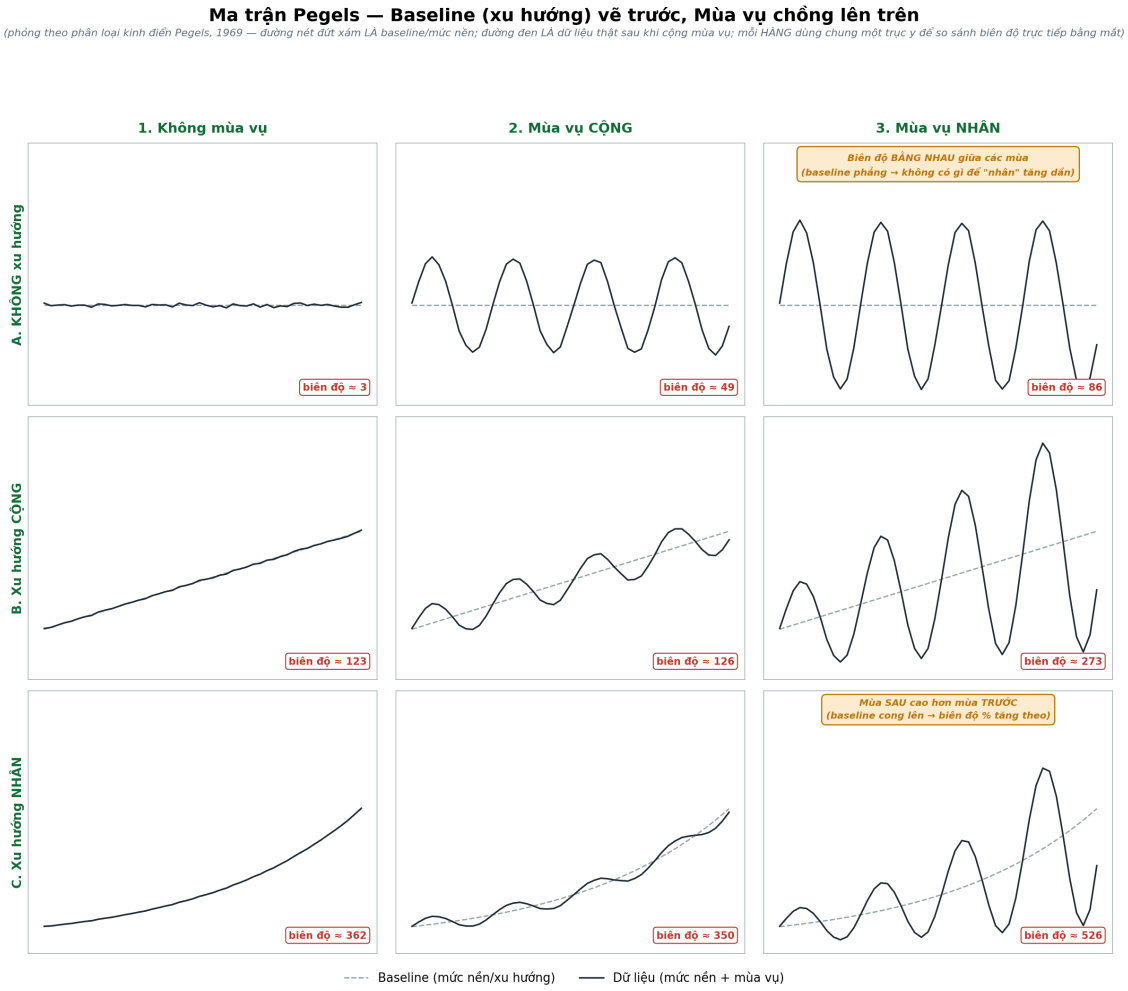
1.6 Ma trận Pegels

Ma trận Pegels là công cụ phân loại hai chiều: một chiều biểu thị đặc điểm xu hướng (không có / cộng / nhân), chiều còn lại biểu thị đặc điểm mùa vụ (không có / cộng / nhân). Mỗi ô trong ma trận tương ứng với một công thức Exponential Smoothing cụ thể sẽ được trình bày chi tiết ở Chương 3.

	Không mùa vụ (N)	Mùa vụ cộng (A)	Mùa vụ nhân (M)
Không xu hướng (N)	SES	Holt-Winters cộng	Holt-Winters nhân
Xu hướng cộng (A)	Holt	Holt-Winters (A,A)	Holt-Winters (A,M)
Xu hướng nhân (M)	Holt nhân	Holt-Winters (M,A)	Holt-Winters (M,M)

1.6.1 Hình dạng trực quan của cả chín ô

Bảng công thức ở trên rất hữu ích để tra cứu, nhưng để THỰC SỰ nhận diện được hình dạng dữ liệu công ty mình thuộc ô nào, cách hiệu quả nhất là nhìn hình dạng ĐỒ THỊ tương ứng với từng ô — đây chính là minh hoạ trực quan đầy đủ cho cả ma trận, phỏng theo phân loại kinh điển của Pegels (1969):



Cách đọc lưới 9 ô

Đọc THEO HÀNG để thấy xu hướng thay đổi thế nào khi giữ nguyên mùa vụ: hàng A dao động quanh một mức cố định; hàng B là đường thẳng dốc lên; hàng C là đường cong dốc dần (giống lãi kép). Đọc THEO CỘT để thấy mùa vụ thay đổi thế nào khi giữ nguyên xu hướng: cột 1 không có sóng lặp lại; cột 2 có sóng biên độ CỐ ĐỊNH, tạo dải song song quanh đường xu hướng; cột 3 có sóng biên độ PHÌNH RA theo xu hướng, tạo hình "loa kèn". So sánh trực tiếp ô B2 với B3 — CÙNG một xu hướng cộng, nhưng B3 có sóng ngày càng lớn dần — là cách nhanh nhất để phân biệt mùa vụ cộng và mùa vụ nhân trên dữ liệu thật của bạn.

Câu hỏi thường gặp: tại sao ô A3 (không xu hướng, mùa vụ nhân) không có hình "loa kèn"?

Mùa vụ NHÂN nghĩa là biên độ dao động bằng một TỶ LỆ PHẦN TRĂM của MỨC NỀN TẠI THỜI ĐIỂM ĐÓ. Ở hàng A, mức nền KHÔNG đổi theo thời gian — nên biên độ phần trăm của nó CŨNG không đổi, bốn mùa trong ô A3 cao BẰNG NHAU là điều ĐÚNG về mặt toán học, không phải lỗi vẽ biểu đồ. Nhìn kỹ sẽ thấy ô A3 vẫn có biên độ LỚN HƠN RÕ RỆT so với ô A2 (mùa vụ cộng) — vì tỷ lệ phần trăm áp lên mức nền 50 vẫn cho ra một con số cố định lớn hơn mức cộng cố định tuỳ chọn. Hình "loa kèn– biên độ TĂNG DẦN qua các mùa — CHỈ xuất hiện khi mùa vụ NHÂN kết hợp với XU HƯỚNG (hàng B, C), vì lúc đó mức nền tăng dần theo thời gian, kéo theo biên độ phần trăm cũng tăng dần theo.

1.7 Ví dụ minh hoạ trên bốn SKU thực tế

Bảng dưới đây trình bày kết quả tính toán thực tế trên bốn SKU của công ty GDMN, sử dụng cùng một bộ dữ liệu mô phỏng có khả năng tái lập (numpy.random.default_rng(42)).

SKU	CV	%kỳ=0	SLOPE	Hình dạng
Nồi cơm điện 1.8L	0.399	0.0%	+12.73	Mùa vụ – Xu hướng
Bếp từ đôi	0.035	0.0%	-0.22	Ổn định
Phụ tùng thay thế X12	1.389	61.0%	n/a	Rời rạc
Áo khoác mùa đông	1.363	56.0%	+19.83	Vòng đời ngắn

Kết luận chương

việc phân loại chính xác hình dạng nhu cầu là bước bắt buộc trước khi lựa chọn phương pháp dự báo. Sai lầm phổ biến nhất của người mới bắt đầu là bỏ qua bước này và áp dụng ngay một phương pháp “mặc định” cho mọi loại SKU.

1.8 Case Study Thực Tế: Nike và cái giá 100 triệu USD của việc đọc sai nhu cầu (2001)

Trước khi chuyển sang chương đo lường độ chính xác, hãy dừng lại ở một case cho thấy đọc SAI hình dạng nhu cầu ở cấp SKU có thể tốn kém đến mức nào — kể cả với một thương hiệu toàn cầu có đầy đủ nguồn lực công nghệ.

Ngành: Bán lẻ thời trang thể thao (Retail / Apparel)

Năm 2000–2001, Nike triển khai hệ thống hoạch định nhu cầu (demand-planning) của i2 Technologies để dự báo cho hàng nghìn mẫu giày, thay thế cách làm thủ công trước đó. Hệ thống mới lại đưa ra dự báo sai lệch nghiêm trọng ở cấp SKU: nhiều mẫu giày bán chạy như dòng Air Jordan bị đặt hàng THIẾU ngay mùa cao điểm, trong khi hàng loạt mẫu ít phổ biến bị đặt THỪA, tồn kho ứ đọng buộc phải giảm giá xả hàng. Nike công bố thiệt hại doanh thu ước tính khoảng 100 triệu USD trong một quý, cổ phiếu giảm khoảng 20% ngay sau đó. CEO Phil Knight khi đó thốt lên câu nổi tiếng: *"This is what you get for $400 million, huh?"* — ám chỉ khoản đầu tư khổng lồ vào hệ thống.

Bài học liên hệ chương này: nguyên nhân gốc rễ không hẳn nằm ở phần mềm "tệ", mà ở việc vận hành một hệ thống dự báo cho HÀNG NGHÌN SKU mà không phân loại đúng hình dạng nhu cầu của từng nhóm trước khi áp mô hình — một mẫu giày đang "hot" có hành vi nhu cầu hoàn toàn khác một mẫu cận biên, nhu cầu rời rạc. Đây chính xác là lý do Ma trận Pegels (mục trước) yêu cầu phân loại SKU theo CV, %kỳ=0, SLOPE TRƯỚC khi chọn phương pháp dự báo — không có công thức "một cỡ vừa tất cả" cho một danh mục hàng nghìn SKU khác biệt nhau.

Nguồn: Panorama Consulting, "Nike Supply Chain Management Failure Case Study"; Henrico Dolfing, "Case Study 16: Nike's $100 Million Supply Chain Speed Bump".

CHƯƠNG 2

Đo Lường Độ Chính Xác

TỆP ĐÍNH KÈM — Chương 2

Python: `Buoi2/Buoi2_01_BieuDo.py`, `Buoi2/Buoi2_02_ExcelSheet_DoChinhXac.py`. **Excel:** sheet `Do_Chinh_Xac` trong `ERP_4SKU_DapAn_Buoi1.xlsx`. **Slide:** `Buoi2_DoLuongDoChinhXac.pptx`.

Chương này trình bày hệ thống các chỉ số đo lường sai số dự báo, cùng hai phương pháp mốc chuẩn (baseline) bắt buộc phải sử dụng trước khi đánh giá bất kỳ mô hình phức tạp nào.

2.1 Hai phương pháp Naive làm mốc chuẩn

Naive Forecast 1 (NF1) là phương pháp đơn giản nhất: dự báo kỳ tiếp theo bằng chính giá trị quan sát ở kỳ liền trước.

$F_t+1 = Y_t$

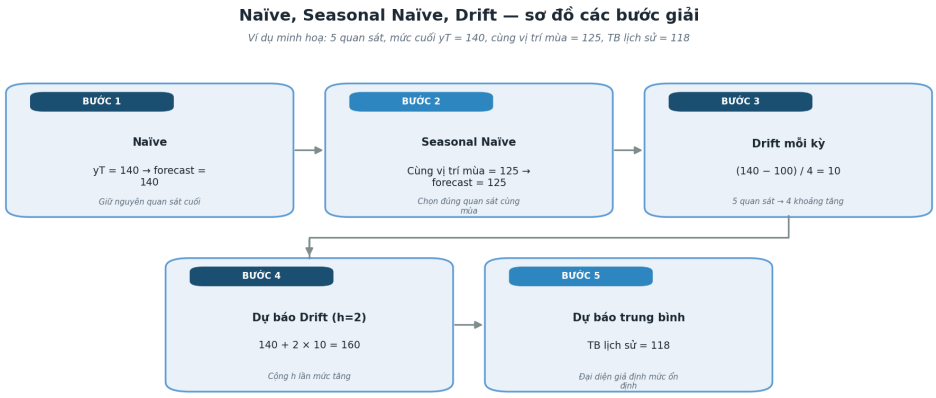
Naive Forecast 2 (NF2) bổ sung một điều chỉnh mùa vụ đơn giản dựa trên tỷ lệ giữa mức trung bình lũy kế hiện tại và mức trung bình lũy kế cùng kỳ 12 tháng trước, giúp NF2 phản ánh tốt hơn các SKU có mùa vụ rõ rệt.

$$S_t = \frac{m \cdot S_{t-12} + Y_t}{m+1} \qquad F_{t+1} = Y_t - S_t + S_{t-11}$$

Nguyên tắc bắt buộc

bất kỳ mô hình dự báo nào được đề xuất, dù phức tạp đến đâu, đều phải được so sánh với NF1 và NF2. Nếu không vượt trội hơn hai mốc chuẩn này, mô hình đó không tạo ra giá trị thực tế và không nên được áp dụng.

NF1 và NF2 là hai đại diện thực hành của một họ ba phương pháp nền tảng hơn — Naïve, Seasonal Naïve và Drift — mỗi phương pháp trả lời một câu hỏi khác nhau về "nếu không biết gì thêm, nên dự báo bằng gì". Sơ đồ dưới đây tóm tắt cách tính cả ba trên cùng một ví dụ minh hoạ:



2.2 Năm chỉ số sai số

Với et = Y_t - F_t là sai số tại kỳ t (giá trị thực tế trừ giá trị dự báo), năm chỉ số sau được sử dụng xuyên suốt khóa học:

Chỉ số	Công thức	Ý nghĩa / Hạn chế
ME	trung bình(et)	Phát hiện thiên lệch hệ thống (trong thực hành gọi là **Forecast Bias**); các sai số trái dấu triệt tiêu nhau, không đo được độ lớn.
MAE	trung bình(|et|)	Sai số tuyệt đối trung bình, cùng đơn vị dữ liệu gốc, không bị triệt tiêu.
MSE	trung bình(et^2)	Phạt nặng sai số lớn; là đầu vào trực tiếp cho công thức Safety Stock (Chương 6).
MPE	trung bình(et/Y_t) × 100%	Tương tự ME nhưng theo phần trăm; vẫn bị triệt tiêu do giữ dấu.
MAPE	trung bình($\|et/Y_t\|$) × 100%	Chỉ số phổ biến nhất; so sánh được giữa các SKU khác quy mô; không xác định khi $Y_t = 0$.

2.2.1 ME chính là Forecast Bias trong ngành

Công thức ME (Mean Error) ở bảng trên, khi dùng trong công việc Demand Planning thực tế, thường được gọi bằng tên khác: **Forecast Bias** (thiên lệch dự báo). Đây không phải hai chỉ số khác nhau — cùng một công thức, chỉ khác tên gọi tuỳ ngữ cảnh học thuật hay công nghiệp. Forecast Bias DƯƠNG liên tục qua nhiều kỳ nghĩa là mô hình đang có xu hướng dự báo THẤP hơn thực tế một cách hệ thống — rủi ro THIẾU HÀNG; Forecast Bias ÂM liên tục nghĩa là dự báo CAO hơn thực tế — rủi ro DƯ TỒN KHO. Đây chính là khái niệm nền tảng cho Tracking Signal đã học ở Chương 6 — Tracking Signal thực chất là Forecast Bias được chuẩn hoá bằng MAD để so sánh được giữa các SKU.

2.2.2 WMAPE: khi các kỳ có quy mô doanh số chênh lệch lớn

MAPE có một nhược điểm ít được chú ý: nó lấy trung bình CỘNG đơn giản của các phần trăm lỗi từng kỳ, khiến những kỳ có DOANH SỐ THẤP (dù chỉ lệch vài đơn vị) có thể tạo ra phần trăm lỗi RẤT LỚN và kéo MAPE lên cao, dù xét về SỐ TUYỆT ĐỐI ảnh hưởng đến doanh nghiệp không đáng kể. **WMAPE** (Weighted MAPE, còn gọi là WAPE) khắc phục điều này bằng cách gộp tất cả sai số tuyệt đối và tất cả doanh số THÀNH MỘT TỶ SỐ DUY NHẤT trước khi chia, thay vì lấy trung bình của từng tỷ số riêng lẻ:

$$\text{WMAPE} = \frac{\sum_{t=1}^{n} |Y_t - F_t|}{\sum_{t=1}^{n} Y_t} \times 100\%$$

Về bản chất, WMAPE tự động gán TRỌNG SỐ LỚN HƠN cho các kỳ có doanh số cao (đúng như tên gọi "Weighted") — phản ánh sát hơn tác động THỰC TẾ đến doanh nghiệp, vì sai số tại kỳ doanh số cao quan trọng hơn nhiều so với sai số tại kỳ doanh số thấp.

Kết quả thật

Trên Áo khoác mùa đông (sản phẩm mới, doanh số tăng từ 76 lên hơn 600 chiếc/tháng) với dự báo NF1: MAPE đạt 12,50% nhưng WMAPE chỉ 8,85% — chênh lệch 3,65 điểm phần trăm. Nguyên nhân: hai tháng đầu tiên (doanh số 112 và 166, còn thấp) có lỗi phần trăm rất lớn (32,1% và 32,5%) do lệch chỉ vài chục đơn vị, kéo MAPE (trung bình cộng đơn giản) lên cao; trong khi WMAPE, vốn lấy tổng lỗi tuyệt đối chia tổng doanh số, bị chi phối bởi các tháng SAU có doanh số lớn hơn nhiều và tỷ lệ lỗi thấp hơn, nên phản ánh sát hơn quy mô sai số thực tế đối với doanh nghiệp.

Khi nào ưu tiên WMAPE thay vì MAPE

Ưu tiên WMAPE khi so sánh độ chính xác TỔNG THỂ của một phương pháp trên toàn danh mục SKU có quy mô doanh số chênh lệch lớn (ví dụ báo cáo hiệu suất forecast cấp công ty), hoặc khi SKU có nhiều kỳ doanh số thấp dễ làm MAPE bị "phóng đại"bởi vài kỳ ngoại lệ. Vẫn nên giữ MAPE khi cần đánh giá độ chính xác riêng lẻ tại TỪNG kỳ, vì WMAPE là một con số tổng hợp toàn chuỗi, không cho biết kỳ nào cụ thể sai nhiều.

2.3 Khoảng tin cậy dự báo

Khoảng tin cậy của một dự báo được xây dựng dựa trên MSE của phương pháp đang sử dụng:

$$\text{Khoảng tin cậy} = F_t \pm z \cdot \sqrt{\text{MSE}}$$

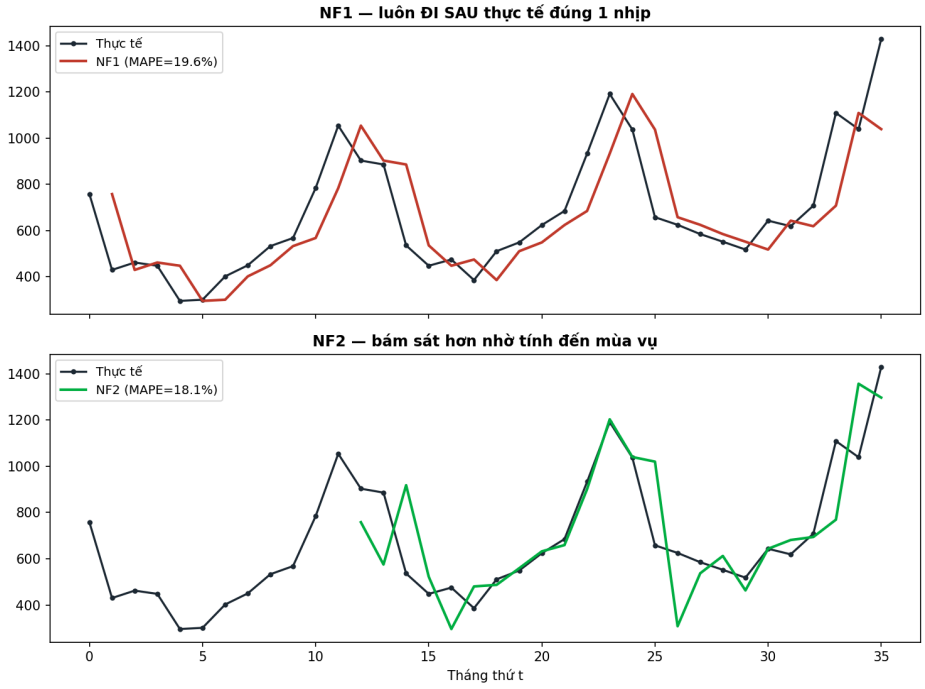
trong đó z là phân vị chuẩn tương ứng với mức tin cậy mong muốn (z=1.645 cho 90%, z=1.96 cho 95%, z=2.576 cho 99%). Công thức này là nền tảng trực tiếp cho công thức Safety Stock sẽ trình bày ở Chương 6.

2.4 Ví dụ minh hoạ thực tế: NF1 và NF2 trên hai SKU

2.4.1 Bảng tính tay: năm chỉ số sai số cho NF1

Tháng	Y_t	F_t(NF1)	e_t	e_t^2	PE (%)	|PE| (%)
02/2022	430	758	−328	107.584	−76,28	76,28
03/2022	462	430	+32	1.024	+6,93	6,93
04/2022	448	462	−14	196	−3,12	3,12
05/2022	296	448	−152	23.104	−51,35	51,35
06/2022	301	296	+5	25	+1,66	1,66
07/2022	402	301	+101	10.201	+25,12	25,12
Trung bình 6 tháng			−59,3	**23.689**	−16,17	**27,41**

Sáu tháng này minh hoạ trực tiếp "bẫy"đã nêu ở Mục 2.2: ME (trung bình e_t có dấu) = −59,3 trông có vẻ nhỏ, nhưng MAE thực tế (trung bình $|e_t|$) lớn hơn nhiều lần — vì các sai số âm và dương triệt tiêu lẫn nhau trong phép tính ME, trong khi MAE và MAPE phản ánh đúng độ lớn sai số trung bình mỗi tháng.



Nhìn trực quan, NF1 luôn "đi sau"đường thực tế đúng một nhịp — vì công thức chỉ đơn giản lặp lại giá trị kỳ trước. NF2 bám sát hơn nhờ tham chiếu đúng giá trị cùng kỳ năm trước, có điều chỉnh theo xu hướng gần đây.

SKU / Phương pháp	MAE	MSE	MAPE
Nồi cơm điện — NF1	130.91	31486.0	19.60%
Nồi cơm điện — NF2	114.59	23126.2	17.41%
Bếp từ đôi — NF1	18.91	645.8	3.68%
Bếp từ đôi — NF2	19.51	629.8	3.79%

Nhận xét

với Nồi cơm điện (có mùa vụ), NF2 vượt trội NF1 nhờ điều chỉnh mùa vụ. Với Bếp từ đôi (ổn định, không mùa vụ), NF1 lại nhỉnh hơn NF2 — vì phần điều chỉnh mùa vụ của NF2 không có tác dụng khi không có mùa vụ thật, thậm chí gây nhiễu nhẹ.

2.5 Case Study Thực Tế: Google Flu Trends — khi "dữ liệu lớn" tự tin sai gần gấp đôi (2013)

Chương này vừa học cách ĐO LƯỜNG độ chính xác dự báo. Case sau đây cho thấy vì sao bước đo lường này không bao giờ được bỏ qua, kể cả khi dự báo đến từ nguồn dữ liệu khổng lồ và thuật toán hiện đại.

Ngành: Y tế công cộng / Công nghệ (Public Health / Big Data)

Ra mắt năm 2008, Google Flu Trends (GFT) dự báo tỷ lệ mắc cúm dựa trên tần suất các từ khoá tìm kiếm liên quan, từng được truyền thông ca ngợi là "nhanh hơn cả CDC". Nhưng mùa cúm 2012–2013, GFT dự báo khoảng 11% dân số Mỹ mắc cúm, trong khi số liệu thực tế do CDC công bố sau đó chỉ khoảng 6% — sai lệch gần gấp đôi. Nghiên cứu "The Parable of Google Flu" (Lazer, Kennedy, King, Vespignani — *Science*, 2014) cho thấy GFT dự báo VƯỢT thực tế ở 100/108 tuần trong giai đoạn 08/2011–09/2013, và gọi đây là hiện tượng "big data hubris" — sự tự tin thái quá rằng khối lượng dữ liệu khổng lồ có thể thay thế hoàn toàn phương pháp đo lường có kiểm chứng.

Bài học liên hệ chương này: một dự báo dù đến từ nguồn dữ liệu lớn và thuật toán phức tạp đến đâu cũng PHẢI được đối chiếu định kỳ với số liệu thực tế bằng các chỉ số sai số vừa học (MAPE, MAE, MSE...) — không quy mô dữ liệu nào miễn trừ một mô hình khỏi việc bị đo sai số. Đây cũng là lý do khóa học nhấn mạnh khoảng tin cậy dự báo (mục sau) thay vì chỉ báo cáo một con số dự báo duy nhất trông có vẻ chắc chắn.

Nguồn: Lazer, Kennedy, King, Vespignani, "The Parable of Google Flu: Traps in Big Data Analysis", Science, 2014; TIME, "Google Flu Trends: The Limits of Big Data" (2014).

CHƯƠNG 3

Exponential Smoothing

TỆP ĐÍNH KÈM — Chương 3

Python: `Buoi3/Buoi3_01_BieuDo.py`, `Buoi3/Buoi3_02_ExcelSheet_SES.py`, `Buoi3/Buoi3_03_ExcelSheet_MovingAverage.py`, `Buoi3/Buoi3_04_ExcelSheet_MovingAverage_NangCao.py` (Solver WMA). **Excel:** sheet `Moving_Average`, `Exponential_Smoothing`. **Slide:** `Buoi3_ExponentialSmoothing.pptx`.

Chương này trình bày họ phương pháp Exponential Smoothing — nhóm mô hình dự báo đầu tiên trong giáo trình thực sự "học" từ dữ liệu thông qua việc gán trọng số giảm dần theo cấp số nhân cho các quan sát trong quá khứ. Trước khi trình bày Exponential Smoothing, chương bắt đầu bằng hai phương pháp đơn giản hơn — Moving Average và Double Moving Average — vừa là bước đệm tư duy tự nhiên từ phương pháp Naive (Chương 2), vừa làm rõ động cơ ra đời của cơ chế trọng số trong Exponential Smoothing.

3.1 Moving Average (Trung bình trượt)

$$MA_t = \frac{Y_t + Y_{t-1} + \cdots + Y_{t-k+1}}{k}$$

Moving Average (MA) dự báo kỳ tiếp theo bằng trung bình cộng của k quan sát gần nhất, trong đó k là độ rộng cửa sổ trượt (window size) do người phân tích tự chọn. Khác với Naive (chỉ dùng 1 quan sát) hay Exponential Smoothing (trọng số giảm dần, trình bày ở mục sau), MA gán trọng số BẰNG NHAU cho mọi quan sát nằm trong cửa sổ và loại bỏ hoàn toàn các quan sát nằm ngoài cửa sổ.

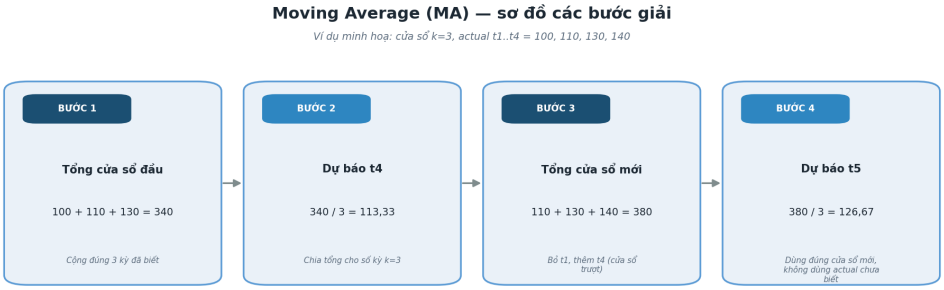
MA có hai hạn chế cố hữu cần lưu ý. Thứ nhất, hiện tượng độ trễ (lag): vì sử dụng trọng số bằng nhau cho các quan sát trong quá khứ, MA luôn phản ứng chậm hơn so với biến động thật của dữ liệu, đặc biệt nghiêm trọng khi dữ liệu có mùa vụ hoặc xu hướng mạnh. Thứ hai, việc lựa chọn k không có công thức tối ưu khép kín — khác với tham số alpha của Exponential Smoothing (mục 3.5) được xác định bằng tối ưu hoá số, k của MA thường phải xác định bằng thử nghiệm nhiều giá trị và so sánh sai số.

3.1.1 Bảng tính tay: MA(3) trên 4 tháng đầu tiên

Tháng	Y_{t-3}	Y_{t-2}	Y_{t-1}	MA_t = trung bình 3 giá trị
04/2022	758	430	462	$(758+430+462)/3 = 550{,}0$
05/2022	430	462	448	$(430+462+448)/3 = 446{,}7$
06/2022	462	448	296	$(462+448+296)/3 = 402{,}0$
07/2022	448	296	301	$(448+296+301)/3 = 348{,}3$

Cửa sổ 3 tháng trượt đều đặn về phía trước, mỗi lần bỏ giá trị cũ nhất và thêm giá trị mới nhất — đây chính là ý nghĩa của từ "trượt"(moving) trong tên gọi phương pháp.

Sơ đồ dưới đây tóm tắt lại đúng trình tự các bước vừa tính ở trên trên một ví dụ khác, dùng để ôn nhanh trước khi chuyển sang biến thể tiếp theo:



3.2 Weighted Moving Average (WMA)

$$WMA_t = w_1 Y_t + w_2 Y_{t-1} + \cdots + w_k Y_{t-k+1}, \qquad \sum w_i = 1$$

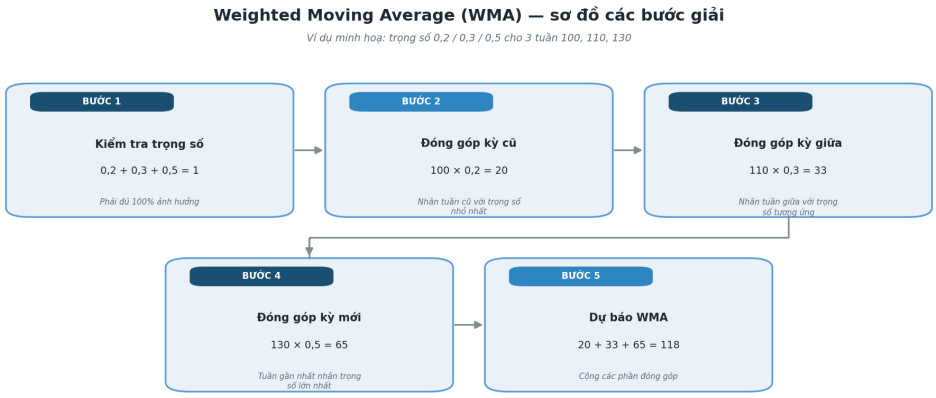
Weighted Moving Average khắc phục một phần nhược điểm độ trễ của MA bằng cách gán trọng số TĂNG DẦN TUYẾN TÍNH cho quan sát gần hiện tại hơn — ví dụ với k=3, bộ trọng số phổ biến nhất là 1:2:3 (chuẩn hoá thành 1/6, 2/6, 3/6). Về mặt vị trí trong họ các phương pháp làm mượt, WMA là điểm TRUNG GIAN giữa MA (trọng số bằng nhau) và Exponential Smoothing (trọng số giảm dần theo CẤP SỐ NHÂN, trình bày ở mục 3.5) — trọng số của WMA giảm dần THEO CẤP SỐ CỘNG (tuyến tính), không phải cấp số nhân.

WMA vẫn giữ nguyên nhược điểm thứ hai của MA: phải xác định cả cửa sổ k LẪN bộ trọng số bằng thử nghiệm thủ công, không có cơ chế tối ưu hoá tự động như alpha của SES. Đây chính là động lực trực tiếp dẫn đến sự ra đời của Exponential Smoothing.

3.2.1 Bảng tính tay: WMA(3) với trọng số 1:2:3

Tháng	Y_{t-3} (w=1/6)	Y_{t-2} (w=2/6)	Y_{t-1} (w=3/6)	WMA_t
04/2022	758	430	462	$\frac{1}{6}(758) + \frac{2}{6}(430) + \frac{3}{6}(462) = 500{,}7$
05/2022	430	462	448	$\frac{1}{6}(430) + \frac{2}{6}(462) + \frac{3}{6}(448) = 449{,}7$
06/2022	462	448	296	$\frac{1}{6}(462) + \frac{2}{6}(448) + \frac{3}{6}(296) = 374{,}3$
07/2022	448	296	301	$\frac{1}{6}(448) + \frac{2}{6}(296) + \frac{3}{6}(301) = 323{,}8$

So với bảng MA(3) ở mục trước trên CÙNG các tháng, WMA phản ứng nhanh hơn với biến động gần đây — ví dụ tháng 07/2022, WMA (323,8) thấp hơn MA (348,3), bám sát xu hướng giảm mạnh của hai tháng liền trước tốt hơn.



3.3 Double Moving Average

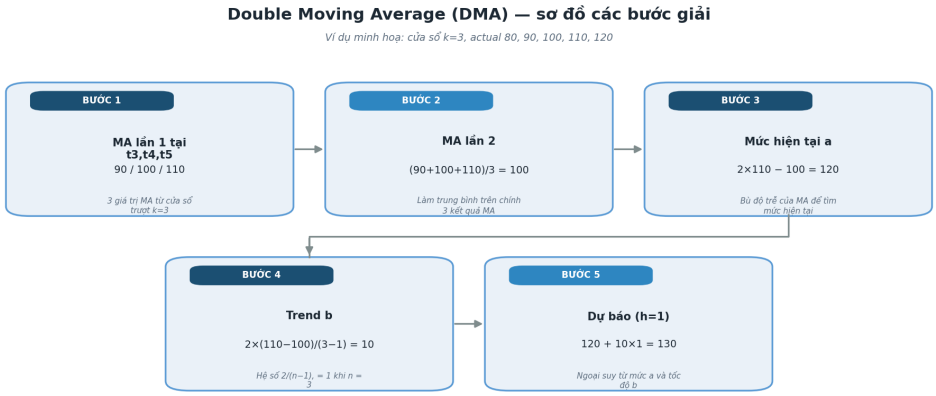
Khi chuỗi dữ liệu có xu hướng, Double Moving Average mở rộng MA bằng cách tính thêm một lớp trung bình trượt thứ hai (MA của chính MA), sử dụng độ chênh lệch giữa hai lớp để ước lượng độ dốc xu hướng:

$$a_t = 2MA'_t - MA''_t \qquad b_t = \frac{2}{k-1}(MA'_t - MA''_t)$$

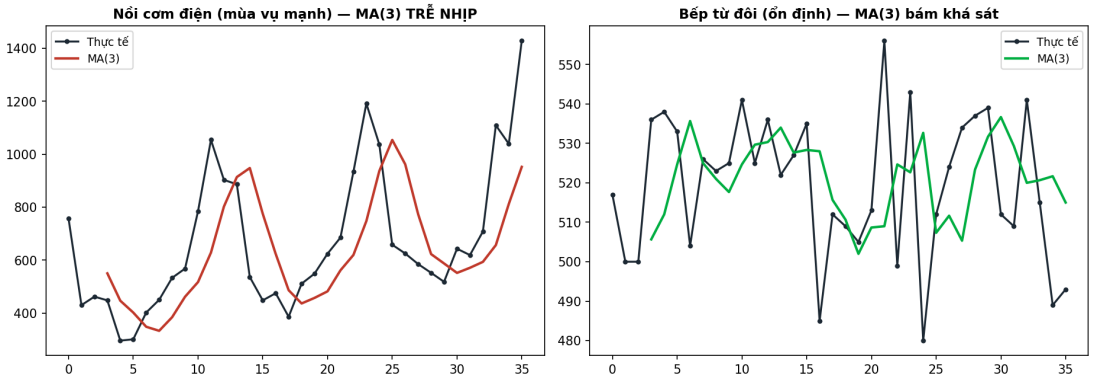
$$F_{t+1} = a_t + b_t$$

trong đó MA′t là trung bình trượt bậc một (như định nghĩa ở mục 3.1), MA″t là trung bình trượt bậc hai (trung bình trượt tính trên chính chuỗi MA′), at là ước lượng mức nền tại kỳ t, và bt là ước lượng độ dốc xu hướng tại kỳ t. Về mặt cấu trúc, Double Moving Average là tiền thân trực tiếp của mô hình Holt sẽ trình bày ở mục 3.6 — cùng nguyên lý tách mức nền và

xu hướng thành hai thành phần riêng biệt, chỉ khác ở cơ chế tính trọng số (đều bằng nhau ở Double-MA, giảm dần theo cấp số nhân ở Holt).



3.4 Kết quả thực nghiệm: khi nào các biến thể MA hoạt động tốt



Hai biểu đồ trên cùng công thức MA(3) nhưng áp dụng lên hai SKU khác hình dạng cho thấy rõ bản chất của độ trễ: trên Nồi cơm điện (mùa vụ mạnh), đường MA(3) luôn "chạy sau"mỗi khi mùa vụ đảo chiều; trên Bếp từ đôi (ổn định), không có đảo chiều đột ngột nên độ trễ gần như không đáng kể.

SKU	MA(k=3)	WMA(k=	Double-MA(k=3)	Nhận xét
Nồi cơm điện (mùa vụ mạnh)	28.73%	24.48%	28.30%	Cả ba đều thua xa NF2 (17.41%) — độ trễ không theo kịp mùa vụ
Bếp từ đôi (ổn định)	3.21%	3.22%	4.20%	MA/WMA khá tốt; Double-MA TỆ HƠN vì thêm xu hướng giả
Áo khoác mùa đông (xu hướng thật)	19.9%	16.36%	6.4%	Xếp hạng: Double-MA > WMA > MA — càng đúng cấu trúc càng tốt

Nhận xét sư phạm

ba kết quả trên minh hoạ đúng nguyên tắc sẽ lặp lại xuyên suốt giáo trình: một thành phần mô hình (trọng số tuyến tính ở WMA, hoặc xu hướng ở Double-MA) chỉ nên được thêm vào khi dữ liệu THẬT SỰ có đặc điểm tương ứng. Thêm sai — như Double-MA trên Bếp từ đôi — làm mô hình xấu đi; thêm đúng — như trên Áo khoác mùa đông — cải thiện đáng kể độ chính xác, và mức cải thiện tỷ lệ thuận với mức độ phù hợp của thành phần được thêm vào.

3.5 Simple Exponential Smoothing (SES)

$$F_{t+1} = \alpha Y_t + (1-\alpha)F_t, \qquad 0 \le \alpha \le 1$$

SES chỉ có một tham số làm mịn (smoothing parameter) alpha. Khai triển đệ quy công thức trên cho thấy F_t+1 thực chất là tổng có trọng số của toàn bộ lịch sử quan sát, với trọng số của quan sát cách hiện tại k kỳ bằng α(1-α)^k — giảm dần theo cấp số nhân, đây là nguồn gốc tên gọi của phương pháp. Khác với Moving Average, SES sử dụng toàn bộ lịch sử (không cắt cụt ở biên cửa sổ) và không có "đường biên cứng" giữa quan sát được tính và không được tính.

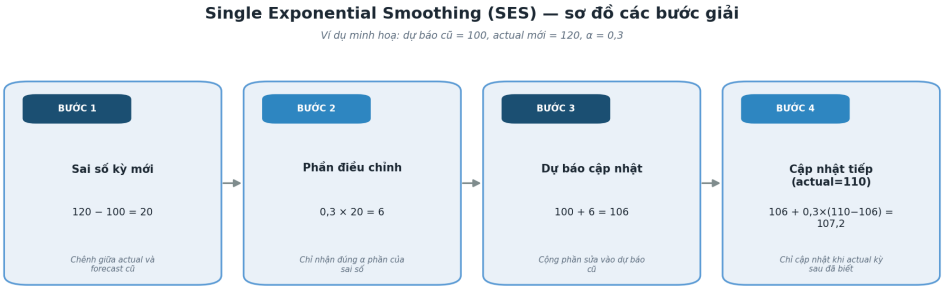
Tham số alpha được xác định bằng cách tối thiểu hoá tổng bình phương sai số (SSE) trên toàn bộ dữ liệu lịch sử, thường thực hiện bằng thuật toán tối ưu số (ví dụ Solver trong Excel, hoặc thuật toán L-BFGS trong thư viện statsmodels của Python) — khác với k của Moving Average phải xác định bằng thử nghiệm thủ công, đây là một trong những lý do chính khiến Exponential Smoothing được ưa chuộng hơn Moving Average trong thực hành. SES chỉ phù hợp với hình dạng nhu cầu Ổn định — ứng với ô (N,N) trong ma trận Pegels.

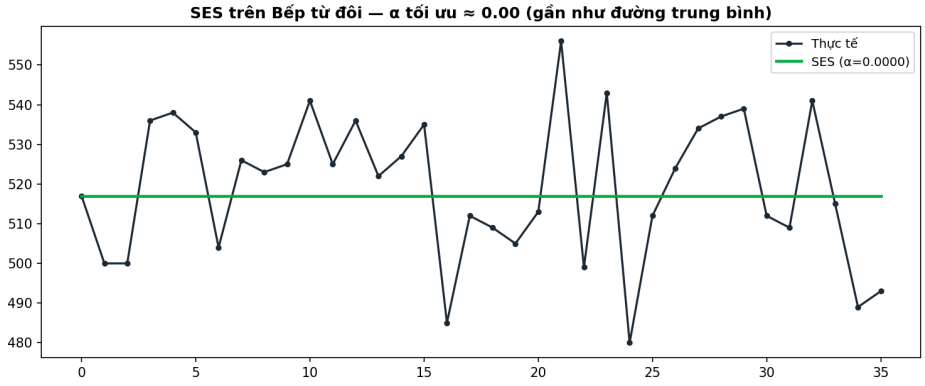
3.5.1 Bảng tính tay: SES đệ quy với alpha=0,1

t	Y_{t-1}	F_{t-1}	$F_t = 0{,}1Y_{t-1} + 0{,}9F_{t-1}$
1	—	—	$F_1 = Y_1 = 517{,}00$ (khởi tạo)
2	517	517,00	$0{,}1(517) + 0{,}9(517{,}00) = 517{,}00$
3	500	517,00	$0{,}1(500) + 0{,}9(517{,}00) = 515{,}30$
4	500	515,30	$0{,}1(500) + 0{,}9(515{,}30) = 513{,}77$
5	536	513,77	$0{,}1(536) + 0{,}9(513{,}77) = 515{,}99$
6	538	515,99	$0{,}1(538) + 0{,}9(515{,}99) = 518{,}19$

Mỗi dự báo mới chỉ cần MỘT giá trị thực tế gần nhất và MỘT dự báo cũ — không cần lưu trữ toàn bộ lịch sử như MA, đây là lý do SES tính toán rất nhanh dù về mặt lý thuyết vẫn "nhớ"toàn bộ quá khứ với trọng số giảm dần.

Sơ đồ dưới đây tóm tắt trình tự các bước tính SES trên một ví dụ minh hoạ:





Kết quả thật

Trên Bếp từ đôi, alpha tối ưu hội tụ về gần 0 — nghĩa là mô hình gần như KHÔNG cập nhật theo quan sát mới, dự báo gần như bằng phẳng ở mức trung bình lịch sử. Đây KHÔNG phải lỗi: SKU này gần như thuần nhiễu ngẫu nhiên, nên "tin vào mức nền"là chiến lược tối ưu về mặt toán học — alpha thấp phản ánh đúng bản chất ổn định của dữ liệu, không phải dấu hiệu mô hình kém.

3.6 Holt (Double Exponential Smoothing)

Khi chuỗi dữ liệu có xu hướng, mô hình Holt bổ sung một phương trình thứ hai để theo dõi độ dốc xu hướng, sử dụng thêm tham số beta:

$$L_t = \alpha Y_t + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

$$F_{t+k} = L_t + k \cdot T_t$$

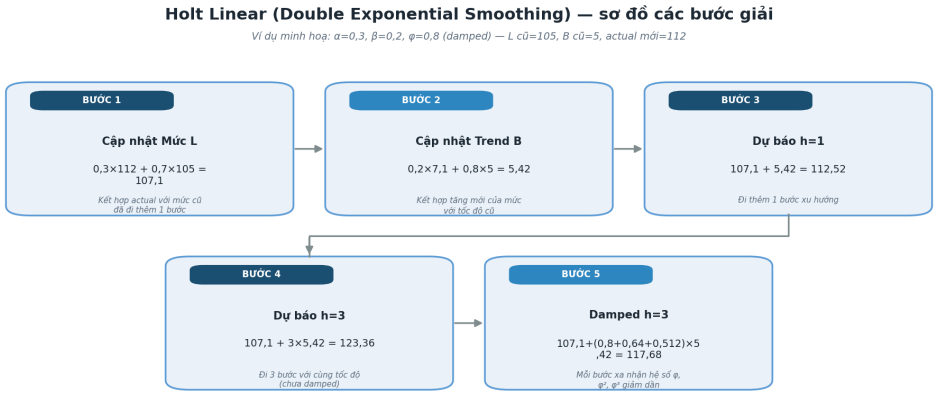
L_t là ước lượng mức nền (level) tại kỳ t, T_t là ước lượng độ dốc xu hướng (trend) tại kỳ t. Biến thể damped trend (xu hướng suy giảm) bổ sung một hệ số phi (0<phi<1) nhân vào thành phần xu hướng khi ngoại suy, giúp tránh dự báo xu hướng tăng/giảm vô hạn về dài hạn — biến thể này thường được khuyến nghị sử dụng mặc định.

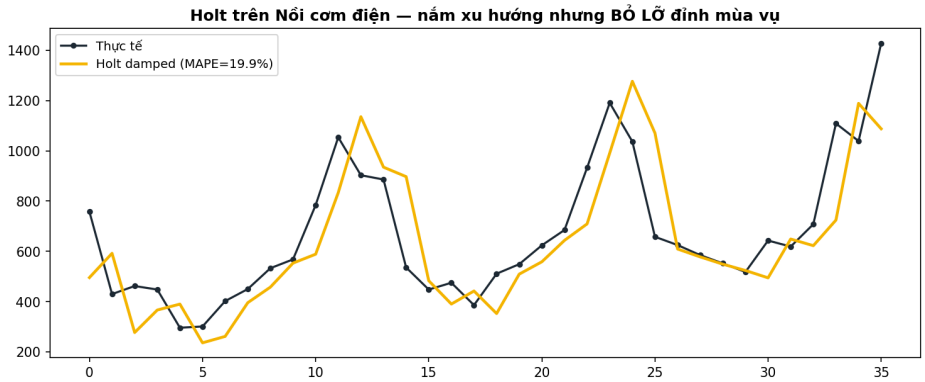
3.6.1 Bảng tính tay: Holt đệ quy với alpha=0,3, beta=0,1

t	Y_t	$L_{t-1}+T_{t-1}$	L_t	T_t	F_t
1	758	—	758,00	0,00	— (khởi tạo)
2	430	758,00	659,60	−9,84	758,00
3	462	649,76	593,43	−15,47	649,76
4	448	577,96	538,97	−19,37	577,96
5	296	519,60	452,52	−26,08	519,60
6	301	426,44	388,81	−29,84	426,44

Cột F_t (dự báo cho kỳ t) chính là $L_{t-1}+T_{t-1}$ — giá trị level cộng trend của kỳ NGAY TRƯỚC, minh hoạ trực tiếp công thức $F_{t+k} = L_t + k \cdot T_t$ với $k = 1$. Quan sát T_t liên tục ÂM và ngày càng âm hơn cho thấy mô hình đang "học"một xu hướng GIẢM từ dữ liệu 6 tháng đầu (giai đoạn trước Tết) — đây chính là nguồn gốc của việc Holt sau này bỏ lỡ đỉnh mùa vụ: nó chỉ theo dõi MỘT xu hướng tuyến tính duy nhất, không có cơ chế nhận biết chu kỳ lặp lại.

Sơ đồ dưới đây tóm tắt trình tự cập nhật Level và Trend của Holt Linear (kèm biến thể Damped Trend) trên một ví dụ minh hoạ:





Kết quả thật

Trên Nồi cơm điện, Holt nắm bắt được xu hướng tăng chung nhưng hoàn toàn BỎ LỠ các đỉnh mùa vụ, cho MAPE 19,9% — tệ hơn cả NF1 (19,6%), dù Holt có tối ưu tham số bằng Solver còn NF1 thì không có tham số nào cả. Đây là bằng chứng số liệu đầu tiên trong giáo trình cho nguyên tắc: mô hình phức tạp hơn không tự động thắng nếu thiếu đúng thành phần cấu trúc mà dữ liệu cần.

3.7 Holt-Winters (Triple Exponential Smoothing)

Khi chuỗi dữ liệu có cả xu hướng lẫn mùa vụ, Holt-Winters bổ sung phương trình thứ ba theo dõi chỉ số mùa vụ, dùng tham số gamma. Có hai biến thể chính:

Biến thể cộng (additive), sử dụng khi biên độ dao động mùa vụ không đổi theo quy mô dữ liệu:

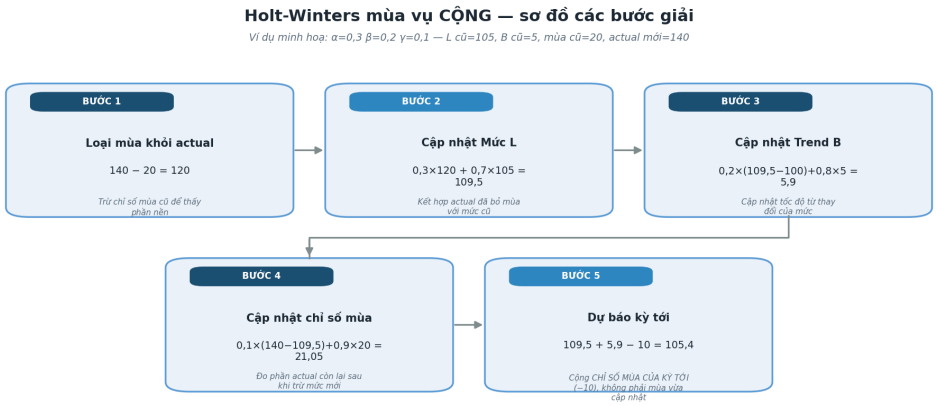
$$L_t = \alpha(Y_t - S_{t-s}) + (1-\alpha)(L_{t-1} + T_{t-1}) \qquad S_t = \gamma(Y_t - L_t) + (1-\gamma)S_{t-s}$$

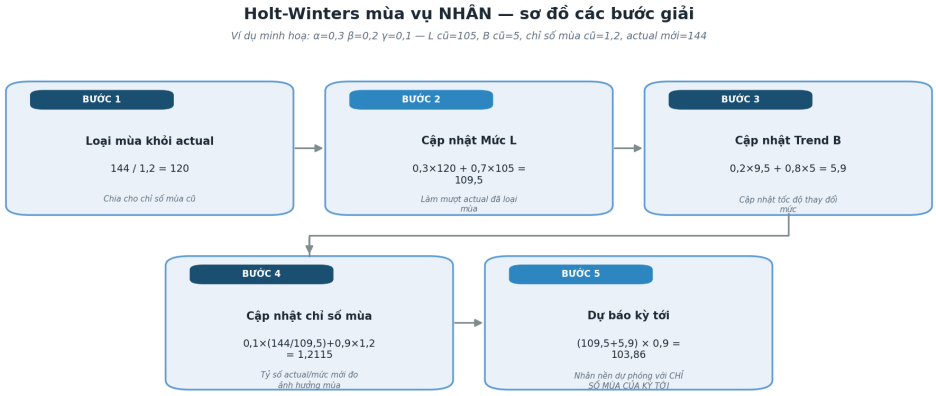
Biến thể nhân (multiplicative), sử dụng khi biên độ dao động mùa vụ tỷ lệ thuận với quy mô dữ liệu:

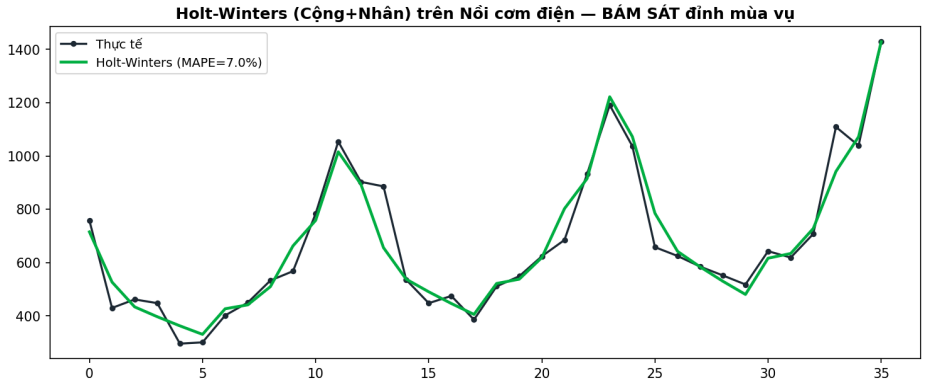
$$L_t = \alpha\left(\frac{Y_t}{S_{t-s}}\right) + (1-\alpha)(L_{t-1} + T_{t-1}) \qquad S_t = \gamma\left(\frac{Y_t}{L_t}\right) + (1-\gamma)S_{t-s}$$

trong đó s là độ dài chu kỳ mùa vụ (s=12 đối với dữ liệu tháng). Việc lựa chọn đúng biến thể (cộng hay nhân) và đúng cấu trúc (có/không xu hướng, có/không mùa vụ) theo ma trận Pegels ở Chương 1 quan trọng hơn nhiều so với việc luôn sử dụng mô hình phức tạp nhất có sẵn.

Hai sơ đồ dưới đây tóm tắt trình tự cập nhật ba thành phần Level–Trend–Seasonal của Holt-Winters, lần lượt cho biến thể mùa vụ CỘNG và mùa vụ NHÂN, trên cùng một ví dụ minh hoạ:





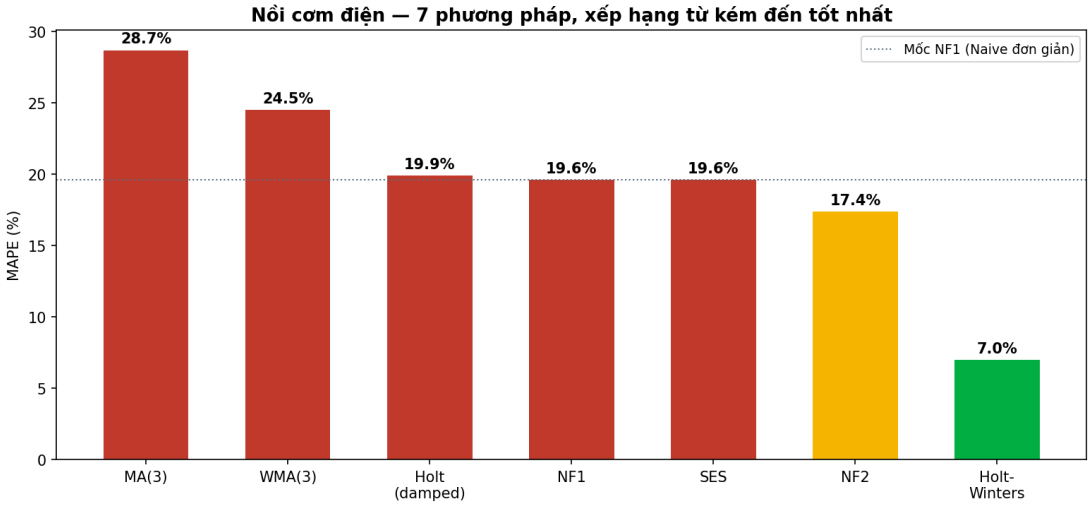


3.8 Kết quả thực nghiệm trên Nồi cơm điện 1.8L

Phương pháp	MAPE	Nhận xét
SES	19.60%	Không mô hình hoá được xu hướng lẫn mùa vụ — kém hơn NF2
Holt (damped)	19.9%	Chỉ mô hình hoá xu hướng, bỏ sót mùa vụ mạnh — vẫn kém
Holt-Winters (nhân)	7.04%	Mô hình hoá đủ cả xu hướng và mùa vụ — vượt trội rõ rệt

Bài học then chốt

Holt có nhiều tham số hơn SES nhưng KHÔNG vượt trội NF1/NF2 trên SKU có mùa vụ mạnh — bằng chứng cho nguyên tắc: đúng cấu trúc mô hình quan trọng hơn số lượng tham số.



Xếp toàn bộ bảy phương pháp học được đến thời điểm này theo thứ tự từ kém đến tốt nhất cho thấy một mẫu hình rõ ràng: mọi biến thể của họ Moving Average và cả Holt đều KHÔNG thắng nổi hai mốc Naive đơn giản (đường chấm chấm). Chỉ khi mô hình có ĐỦ cả hai thành phần Trend và Seasonal — đúng như cấu trúc thật của dữ liệu — độ chính xác mới cải thiện vượt bậc.

3.9 Case Study Thực Tế: Cuộc thi M-Competitions — vì sao mô hình đơn giản vẫn "sống khỏe" suốt 40 năm?

Trước khi bước sang ARIMA — một họ mô hình phức tạp hơn hẳn Exponential Smoothing — case sau đây rất đáng đọc kỹ: liệu phức tạp hơn có luôn nghĩa là chính xác hơn?

Ngành: Học thuật / Nghiên cứu dự báo, ứng dụng đa ngành

Từ năm 1982, giáo sư Spyros Makridakis khởi xướng chuỗi cuộc thi dự báo quy mô lớn (M1 đến M5), mời hàng trăm đội trên toàn cầu dự báo trên hàng nghìn chuỗi dữ liệu thật để trả lời câu hỏi: mô hình phức tạp có thực sự chính xác hơn mô hình đơn giản? Kết quả gây bất ngờ cho giới nghiên cứu: ở cuộc thi M3, phương pháp vô địch là **Theta method** — về bản chất là một biến thể của Simple Exponential Smoothing (chính là phương pháp SES sắp học trong chương này) kết hợp thêm một đường xu hướng tuyến tính, đơn giản hơn nhiều so với các mô hình kinh tế lượng phức tạp cùng dự thi (Hyndman & Billah chứng minh điều này trong bài báo "Unmasking the Theta Method", 2003). Đến M4 (2018), người chiến thắng là Slawek Smyl (Uber) với một mô hình LAI kết hợp Exponential Smoothing với mạng neural — KHÔNG phải một mô hình Machine Learning thuần túy; đáng chú ý hơn, cả 6 phương pháp ML thuần túy dự thi M4 đều có kết quả KÉM HƠN benchmark tổ hợp đơn giản (Combination benchmark).

Bài học liên hệ chương này: các phương pháp làm nền tảng của khóa học (MA, SES, Holt, Holt-Winters) không phải "công cụ cơ bản dành cho người mới" rồi sẽ bị thay thế khi lên trình độ cao hơn — chúng là những khối xây dựng CỐT LÕI mà ngay cả các mô hình vô địch thế giới cũng dùng làm thành phần chính, thường được KẾT HỢP THÊM (chứ không thay thế hoàn toàn) bởi các kỹ thuật hiện đại hơn như ARIMA sắp học sau đây.

Nguồn: Hyndman & Billah, "Unmasking the Theta Method", International Journal of Forecasting, 2003; Makridakis, Spiliotis & Assimakopoulos, "The M4 Competition: Results, findings, conclusion and way forward", 2018.

CHƯƠNG 4

ARIMA

TỆP ĐÍNH KÈM — Chương 4

Python: `Buoi4/Buoi4_01_BieuDo.py`, `Buoi4/Buoi4_02_ExcelSheet_TinhDung.py`, `Buoi4/Buoi4_03_AIC_Heatmap_LjungBox.py`. **Excel:** sheet `ARIMA_Tinh_Dung`. **Slide:** `Buoi4_ARIMA.pptx`.

Chương này trình bày họ mô hình ARIMA (AutoRegressive Integrated Moving Average) — cách tiếp cận dựa trên cấu trúc tự tương quan nội tại của chuỗi dữ liệu, khác biệt về triết lý so với Exponential Smoothing.

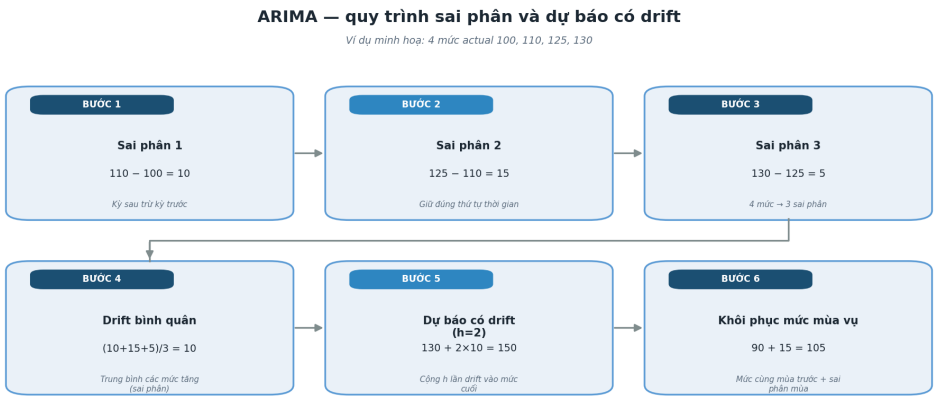
4.1 Tính dừng và kiểm định ADF

Một chuỗi thời gian được gọi là dừng (stationary) khi các đặc tính thống kê của nó — trung bình, phương sai, hiệp phương sai theo độ trễ — không thay đổi theo thời gian. ARIMA yêu cầu dữ liệu đầu vào phải dừng để các hệ số tự tương quan phản ánh đúng cấu trúc phụ thuộc thời gian, không bị nhiễu bởi xu hướng.

Kiểm định Augmented Dickey-Fuller (ADF) là công cụ thống kê chính thức kiểm tra tính dừng. Giả thuyết gốc (H0) là chuỗi CHƯA dừng (có nghiệm đơn vị). Quy tắc quyết định: nếu p-value nhỏ hơn 0.05, bác bỏ H0, kết luận chuỗi đã dừng; nếu p-value lớn hơn hoặc bằng 0.05, chưa đủ bằng chứng bác bỏ, kết luận chuỗi chưa dừng.

Khi chuỗi chưa dừng, phép sai phân (differencing) bậc d được áp dụng: chuyển từ Y_t sang ΔYt = Y_t - Y_t-1 (sai phân bậc 1), có thể lặp lại nếu cần (sai phân bậc 2 trở lên). Số lần sai phân cần thiết chính là tham số d trong ký hiệu ARIMA(p,d,q).

Sơ đồ dưới đây tóm tắt trình tự các bước kiểm tra dừng, sai phân và dự báo có drift của ARIMA trên một ví dụ minh hoạ:



SKU	ADF statistic	p-value	Kết luận
Nồi cơm điện (có xu hướng)	-1.201	0.6732	Chưa dừng — cần sai phân
Bếp từ đôi (ổn định)	-5.552	0.0000	Đã dừng — không cần sai phân

4.2 Thành phần AR và MA

Thành phần AutoRegressive bậc p, ký hiệu AR(p), biểu diễn giá trị hiện tại như một tổ hợp tuyến tính của p giá trị quá khứ của chính nó:

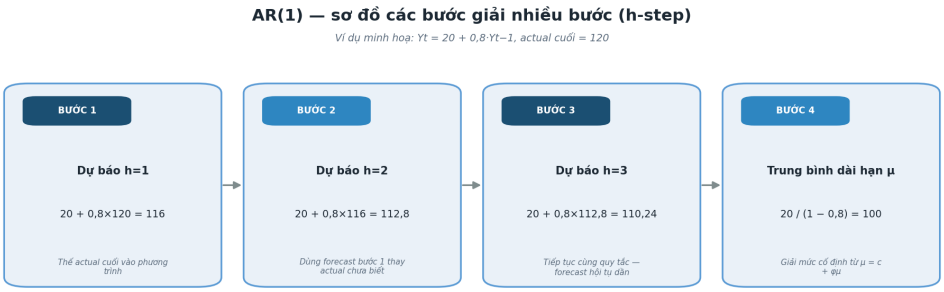
$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

Thành phần Moving Average bậc q, ký hiệu MA(q), biểu diễn giá trị hiện tại như một tổ hợp tuyến tính của q sai số dự báo trong quá khứ:

$$Y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Mô hình ARIMA(p,d,q) kết hợp cả hai thành phần trên áp dụng cho chuỗi đã sai phân bậc d. Khi bổ sung thêm thành phần mùa vụ, mô hình được mở rộng thành SARIMA(p,d,q)(P,D,Q)s, với các tham số viết hoa tương ứng áp dụng ở độ trễ theo chu kỳ mùa vụ s.

Sơ đồ dưới đây tóm tắt trình tự dự báo nhiều bước của mô hình AR(1) trên một ví dụ minh hoạ:

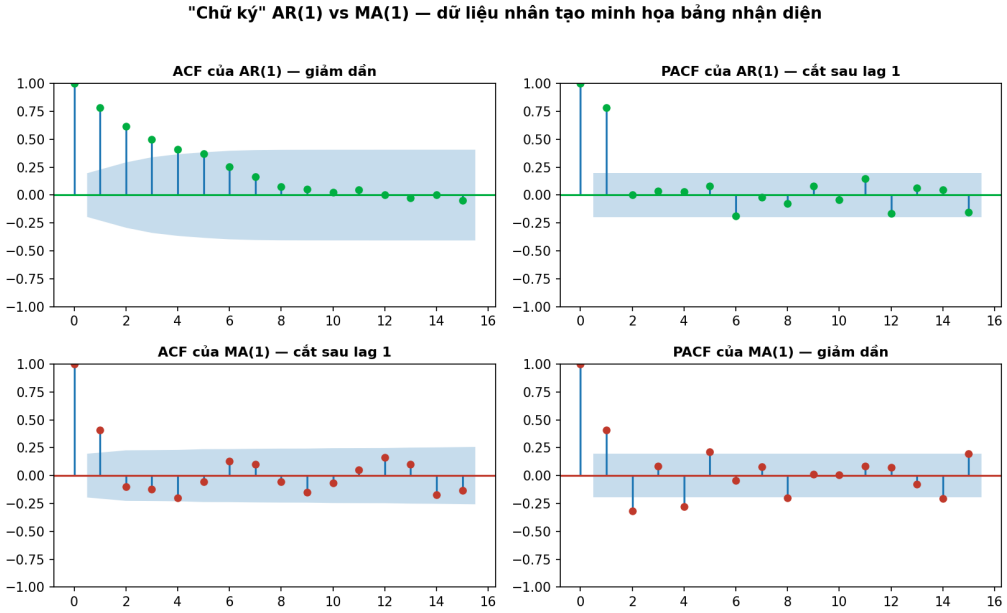


4.3 Đọc biểu đồ ACF và PACF

Autocorrelation Function (ACF) đo tương quan giữa Y_t và Y_t-k tại mỗi độ trễ k. Partial Autocorrelation Function (PACF) đo tương quan giữa Y_t và Y_t-k SAU KHI đã loại bỏ ảnh hưởng gián tiếp qua các độ trễ trung gian.

Quy tắc nhận dạng bậc mô hình dựa trên hình dạng hai biểu đồ:

- **Nếu PACF cắt đột ngột về 0 sau lag p, còn ACF giảm dần:** chuỗi có cấu trúc AR(p).
- **Nếu ACF cắt đột ngột về 0 sau lag q, còn PACF giảm dần:** chuỗi có cấu trúc MA(q).
- **Nếu cả hai đều giảm dần không cắt rõ rệt:** cân nhắc cấu trúc hỗn hợp ARMA, thường xác định bậc bằng tiêu chí AIC thay vì đọc đồ thị.



Bốn biểu đồ trên dùng dữ liệu nhân tạo (không phải SKU thật) để minh họa "chữ ký"lý tưởng, chưa bị nhiễu từ dữ liệu thực tế làm mờ đi: AR(1) có ACF giảm mượt còn PACF cắt hẳn sau lag 1; MA(1) thì ngược lại.

4.3.1 Bảng tính tay: ACF cho 4 lag đầu trên dữ liệu thật

Lag k	$\gamma_k = \sum(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})/n$	γ_0 (phương sai)	$r_k = \gamma_k/\gamma_0$
1	46.139,2	69.523,4	0,664
2	27.618,0	69.523,4	0,397
3	4.262,4	69.523,4	0,061
4	−11.325,4	69.523,4	−0,163

Tính trên toàn bộ 36 tháng Nồi cơm điện: ACF giảm dần từ lag 1 đến lag 4 rồi đổi dấu ở lag 4 — đúng dạng "giảm mượt"đặc trưng của thành phần AR, khớp với việc mô hình SARIMA tối ưu sau này chọn $q = 1$ (thành phần MA bậc thấp) chứ không phải AR bậc cao.

4.4 Tiêu chí lựa chọn mô hình: AIC

Akaike Information Criterion (AIC) là tiêu chí cân bằng giữa độ khớp của mô hình với dữ liệu và độ phức tạp (số tham số), giá trị càng thấp càng tốt:

$\text{AIC} = 2k - 2\ln(\hat{L})$

trong đó k là số tham số của mô hình, $\hat{L}$ là giá trị hợp lý cực đại (maximum likelihood). Trong thực hành, việc tìm bộ tham số (p,d,q) tối ưu thường được thực hiện bằng phương pháp duyệt lưới (grid search): thử tất cả tổ hợp tham số trong một phạm vi hợp lý, chọn tổ hợp có AIC nhỏ nhất.

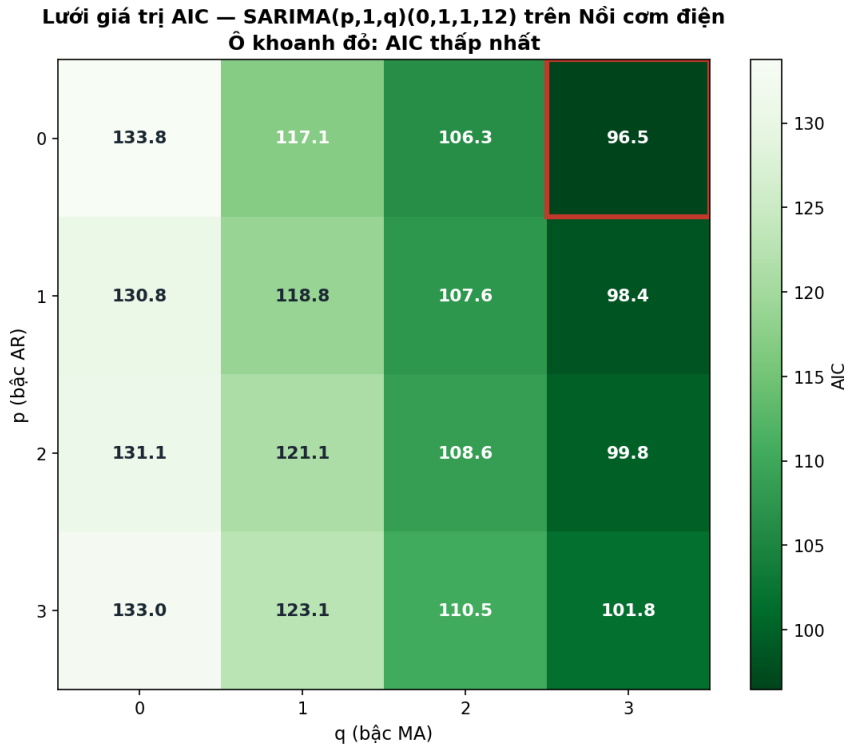
4.4.1 Bảng kết quả thật: 6 tổ hợp đầu tiên trong grid search

Tổ hợp $(p,d,q)(P,D,Q)_{12}$	**AIC**	**Nhận xét**
(0,1,0)(0,1,0)	291,7	Không thành phần nào — kém nhất
(0,1,0)(0,1,1)	133,8	Thêm MA mùa vụ — cải thiện mạnh
(0,1,1)(0,1,0)	265,9	Chỉ MA thường, thiếu mùa vụ — vẫn kém
(0,1,1)(0,1,1)	**117,1**	**Thấp nhất — mô hình được chọn**
(1,1,0)(0,1,1)	130,8	Thêm AR — không cải thiện
(1,1,1)(0,1,1)	118,8	Thêm cả AR lẫn MA — cũng không tốt hơn

So sánh hai dòng đầu và dòng thứ tư cho thấy rõ giá trị của thành phần MA mùa vụ $(0,1,1)$: AIC giảm từ 291,7 xuống 117,1 chỉ nhờ thêm đúng thành phần này — trong khi thêm AR ở hai dòng cuối lại LÀM TĂNG AIC nhẹ, xác nhận mô hình đơn giản $(0,1,1)(0,1,1)_{12}$ là lựa chọn tối ưu, không cần phức tạp hơn.

4.4.2 Trực quan hoá toàn bộ lưới AIC bằng bản đồ nhiệt

Bảng sáu dòng ở trên chỉ là một lát cắt nhỏ. Cách trình bày trực quan hơn — đặc biệt hữu ích khi thuyết trình hoặc rà soát nhanh một vùng tham số rộng — là vẽ TOÀN BỘ lưới (p,q) dưới dạng bản đồ nhiệt (heatmap), màu càng đậm AIC càng thấp:



Kết quả thật — và một bài học về phạm vi tìm kiếm

Mở rộng lưới tìm kiếm ra đầy đủ $p, q \in \{0, 1, 2, 3\}$ (thay vì chỉ sáu tổ hợp chọn tay ở bảng trên) cho thấy $(0, 1, 1)$ với AIC 117,1 — giá trị đã dùng xuyên suốt chương này — KHÔNG PHẢI điểm thấp nhất trong toàn vùng: $(0, 1, 3)$ đạt AIC 96,5, thấp hơn hẳn. Đây là bài học quan trọng: kết quả grid search phụ thuộc TRỰC TIẾP vào phạm vi bạn chọn tìm kiếm — một lưới quá hẹp có thể bỏ lỡ mô hình tốt hơn. Trong thực hành, luôn ưu tiên quét một phạm vi p, q đủ rộng (ví dụ 0 đến 5) bằng vòng lặp tự động thay vì chỉ thử vài tổ hợp trực giác, và đối chiếu tỷ lệ quan sát trên tham số (Chương 7) trước khi chọn mô hình phức tạp hơn chỉ vì AIC thấp hơn một chút.

4.4.3 Kiểm định Ljung-Box: xác nhận phần dư bằng con số, không chỉ bằng mắt

ACF phần dư (đã học ở trên) là cách kiểm tra ĐỊNH TÍNH — nhìn biểu đồ để đánh giá các thanh có vượt ngưỡng hay không. Kiểm định Ljung-Box bổ sung một bài kiểm tra ĐỊNH LƯỢNG chính thức, gộp thông tin tự tương quan tại NHIỀU lag cùng lúc thành một con số duy nhất:

$$Q = n(n+2) \sum_{k=1}^{h} \frac{r_k^2}{n-k}$$

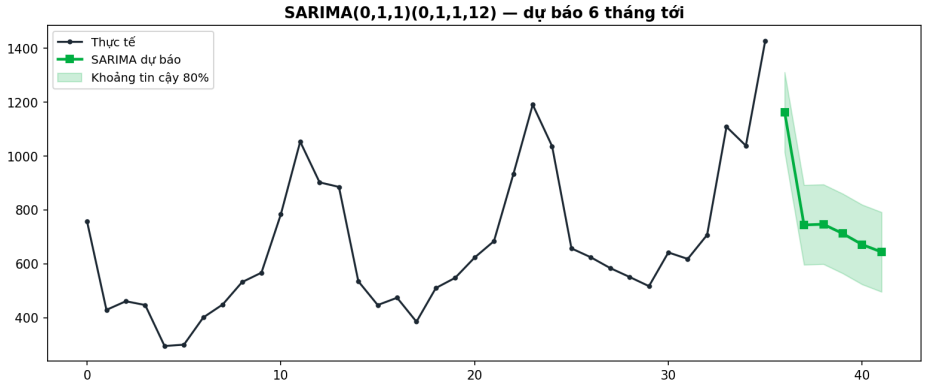
trong đó n là số quan sát, h là số lag kiểm tra, r_k là hệ số tự tương quan của phần dư tại lag k. Giả thuyết H_0: phần dư không có tự tương quan (là nhiễu trắng). Quy tắc đọc: nếu p-value $> 0{,}05$, KHÔNG đủ bằng chứng bác bỏ H_0 — phần dư được xem là chấp nhận được, mô hình có thể dùng để dự báo.

Số lag kiểm tra	Thống kê Q	p-value	Kết luận
6	0,87	0,990	p-value $\gg$ 0,05 — không bác bỏ H_0
12	8,79	0,721	p-value $\gg$ 0,05 — không bác bỏ H_0

Kết quả thật

Cả hai mức lag đều cho p-value rất lớn (0,99 và 0,72) — xác nhận ĐỊNH LƯỢNG điều đã thấy ĐỊNH TÍNH qua ACF phần dư: mô hình SARIMA$(0,1,1)(0,1,1)_{12}$ đã khai thác gần hết cấu trúc có thể học được, phần dư còn lại gần với nhiễu trắng. Trong Python, chỉ cần một dòng: `acorr_ljungbox(residuals, lags=[6,12], return_df=True)` từ `statsmodels.stats.diagnostic`.

4.5 Kết quả thực nghiệm: khi nào ARIMA không thắng



Trên SKU Nồi cơm điện, mô hình SARIMA(0,1,1)(0,1,1,12) tốt nhất theo AIC đạt MAPE 19.3% — KHÔNG vượt trội Holt-Winters (7.04%) dù ARIMA là mô hình tổng quát hơn về mặt lý thuyết. Nguyên nhân chính là số lượng tham số cần ước lượng cho thành phần mùa vụ trong SARIMA lớn hơn đáng kể so với Holt-Winters, trong khi chỉ có 36 quan sát (3 chu kỳ mùa vụ) để ước lượng — không đủ để các tham số hội tụ chính xác.

Kết luận chương

sức mạnh lý thuyết của một mô hình không đảm bảo hiệu quả thực tế khi lượng dữ liệu hạn chế. Việc lựa chọn phương pháp cần cân nhắc cả độ phức tạp cấu trúc lẫn quy mô dữ liệu sẵn có.

4.6 Case Study Thực Tế: ARIMA không chỉ là bài tập học thuật — nó chạy ngầm trong số liệu kinh tế quốc gia

Ngành: Thống kê chính phủ / Kinh tế vĩ mô

Mỗi khi một chỉ số như "Doanh số bán lẻ" hay "Tỷ lệ thất nghiệp" được công bố tại Mỹ kèm ghi chú "đã điều chỉnh mùa vụ" (seasonally adjusted), con số đó gần như chắc chắn đã đi qua **X-13ARIMA-SEATS** — phần mềm chính thức do Cục Thống kê Dân số Hoa Kỳ (U.S. Census Bureau) phát triển và duy trì, dựa trực tiếp trên khung mô hình ARIMA vừa học ở chương này (kết hợp thêm phương pháp SEATS của Ngân hàng Trung ương Tây Ban Nha). Đây không phải một thử nghiệm nội bộ: hàng loạt báo cáo kinh tế hằng tháng dùng để ra quyết định lãi suất, chính sách tài khoá của nhiều quốc gia đều dựa trên đầu ra của mô hình này.

Bài học liên hệ chương này: chuỗi thao tác "kiểm định tính dừng (ADF) → xác định bậc AR/MA qua ACF/PACF → chọn mô hình bằng AIC" mà chương này dạy không phải một quy trình mang tính lý thuyết suông — đó CHÍNH XÁC là quy trình vận hành bên trong một phần mềm được hàng chục cơ quan thống kê quốc gia trên thế giới tin dùng suốt hơn hai thập kỷ qua.

Nguồn: U.S. Census Bureau, "X-13ARIMA-SEATS Seasonal Adjustment Program", census.gov/data/software/x13as.htm

CHƯƠNG 5

Regression-Based Forecasting

TỆP ĐÍNH KÈM — Chương 5

Python: `Buoi5/Buoi5_01_BieuDo.py`, `Buoi5/Buoi5_02_ExcelSheet_Regression.py`, `Buoi5/Buoi5_03_QuadraticTrend.py`, `Buoi5/Buoi5_04_MultivariateRegression_YeuToNgoaiSinh.py`. **Excel:** sheet `Regression` (Regression Toolpak), `Quadratic_Trend` (LINEST đa biến), `Regression_DaBien_NgoaiSinh` (biến ngoại sinh liên tục + kiểm tra đa cộng tuyến). **Slide:** `Buoi5_RegressionForecasting.pptx`.

Chương này trình bày phương pháp hồi quy tuyến tính đa biến áp dụng cho dự báo — cách tiếp cận duy nhất trong giáo trình sử dụng thông tin NGUYÊN NHÂN bên ngoài (biến giải thích) thay vì chỉ dựa vào lịch sử nội tại của chuỗi số.

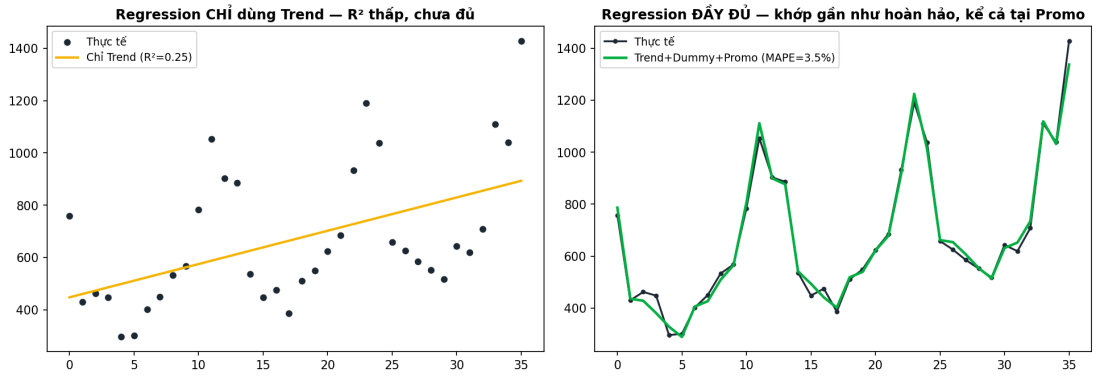
5.1 Mô hình hồi quy tuyến tính đa biến

$$Y = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_k X_k + \varepsilon$$

trong đó Y là biến phụ thuộc (doanh số cần dự báo), X1...Xk là các biến giải thích (biến độc lập), b0 là hệ số chặn (intercept), b1...bk là các hệ số hồi quy đo mức ảnh hưởng biên của từng biến giải thích, và ε là phần sai số không giải thích được bởi mô hình. Các hệ số được ước lượng bằng phương pháp bình phương nhỏ nhất thông thường (Ordinary Least Squares — OLS), tối thiểu hoá tổng bình phương phần dư.

Sơ đồ dưới đây tóm tắt trình tự các bước ước lượng đường hồi quy OLS đơn biến trên một ví dụ minh hoạ:





Panel trái cho thấy vì sao chỉ dùng Trend là chưa đủ: R^2 chỉ đạt 0,25, bỏ sót phần lớn biến động do mùa vụ và khuyến mãi gây ra. Panel phải, sau khi thêm đầy đủ biến giả tháng và biến Promo, đường khớp gần như trùng khít với thực tế — kể cả tại hai điểm khuyến mãi mà các mô hình chuỗi thời gian thuần túy ở Chương 3–4 đều gặp khó khăn.

5.2 Biến giả (Dummy Variables)

Biến giả là công cụ chuyển đổi thông tin định tính thành dạng số để đưa vào mô hình hồi quy. Với một biến phạm trù có m mức (ví dụ 12 tháng trong năm), cần m-1 biến giả để biểu diễn đầy đủ, với một mức được chọn làm mốc gốc (baseline). Ví dụ với biến tháng: chọn tháng 1 làm gốc, tạo 11 biến D2 đến D12, mỗi biến Dk nhận giá trị 1 nếu quan sát thuộc tháng k, ngược lại nhận giá trị 0.

Hệ số hồi quy của mỗi biến giả tháng cho biết mức chênh lệch trung bình giữa tháng đó và tháng gốc, sau khi đã kiểm soát các biến khác trong mô hình — đây là cách diễn giải trực tiếp và trực quan hơn nhiều so với chỉ số mùa vụ nhân/cộng trong Holt-Winters.

5.2.1 Bảng minh hoạ: cấu trúc dữ liệu biến giả cho 6 tháng đầu

Tháng	t	D2	D3	D4	D5	D6	Promo	Y_t
01/2022	1	0	0	0	0	0	1	758
02/2022	2	1	0	0	0	0	0	430
03/2022	3	0	1	0	0	0	0	462
04/2022	4	0	0	1	0	0	0	448
05/2022	5	0	0	0	1	0	0	296
06/2022	6	0	0	0	0	1	0	301

Tháng 01/2022 (t=1) là tháng GỐC (baseline) của biến dummy mùa vụ — D2 đến D12 đều bằng 0 — nhưng cột Promo lại bật lên 1, vì đây chính là tháng trùng đợt khuyến mãi Tết đã nêu ở Chương 1. Điều này hoàn toàn hợp lệ về mặt kỹ thuật: biến dummy mùa vụ (D2–D12) và biến giải thích Promo là hai nhóm biến ĐỘC LẬP, một tháng có thể vừa là baseline mùa vụ vừa có sự kiện khuyến mãi. Trên thực tế, bảng đầy đủ có tới 11 cột dummy (D2 đến D12); phần mềm thống kê (hàm C(month) trong Python, hoặc LINEST trong Excel) tự động tạo các cột này, người dùng không cần gõ tay.

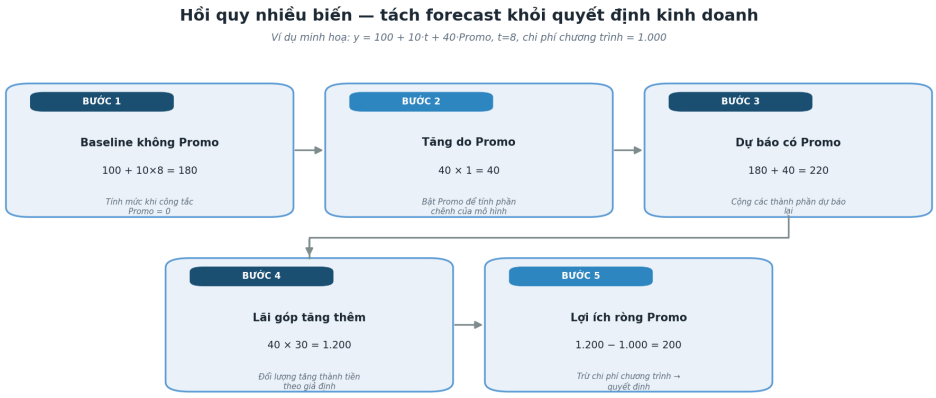
5.3 Mô hình áp dụng cho Nồi cơm điện 1.8L

$$Y_t = b_0 + b_1 \cdot t + \sum_i b_i D_i + b_{\text{promo}} \cdot \text{Promo}_t + \varepsilon_t$$

Biến t là biến xu hướng (thứ tự thời gian), 11 biến Di là biến giả tháng, và biến Promo nhận giá trị 1 tại các tháng có chương trình khuyến mãi đã biết trước (do doanh nghiệp tự lên kế hoạch).

Biến	Hệ số	P-value	Diễn giải
Intercept	786.53	<0.001	Mức nền tháng 1 (baseline)
t (xu hướng)	9.40	<0.001	Mỗi tháng tăng thêm ~9.4 chiếc so với xu hướng nền
Promo	327.65	<0.001	Khuyến mãi làm tăng trung bình 327.6 chiếc

Sơ đồ dưới đây minh hoạ lại trình tự các bước xây dựng và ước lượng một mô hình hồi quy nhiều biến (Trend + Dummy mùa vụ + Promo), trên một bộ số liệu ví dụ đơn giản hoá (khác với các hệ số thực tế của Nồi cơm điện ở trên), dùng để ôn nhanh quy trình:



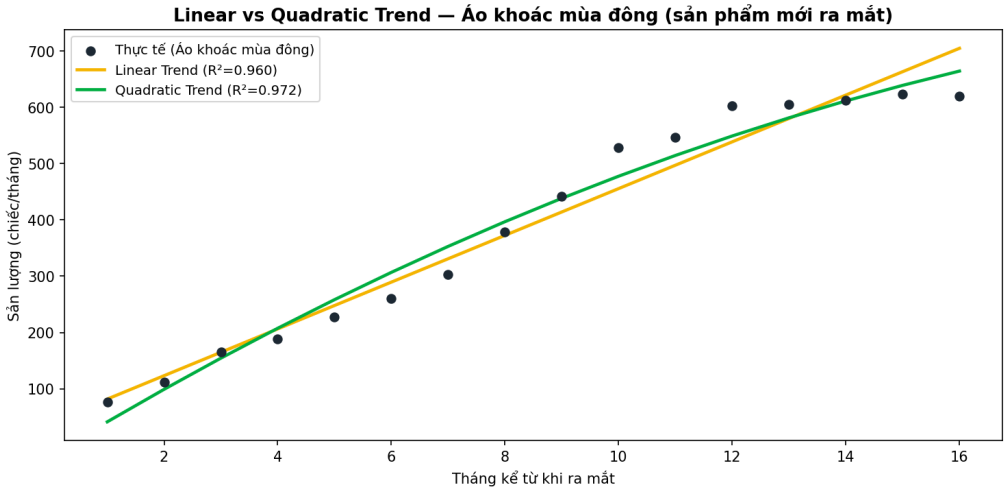
5.4 Quadratic Trend: khi xu hướng thẳng chưa đủ

Mô hình Regression vừa trình bày giả định xu hướng nền là một ĐƯỜNG THẲNG — hệ số b_1 (tốc độ tăng mỗi tháng) không đổi suốt chuỗi thời gian. Giả định này hợp lý với sản phẩm đã trưởng thành như Nồi cơm điện, nhưng với sản phẩm MỚI RA MẮT, tốc độ tăng trưởng thường KHÔNG đều — nhanh lúc đầu, chậm dần khi thị trường bắt đầu bão hoà, tạo thành đường cong thay vì đường thẳng.

Giải pháp là mở rộng trực tiếp mô hình đã học bằng cách thêm biến t^2:

$$\hat{Y}_t = b_0 + b_1 t + b_2 t^2$$

Đây KHÔNG phải kỹ thuật hoàn toàn mới — vẫn là hồi quy tuyến tính OLS đã học, chỉ thêm một cột dữ liệu (t^2) vào bảng biến giải thích, tương tự cách thêm biến giả tháng hay Promo. Hệ số b_2 mang ý nghĩa chẩn đoán quan trọng: b_2 ÂM cho thấy tốc độ tăng trưởng đang CHẬM DẦN (chững lại, tiến gần bão hoà); b_2 DƯƠNG cho thấy tốc độ tăng trưởng đang NHANH DẦN (tăng tốc) — liên hệ trực tiếp với khái niệm xu hướng NHÂN đã học ở Chương 1, dù cách tiếp cận toán học khác nhau (đa thức bậc hai so với hàm mũ).



Kết quả thật

Trên Áo khoác mùa đông (16 tháng có doanh số kể từ khi ra mắt), Linear Trend cho $R^2 = 0{,}960$; thêm t^2 nâng R^2 lên 0,972, giảm MSE từ 1.527,7 xuống 1.050,8 — cải thiện 31,2%. Hệ số $b_2 = -1{,}156$ (ÂM) xác nhận đúng trực giác kinh doanh: tốc độ tăng trưởng đang CHỮNG LẠI khi sản phẩm tiến gần mức bão hoà thị trường — nhìn biểu đồ, đường Quadratic uốn cong bám sát các điểm cuối kỳ (tháng 12–16) mà đường Linear đi vọt lên cao hơn thực tế.

Lưu ý thực hành

MAPE của Quadratic (10,29%) trên thực tế CAO HƠN Linear (7,73%) dù MSE thấp hơn — vì MAPE nhạy với sai số phần trăm tại các giá trị NHỎ ở đầu chuỗi, trong khi MSE bị chi phối bởi sai số tuyệt đối tại các giá trị LỚN cuối chuỗi. Đây là minh chứng thêm cho nguyên tắc Chương 2: luôn chọn chỉ số đánh giá phù hợp với mục tiêu thực tế, không có chỉ số nào "vạn năng"cho mọi tình huống. Cẩn thận không lạm dụng bậc cao hơn (bậc 3, bậc 4) chỉ để tăng R^2 — đây chính là quá khớp đã học ở Chương 7.

5.5 Đánh giá mô hình: R-squared và F-test

Hệ số xác định R-squared đo tỷ lệ phương sai của biến phụ thuộc được giải thích bởi mô hình:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{total}}}$$

R^2 nhận giá trị từ 0 đến 1, càng gần 1 cho thấy mô hình giải thích được càng nhiều biến động của dữ liệu. Trên mô hình đầy đủ áp dụng cho Nồi cơm điện, R^2 đạt 0.988 và F p-value nhỏ hơn 0.001, cho thấy mô hình có ý nghĩa thống kê rất mạnh.

Tuy nhiên, R^2 đơn thuần có một nhược điểm quan trọng: giá trị này KHÔNG BAO GIỜ giảm khi thêm biến mới vào mô hình, dù biến đó có ý nghĩa thực chất hay không — vấn đề này được giải quyết bằng Adjusted R-squared, trình bày chi tiết ở Chương 7.

5.6 Hồi quy đa biến với yếu tố ngoại sinh LIÊN TỤC: vượt ra ngoài biến giả nhị phân

Mô hình Nồi cơm điện 1.8L vừa học chỉ dùng hai loại biến giải thích: biến giả mùa vụ (D2–D12, mỗi biến chỉ nhận 0 hoặc 1) và biến giả Promo (cũng 0/1). Đây là dạng đơn giản nhất của "biến giải thích bên ngoài": một sự kiện CÓ xảy ra hay KHÔNG. Trong thực tế, nhiều yếu tố ảnh hưởng đến nhu cầu lại biến thiên LIÊN TỤC theo độ lớn — chỉ số niềm tin tiêu dùng, giá nguyên liệu đầu vào, chỉ số kinh tế vĩ mô, mức chi tiêu quảng cáo, v.v. — và không thể mã hoá bằng một biến 0/1 mà không mất thông tin về ĐỘ LỚN của tác động.

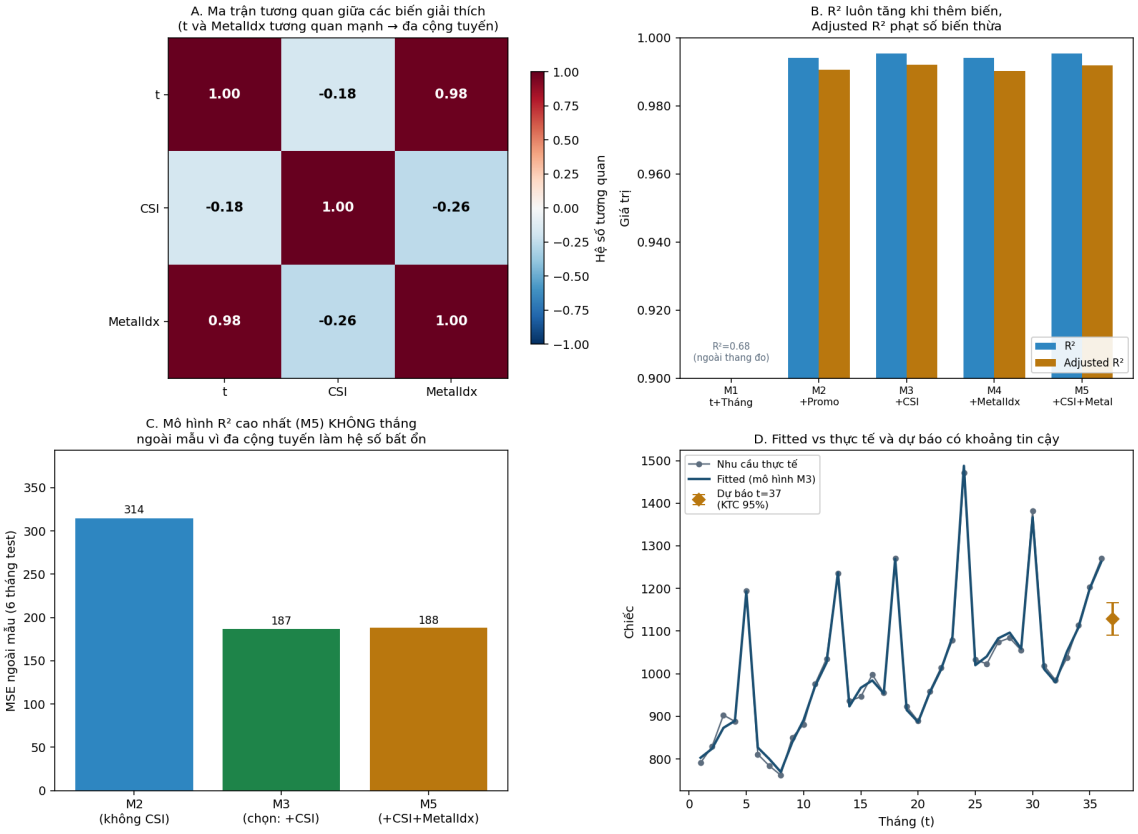
Một khuôn mẫu phổ biến trong thực tế: dự báo có yếu tố kinh tế vĩ mô

Một cách làm phổ biến khi dự báo một chỉ số kinh doanh (doanh số, giá cổ phiếu, chỉ số ngành...) là hồi quy nó theo NHIỀU chỉ số kinh tế liên tục cùng lúc — ví dụ một nghiên cứu dự báo chỉ số FTSE 100 (Anh) dùng đồng thời bốn chỉ số: tiền lương khu vực tư nhân, chỉ số bán lẻ hàng gia dụng, sản lượng khai thác dầu khí và doanh thu ngành sản xuất. Quy trình gồm bốn bước: (1) ước lượng nhiều mô hình ứng viên với các tổ hợp biến khác nhau; (2) kiểm tra ma trận tương quan giữa các biến giải thích để phát hiện đa cộng tuyến (hai biến giải thích tương quan quá cao khiến hệ số ước lượng bất ổn); (3) loại bớt biến gây đa cộng tuyến mạnh nhất, giữ mô hình gọn hơn; (4) chọn mô hình cuối cùng theo hiệu suất NGOÀI MẪU (train/test), không chỉ theo R^2 trong mẫu. Phần dưới đây áp dụng đúng quy trình bốn bước này cho Nồi cơm điện 1.8L.

5.6.1 Mở rộng mô hình Nồi cơm điện với hai yếu tố ngoại sinh liên tục

Giữ nguyên cấu trúc đã học (t, D2–D12, Promo), ta bổ sung hai biến liên tục:

- **CSI** — chỉ số niềm tin tiêu dùng nhóm hàng gia dụng (100 = mức trung bình dài hạn), phản ánh tâm lý chi tiêu của người mua, dao động không có xu hướng rõ theo thời gian.
- **MetalIdx** — chỉ số giá thép tấm/inox đầu vào (100 = tháng đầu chuỗi), phản ánh chi phí nguyên liệu mà Mua hàng và Sản xuất theo dõi, nhưng có XU HƯỚNG TĂNG khá đều theo thời gian.



Bước 1 — Ước lượng nhiều mô hình ứng viên. Trên 36 tháng dữ liệu mô phỏng, so sánh R^2 và Adjusted R^2:

Mô hình	Số biến (k)	R^2	Adjusted R^2
M1: t + Tháng	12	0,684	0,519
M2: t + Tháng + Promo	13	0,994	0,991
M3: M2 + CSI	14	0,995	**0,992**
M4: M2 + MetalIdx	14	0,994	0,990
M5: M2 + CSI + MetalIdx	15	0,995	0,992

Nhìn thoáng qua, M5 (đưa vào CẢ HAI biến liên tục) có R^2 cao nhất — đúng như tính chất R^2 không bao giờ giảm khi thêm biến đã học ở mục trước. Nhưng Adjusted R^2 của M5 (0,992) không nhỉnh hơn M3 (0,992) dù M5 dùng thêm một biến — dấu hiệu đầu tiên cho thấy MetalIdx không đóng góp thông tin thật sự mới.

Bước 2 — Kiểm tra ma trận tương quan (Panel A). Tương quan giữa `t` và `MetalIdx` là **0,977** — cực kỳ cao, vì giá thép tăng khá đều theo thời gian giống hệt biến xu hướng `t`. Đây chính là **đa cộng tuyến**: khi hai biến giải thích gần như mang cùng một thông tin, mô hình không thể tách bạch `t` và `MetalIdx` đóng góp bao nhiêu phần trăm mỗi biến, khiến hệ số ước lượng SAI SỐ CHUẨN lớn và không ổn định.

Bằng chứng trực tiếp: trong mô hình M5, hệ số của `MetalIdx` có p-value ≈ 0,49 (không có ý nghĩa thống kê ở mức 5%) dù bản thân MetalIdx có vẻ "hợp lý" về mặt kinh doanh — ngược lại, hệ số của `CSI` trong M3 có p-value ≈ 0,03, có ý nghĩa thống kê rõ ràng.

Bước 3 — Loại biến gây đa cộng tuyến, giữ mô hình gọn hơn. Vì `MetalIdx` gần như trùng lặp thông tin với `t` mà không thêm ý nghĩa thống kê, ta LOẠI `MetalIdx` khỏi mô hình cuối cùng và giữ lại `CSI` — chọn mô hình **M3** thay vì mô hình có R^2 cao nhất (M5).

Bước 4 — Kiểm định ngoài mẫu (Panel C). Chia 36 tháng thành 30 tháng train và 6 tháng test, tính MSE dự báo ngoài mẫu:

Mô hình	MSE ngoài mẫu (6 tháng test)
M2 (không có biến liên tục nào)	314
M3 (chỉ thêm CSI)	**187**
M5 (thêm cả CSI và MetalIdx)	188

Kết quả xác nhận lựa chọn ở Bước 3: M3 (14 biến, đã loại MetalIdx) có MSE ngoài mẫu THẤP HƠN M5 (15 biến, giữ cả hai) dù M5 có R^2 trong mẫu cao hơn — đúng chủ đề đã cảnh báo ở mục Adjusted R^2: **số liệu "đẹp hơn" trong mẫu không đảm bảo dự báo tốt hơn ngoài mẫu**, đặc biệt khi biến thêm vào bị đa cộng tuyến.

Hệ số mô hình M3 (đã chọn)	Giá trị
Intercept	574,8
t	7,98
Promo	336,6
CSI	1,03 (p ≈ 0,03)

Panel D minh hoạ dự báo tháng 37 (ngoài mẫu huấn luyện) bằng mô hình M3, kèm khoảng tin cậy 95%: điểm dự báo khoảng 1.128 chiếc, khoảng tin cậy [1.090; 1.167] chiếc — độ rộng khoảng tin cậy phản ánh cả sai số mô hình lẫn bất định của chính biến CSI trong tương lai.

Vì sao bước "kiểm tra ngoài mẫu" không thể bỏ qua

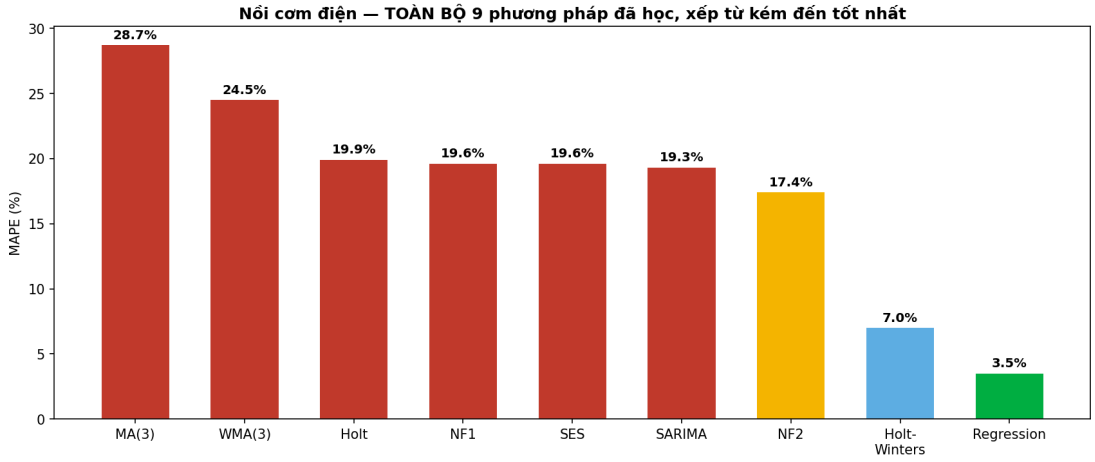
Nếu chỉ nhìn R^2/Adjusted R^2 trong mẫu, người phân tích dễ chọn nhầm mô hình M5 vì con số "đẹp" hơn một chút. Chỉ khi kiểm tra trên dữ liệu CHƯA DÙNG để ước lượng (train/test), đa cộng tuyến giữa `t` và `MetalIdx` mới lộ ra rõ ràng qua việc mô hình gọn hơn (M3) dự báo tốt hơn. Đây là lý do Chương 7 sẽ trình bày quy trình train/validation/test đầy đủ, không chỉ áp dụng riêng cho hồi quy.

So với biến giả nhị phân: khi nào cần thêm biến liên tục?

Biến giả nhị phân (Promo, mùa vụ, sự kiện) phù hợp khi tác động có tính chất "bật/tắt" và doanh nghiệp BIẾT TRƯỚC lịch xảy ra (đã học ở Case Study Walmart cuối chương).

Biến liên tục (như CSI) phù hợp khi tác động biến thiên theo ĐỘ LỚN và có ý nghĩa kinh doanh rõ ràng — nhưng đi kèm chi phí: (1) phải kiểm tra đa cộng tuyến kỹ hơn vì càng nhiều biến liên tục, khả năng hai biến "trùng thông tin" càng cao; (2) như mục sau sẽ nêu, biến liên tục ngoại sinh (không thuộc tầm kiểm soát doanh nghiệp) đòi hỏi một mô hình dự báo RIÊNG cho chính biến đó — CSI trong ví dụ trên được giả định ổn định để đơn giản hoá, nhưng trong triển khai thực tế cần được dự báo bằng chuỗi thời gian riêng trước khi đưa vào mô hình chính.

5.7 Giới hạn của phương pháp hồi quy trong dự báo



Tổng hợp toàn bộ chín phương pháp đã học đến Chương 5 trên cùng một SKU, Regression đạt MAPE thấp nhất (3,5%) trong toàn giáo trình — nhưng lợi thế này đi kèm điều kiện quan trọng trình bày ngay sau đây.

Khác với các phương pháp ở Chương 3 và 4 (chỉ cần dữ liệu lịch sử của chính biến cần dự báo), phương pháp hồi quy đòi hỏi phải biết trước giá trị TƯƠNG LAI của các biến giải thích để tạo dự báo. Với biến mang tính kế hoạch nội bộ (như Promo, giá bán), doanh nghiệp có thể biết trước với độ tin cậy cao. Với biến ngoại sinh khó kiểm soát (giá đối thủ, thời tiết, chỉ số kinh tế vĩ mô), cần một mô hình dự báo RIÊNG cho chính biến giải thích đó trước, khiến sai số cộng dồn qua hai lớp mô hình.

5.7.1 Có biến giải thích chưa đủ: ví dụ mở rộng điểm bán

Ngay cả khi biến giải thích thuộc tầm kiểm soát của doanh nghiệp, việc NGOẠI SUY giá trị tương lai của nó vẫn có thể sai nếu áp dụng máy móc. Xét tình huống: hiện có 1.000 điểm bán (POS), tốc độ bán trung bình 10 chiếc/POS/tuần, tức 10.000 chiếc/tuần. Sales dự kiến mở rộng lên 1.300 điểm bán.

Cách ngoại suy ngây thơ, phổ biến trong thực tế: $1.300 \times 10 = 13.000$ chiếc/tuần — tăng 30%. Phép tính này giả định MỌI POS mới đều bán tốt như POS cũ — giả định thường sai, vì các điểm bán mới thường được mở SAU, ở vị trí hoặc phân khúc kém hấp dẫn hơn những điểm đã mở trước.

Nếu velocity thực tế của POS mới giảm còn 8,8 chiếc/POS/tuần: $1.300 \times 8{,}8 = 11.440$ chiếc/tuần — chỉ tăng 14,4%, không phải 30%.

Bài học cho biến giải thích trong Regression

Có biến giải thích là ĐIỀU KIỆN CẦN, không phải điều kiện đủ. Luôn kiểm tra xem hệ số ước lượng (ở đây là doanh số/POS) có còn ĐÚNG khi quy mô biến giải thích thay đổi đáng kể, thay vì ngoại suy tuyến tính máy móc — đặc biệt khi biến giải thích tăng nhanh và vượt xa phạm vi dữ liệu lịch sử đã dùng để ước lượng mô hình.

Kết luận chương

hồi quy phát huy hiệu quả cao nhất khi biến giải thích nằm trong tầm kiểm soát hoặc có thể biết trước với độ tin cậy cao — đây là điều kiện tiên quyết cần đánh giá trước khi lựa chọn phương pháp này.

5.8 Case Study Thực Tế: Vì sao Walmart luôn chất đầy Pop-Tarts vị dâu trước mỗi cơn bão?

Ngành: Bán lẻ / Hàng tiêu dùng (Retail / FMCG)

Trước khi cơn bão Frances đổ bộ Florida năm 2004, đội ngũ phân tích của Walmart đã khai thác dữ liệu bán hàng lịch sử tại các khu vực từng hứng bão trước đó (như bão Charley) để tìm sản phẩm nào tăng đột biến trước bão. Ngoài các mặt hàng "hiển nhiên" như đèn pin, pin, kết quả gây bất ngờ: doanh số bánh Pop-Tarts vị dâu tăng khoảng gấp 7 lần mức bình thường, và bia cũng tăng mạnh dù ít ai đoán trước được điều này. Walmart sau đó chủ động chất các mặt hàng này lên kệ đầu cửa hàng NGAY khi có dự báo bão — sự việc được *The New York Times* ghi lại năm 2004 và trở thành ví dụ kinh điển trong ngành phân tích bán lẻ.

Bài học liên hệ chương này: đây là ứng dụng thực tế của Biến giả (Dummy Variable) vừa học — "có bão hay không" là một biến nhị phân (0/1) được đưa thẳng vào mô hình hồi quy cùng các biến xu hướng/mùa vụ khác, giúp định lượng CHÍNH XÁC mức tăng doanh số gắn với một sự kiện cụ thể, thay vì chỉ dựa vào cảm tính "chắc là sẽ bán chạy hơn".

Nguồn: Constance L. Hays, "What Wal-Mart Knows About Customers' Habits", The New York Times, 14/11/2004.

CHƯƠNG 6

Từ Forecast Đến Quyết Định Vận Hành

TỆP ĐÍNH KÈM — Chương 6

Python: `Buoi6/Buoi6_01_BieuDo.py`, `Buoi6/Buoi6_02_ExcelWorkbook_SafetyStock.py`, `Buoi6/Buoi6_03_BieuDo_IBP_CaseThat.py` (case dữ liệu thật, xem thư mục `data_that_an_danh/`). **Excel:** `Buoi6_SafetyStock_TrackingSignal.xlsx` — sheet `Safety_Stock`, `Chi_Phi`, `Tracking_Signal`. **Slide:** `Buoi6_TuForecastDenQuyetDinh.pptx`.

Chương này trình bày cách chuyển hoá một dự báo thống kê thành các quyết định vận hành cụ thể: tồn kho an toàn, chi phí, và cơ chế giám sát mô hình theo thời gian.

Một dự báo "tốt"cần cả hai con số, không chỉ một

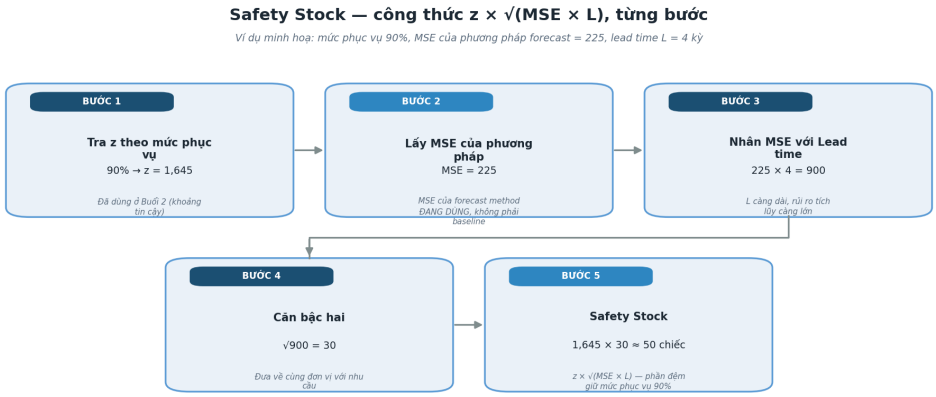
Mọi mô hình dự báo đã học (Chương 3–5) đều nên tạo ra HAI con số, không phải một: μ — điểm dự báo (point forecast), trả lời câu hỏi "trung bình cần bao nhiêu hàng?"; và σ — sai số dự báo (thường lấy từ RMSE/MSE của mô hình, đã học Chương 2), trả lời câu hỏi "dự báo có thể sai lệch bao nhiêu?". Đây là điểm nhiều người mới học hay bỏ sót: chỉ báo cáo μ mà không kèm σ khiến Supply Planning không có cơ sở chuẩn bị nguồn lực cho rủi ro sai lệch — và σ chính là đầu vào trực tiếp cho công thức Safety Stock ngay sau đây.

6.1 Tồn kho an toàn (Safety Stock)

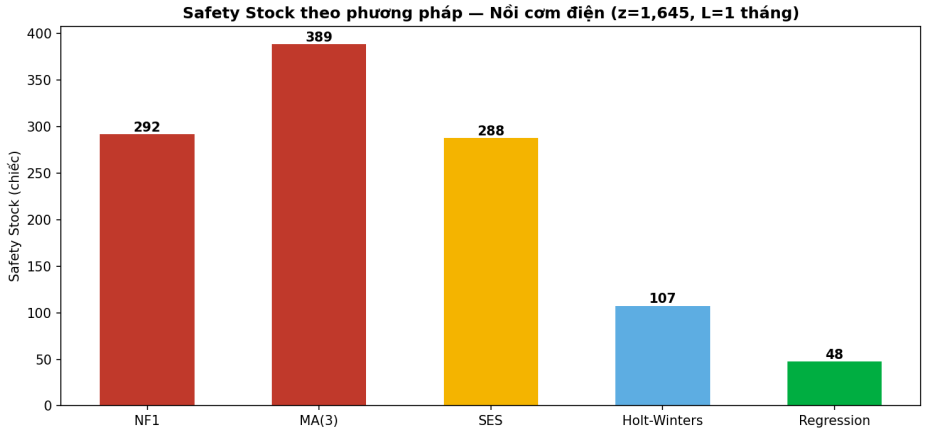
$$\text{Safety Stock} = z \cdot \sqrt{\text{MSE} \cdot L}$$

Công thức trên là hệ quả trực tiếp của khoảng tin cậy dự báo trình bày ở Chương 2, áp dụng cho khoảng thời gian chờ hàng về (lead time, ký hiệu L). Ba thành phần: z là phân vị chuẩn tương ứng mức phục vụ mong muốn; MSE là sai số bình phương trung bình của phương pháp dự báo đang sử dụng — phương pháp càng chính xác, MSE càng nhỏ, Safety Stock cần thiết càng ít; L là số kỳ chờ hàng, phản ánh việc rủi ro tích luỹ theo thời gian chờ.

Sơ đồ dưới đây tóm tắt trình tự các bước tính Safety Stock trên một ví dụ minh hoạ:



Phương pháp (Nồi cơm điện)	MSE	Safety Stock (z=1.645, L=1)
NF1	31486.0	292 chiếc
NF2	23126.2	250 chiếc
Holt-Winters	4266.2	107 chiếc
Regression	834.4	48 chiếc



Ý nghĩa thực tiễn

chênh lệch giữa phương pháp kém chính xác nhất (NF1, 292 chiếc) và chính xác nhất (Regression, 48 chiếc) lên tới gần 6 lần — minh chứng bằng số học cho giá trị tài chính trực tiếp của việc lựa chọn đúng phương pháp dự báo.

6.1.1 Bảng tính tay: Safety Stock theo mức phục vụ mong muốn

Mức phục vụ	z	$SS = z\sqrt{\text{MSE} \times L}$, với MSE=4266, L=1	SS (chiếc)
80%	1,282	$1{,}282 \times \sqrt{4266 \times 1}$	83,7
90%	1,645	$1{,}645 \times \sqrt{4266 \times 1}$	107,4
95%	1,960	$1{,}960 \times \sqrt{4266 \times 1}$	128,0
99%	2,576	$2{,}576 \times \sqrt{4266 \times 1}$	168,3

Cùng một phương pháp dự báo (Holt-Winters, MSE cố định) nhưng Safety Stock tăng dần theo mức phục vụ mong muốn — tăng từ 95% lên 99% đòi hỏi thêm khoảng 40 chiếc tồn kho an toàn, minh hoạ sự đánh đổi giữa mức độ an toàn và chi phí vốn lưu động mà doanh nghiệp cần cân nhắc khi đặt chính sách tồn kho.

6.1.2 Điểm đặt hàng lại (Reorder Point)

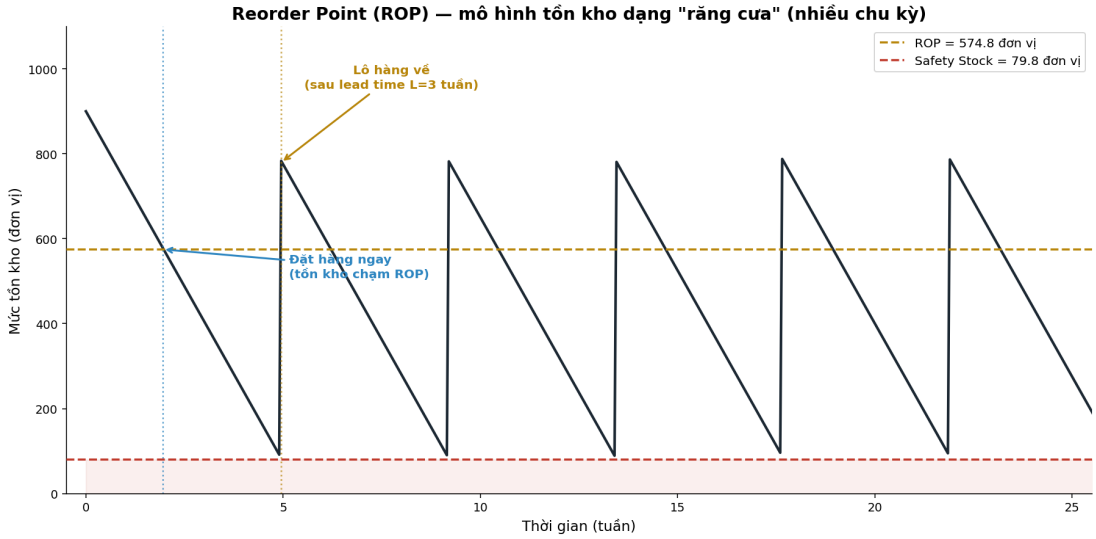
Safety Stock trả lời câu hỏi "cần giữ THÊM bao nhiêu để phòng rủi ro", nhưng câu hỏi vận hành thực tế là "KHI NÀO cần đặt hàng tiếp theo". Điểm đặt hàng lại (Reorder Point, viết tắt ROP) trả lời câu hỏi đó bằng cách cộng thêm nhu cầu DỰ KIẾN tiêu thụ trong suốt thời gian chờ hàng về:

$$\text{ROP} = \bar{d} \times L + \text{Safety Stock}$$

trong đó $\bar{d}$ là nhu cầu trung bình mỗi kỳ (ví dụ mỗi tuần), L là lead time — cùng đơn vị thời gian với $\bar{d}$. Số hạng đầu ($\bar{d} \times L$) là lượng hàng dự kiến TIÊU THỤ trong lúc chờ đơn hàng mới về; Safety Stock là phần đệm thêm để phòng trường hợp nhu cầu thực tế cao hơn dự kiến hoặc lead time kéo dài hơn dự kiến.

Ví dụ minh hoạ

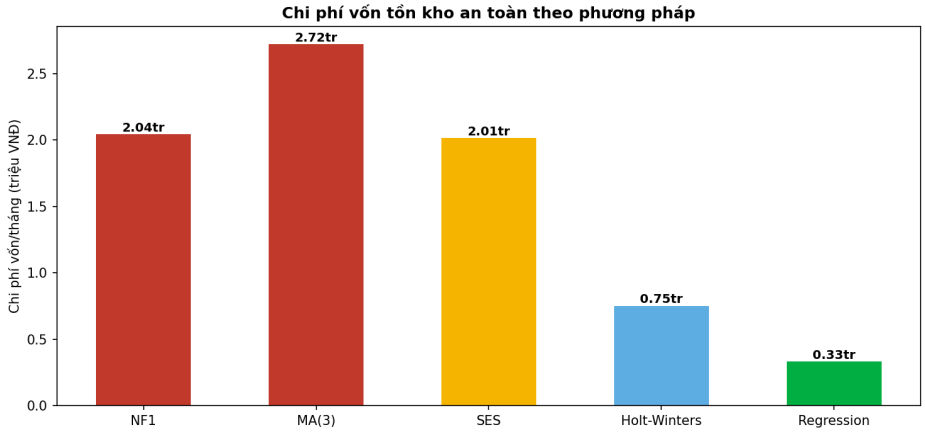
Với nhu cầu trung bình $\bar{d} = 165$ đơn vị/tuần, độ lệch chuẩn sai số dự báo $\sigma = 28$, lead time $L = 3$ tuần, mức phục vụ 95% ($z = 1{,}645$): Safety Stock $= 1{,}645 \times 28 \times \sqrt{3} \approx 79{,}8$ đơn vị. ROP $= 165 \times 3 + 79{,}8 = 574{,}8$ đơn vị — khi tồn kho giảm xuống mức này, cần đặt hàng ngay để tránh hết hàng trước khi lô hàng mới về.



Hình dạng "răng cưa"là mô hình tồn kho kinh điển: tồn kho GIẢM ĐỀU theo nhu cầu tiêu thụ $\bar{d}$ mỗi kỳ, khi chạm ROP thì đặt hàng ngay, và sau đúng lead time L, lô hàng về làm tồn kho NHẢY VỌT trở lại mức cao. Vùng tô đỏ phía dưới (Safety Stock) là "lớp đệm"không bao giờ nên chạm tới trong điều kiện vận hành bình thường — nếu đường răng cưa liên tục cắt xuống vùng này, đó là tín hiệu Safety Stock đang đặt quá thấp so với thực tế biến động.

6.2 Quy đổi chi phí vốn tồn kho

$$\text{Chi phí vốn/tháng} = \text{Safety Stock} \times \text{Giá vốn/đơn vị} \times \text{Tỷ lệ chi phí giữ hàng}$$



Bước quy đổi này chuyển một chỉ số thống kê (Safety Stock, đơn vị "chiếc") thành ngôn ngữ mà ban lãnh đạo thực sự quan tâm: số tiền cụ thể mỗi tháng. Với danh mục hàng trăm SKU, chênh lệch nhỏ ở mỗi SKU nhân lên thành hàng trăm triệu đồng vốn lưu động.

Tỷ lệ chi phí giữ hàng (holding cost rate) bao gồm chi phí cơ hội của vốn bị đọng trong tồn kho, chi phí kho bãi, chi phí bảo quản và rủi ro lỗi thời, thường dao động 1.5% đến 3% mỗi tháng tuỳ ngành hàng.

6.3 Vòng quay tồn kho: thước đo hiệu quả sau Safety Stock

Safety Stock và ROP (mục trước) trả lời câu hỏi "cần giữ bao nhiêu, khi nào đặt lại". **Vòng quay tồn kho** (Inventory Turnover) trả lời câu hỏi ngược lại, từ góc nhìn Tài chính: những chính sách tồn kho đó đang sử dụng vốn lưu động HIỆU QUẢ đến đâu?

$$\text{Vòng quay tồn kho} = \frac{\text{Giá vốn hàng bán (COGS) trong kỳ}}{\text{Tồn kho bình quân}}$$

Kết quả thật (Nồi cơm điện, phương pháp Holt-Winters)

Với 12 tháng gần nhất: COGS $\approx$ 3,33 tỷ đồng (9.521 chiếc $\times$ 350.000đ/chiếc). Tồn kho bình quân ước tính (Safety Stock 107 chiếc + một nửa lô đặt hàng trung bình mỗi tháng) $\approx$ 504 chiếc $\approx$ 176,5 triệu đồng. Vòng quay tồn kho = 3,33 tỷ $\div$ 176,5 triệu $\approx$ **18,9 lần/năm** — tức trung bình cứ khoảng 19 ngày, toàn bộ lô hàng tồn kho được bán hết và nhập lại một vòng mới.

Mối liên hệ trực tiếp với Safety Stock: nếu Safety Stock được đặt QUÁ CAO — do chọn phương pháp dự báo kém chính xác (MSE lớn, xem bảng ở mục trước) hoặc do quá thận trọng với hàng thuộc nhóm Bottleneck (mục Kraljic Matrix ngay sau đây) — vòng quay tồn kho sẽ GIẢM, đồng nghĩa vốn lưu động bị "chôn"trong kho tăng lên. Đây chính là lý do bộ phận Tài chính (FP&A) luôn tham gia bước Financial Reconciliation trong quy trình S&OP (mục sau) — để cân đối giữa mức phục vụ khách hàng mong muốn và chi phí vốn tồn kho thực tế.

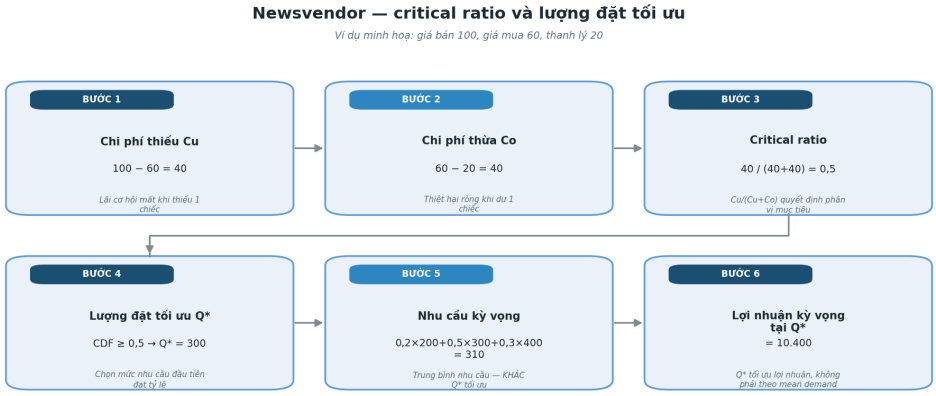
6.4 Newsvendor: quyết định lượng đặt cho SKU bán một mùa duy nhất

Safety Stock và ROP giả định SKU được đặt hàng LẶP LẠI nhiều kỳ liên tiếp. Với những mặt hàng chỉ bán một mùa duy nhất rồi hết hạn hoặc lỗi mốt (hàng thời trang theo mùa, lịch/thiệp Tết, đồ chơi theo sự kiện) — không có kỳ sau để bù cho sai số dự báo — bài toán trở thành **Newsvendor**: chọn MỘT lượng đặt hàng duy nhất Q trước khi biết nhu cầu thật.

$$\text{Critical Ratio} = \frac{C_u}{C_u + C_o}$$

trong đó C_u (underage cost) là chi phí cơ hội mất đi khi ĐẶT THIẾU một đơn vị (lỡ bán một đơn hàng), còn C_o (overage cost) là chi phí thiệt hại khi ĐẶT THỪA một đơn vị (hàng tồn phải thanh lý dưới giá vốn hoặc bỏ đi). Lượng đặt tối ưu Q^* là mức nhu cầu tại đó xác suất tích luỹ (CDF) của phân phối nhu cầu đạt đúng bằng Critical Ratio — lưu ý Q^* nói chung KHÁC với nhu cầu kỳ vọng (giá trị trung bình): khi $C_u > C_o$ (thiếu hàng tốn kém hơn thừa hàng), Critical Ratio $> 0{,}5$ và Q^* nên cao hơn mức trung bình, và ngược lại.

Sơ đồ dưới đây tóm tắt trình tự các bước tính Critical Ratio và chọn Q^* trên một ví dụ minh hoạ:



Bài toán Newsvendor và Critical Ratio là công cụ được áp dụng trực tiếp trong Case Study của Buổi 10 (bảo vệ và tổng kết cuối khoá) để quyết định lượng đặt hàng cho SKU mùa vụ.

6.5 Tracking Signal — giám sát mô hình theo thời gian

$$TS_t = \frac{\sum_{i=1}^{t} e_i}{MAD_t}$$

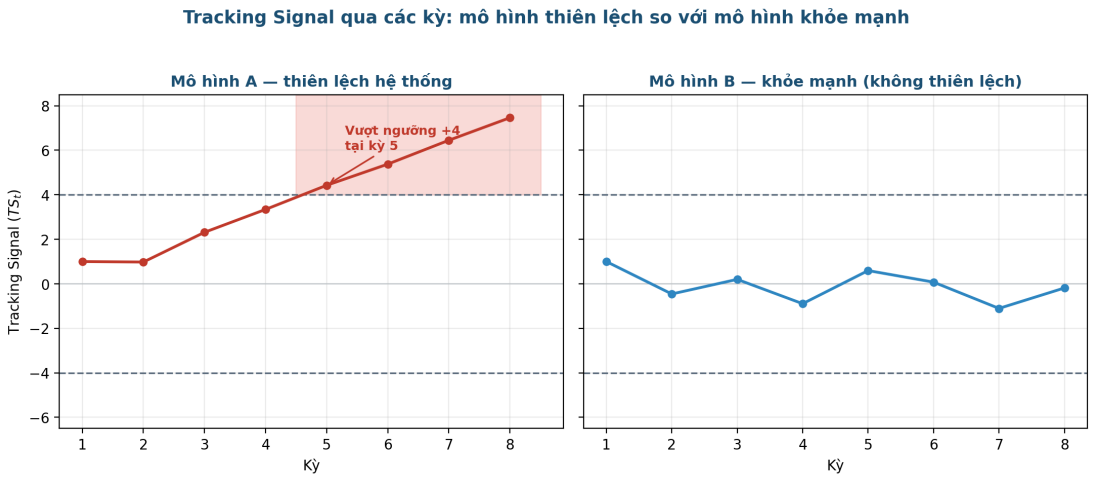
trong đó tử số là tổng sai số CÓ DẤU lũy kế từ kỳ đầu tiên đến kỳ t, và MADt là trị tuyệt đối sai số trung bình lũy kế tính đến kỳ t. Nếu mô hình dự báo không thiên lệch, các sai số dương và âm sẽ triệt tiêu lẫn nhau, khiến Tracking Signal dao động quanh 0. Khi TS liên tục lệch về một phía và vượt ngưỡng quy ước ±4, đây là tín hiệu cho thấy mô hình đang thiên lệch hệ thống (liên tục dự báo thấp hoặc liên tục dự báo cao so với thực tế), cần xây dựng lại toàn bộ quy trình dự báo.

6.5.1 Bảng tính tay: Tracking Signal khi mô hình thiên lệch hệ thống

Lưu ý quan trọng trước khi đọc bảng: nếu TẤT CẢ sai số của một mô hình đều cùng dấu (luôn dương hoặc luôn âm), thì về mặt toán học TS_t sẽ LUÔN bằng đúng t (kỳ thứ mấy thì TS bằng đúng số đó), vì khi đó tổng có dấu và tổng trị tuyệt đối bằng nhau. Đây không phải là điều thường gặp trong thực tế — một mô hình thiên lệch thật vẫn có những kỳ sai số ngược dấu xen kẽ (nhiễu ngẫu nhiên chồng lên xu hướng thiên lệch), chỉ là NHIỀU kỳ dương hơn âm (hoặc ngược lại) một cách có hệ thống. Bảng dưới đây dùng dữ liệu có nhiễu thật để thể hiện đúng dáng đi "gập ghềnh nhưng đi lên"của TS_t trong thực tế, thay vì một đường thẳng tăng đều giả tạo.

Kỳ	e_t	$\sum e_i$ (lũy kế)	MAD_t	$TS_t = \sum e_i / MAD_t$
1	+35	+35	35,00	35/35,00 = 1,00
2	−12	+23	23,50	23/23,50 = 0,98
3	+58	+81	35,00	81/35,00 = 2,31
4	+41	+122	36,50	122/36,50 = 3,34
5	+63	+185	41,80	185/41,80 = **4,43**
6	+22	+207	38,50	207/38,50 = 5,38
7	+74	+281	43,57	281/43,57 = 6,45
8	+51	+332	44,50	332/44,50 = 7,46

Đọc bảng: kỳ 2 có sai số ÂM xen kẽ (−12) như một mô hình thật sự sẽ có, nhưng vì 7/8 kỳ còn lại đều dương và có biên độ lớn dần, TS_t vẫn kiên trì đi lên và cắt ngưỡng cảnh báo +4 ngay tại kỳ 5 — đây chính là tín hiệu thiên lệch hệ thống mà Demand Planner cần hành động (xem lại giả định mô hình, kiểm tra có sự kiện thị trường mới nào chưa được đưa vào dự báo hay không).



Biểu đồ trên đặt cạnh nhau hai tình huống để học viên phân biệt: bên trái là **Mô hình A** (bảng vừa tính) — TS_t có dao động nhỏ ở kỳ đầu nhưng sau đó đi lên bền bỉ, vượt hẳn ngưỡng +4 và không quay trở lại; bên phải là **Mô hình B** — một mô hình khỏe mạnh với sai số dao động ngẫu nhiên thật sự quanh 0 (không thiên lệch), nên TS_t chỉ dập dềnh nhẹ trong khoảng −1,1 đến +1,0, không bao giờ tiệm cận ngưỡng cảnh báo. Đây là hai hình dạng mà một Demand Planner cần nhận ra ngay khi nhìn biểu đồ theo dõi hằng tháng — KHÔNG phải bằng cách nhớ công thức, mà bằng cách nhớ HÌNH DẠNG: đi lên (hoặc xuống) bền bỉ và không quay đầu = thiên lệch cần xử lý; dao động lộn xộn quanh 0 = mô hình vẫn khỏe mạnh, không cần can thiệp.

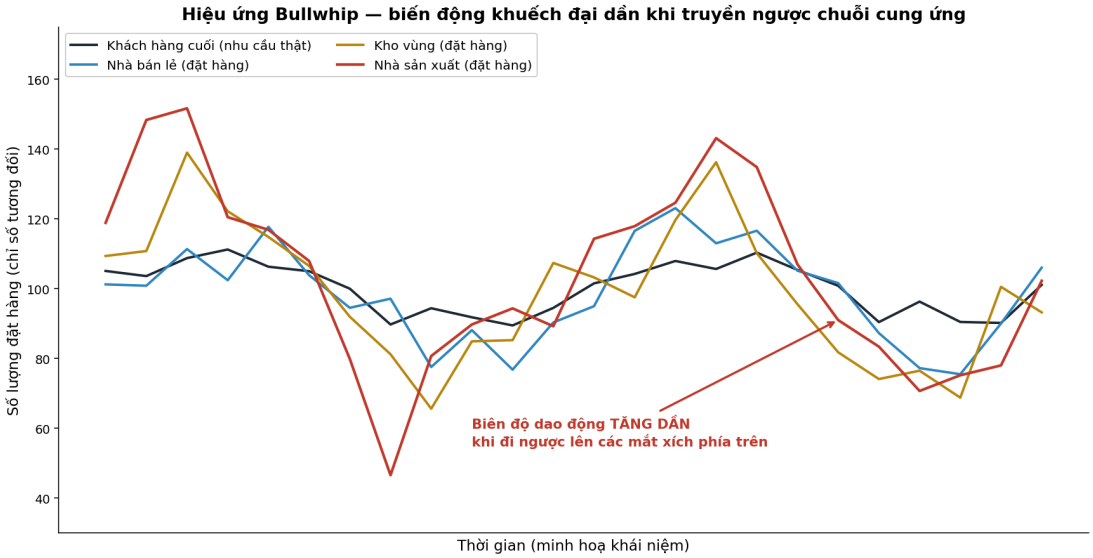
Lưu ý thực hành

Tracking Signal chỉ đáng tin cậy sau khi đã tích luỹ đủ số kỳ quan sát (khuyến nghị tối thiểu 6-8 kỳ), vì MAD lũy kế còn nhỏ ở các kỳ đầu khiến tỷ số dễ dao động mạnh một cách giả tạo (xem kỳ 1–2 trong bảng trên: TS đã gần bằng 1 dù dữ liệu còn rất ít, chưa đủ cơ sở để kết luận thiên lệch). Trong thực hành, nên kết hợp Tracking Signal với biểu

đồ sai số theo thời gian (không chỉ nhìn con số cuối cùng) và đặt ngưỡng hành động rõ ràng: ví dụ "nếu $|TS_t| > 4$ trong 2 kỳ liên tiếp, tổ chức họp rà soát lại mô hình"thay vì phản ứng ngay ở lần vượt ngưỡng đầu tiên (có thể chỉ là nhiễu tạm thời).

6.6 Hiệu ứng Bullwhip trong chuỗi cung ứng

Hiệu ứng Bullwhip mô tả hiện tượng biến động nhu cầu bị khuếch đại dần khi truyền ngược từ khách hàng cuối cùng lên các mắt xích phía trên trong chuỗi cung ứng (nhà bán lẻ, kho vùng, nhà sản xuất). Ba nguyên nhân chính: (1) mỗi mắt xích tự làm tròn hoặc dự phòng thêm khi đặt hàng lên mắt xích tiếp theo; (2) tập quán đặt hàng theo lô lớn (batch ordering) thay vì liên tục; (3) mỗi mắt xích sử dụng phương pháp dự báo khác nhau, dẫn tới sai số không đồng nhất và cộng dồn qua các tầng.



Hình trên minh hoạ khái niệm (không phải số liệu SKU cụ thể của khóa học): cùng một biến động nhu cầu gốc từ khách hàng cuối, nhưng biên độ dao động của đơn đặt hàng lan truyền ngược lên các mắt xích phía trên NGÀY CÀNG LỚN — nhà sản xuất (đường đỏ) phải đối mặt với biến động mạnh hơn nhiều lần so với nhu cầu thật ban đầu, dù bản thân khách hàng cuối không hề thay đổi hành vi mua sắm đột biến như vậy.

6.7 Kiến trúc ERP/APS: forecast nằm ở đâu trong hệ thống doanh nghiệp?

ERP (Enterprise Resource Planning — ví dụ SAP S/4HANA, Oracle) quản lý dữ liệu GIAO DỊCH: đơn hàng, tồn kho, sản xuất, tài chính — nhưng bản thân ERP thường KHÔNG có engine dự báo thống kê đủ mạnh để chạy các mô hình đã học xuyên suốt khóa (Chương 3–5). APS (Advanced Planning & Scheduling) là lớp thông minh nằm cạnh/trên ERP, chuyên trách dự báo và tối ưu hoá kế hoạch. Ba nền tảng phổ biến trên thị trường:

- **SAP Integrated Business Planning (IBP):** tích hợp chặt với hệ sinh thái SAP, dùng các thuật toán thống kê (bao gồm các mô hình như ARIMA, Holt-Winters, hồi quy đã học) kết hợp machine learning, hỗ trợ mô phỏng kịch bản (what-if) ngay trong quy trình S&OP.
- **Oracle Demantra:** chuyên sâu về quản trị nhu cầu (demand management), mô hình hoá theo nhiều cấp phân cấp (SKU – cửa hàng – vùng – quốc gia), cho phép phân bổ dự báo từ cấp cao xuống thấp và đối chiếu ngược lại (top-down/bottom-up reconciliation).
- **Kinaxis RapidResponse:** nổi bật ở tốc độ mô phỏng kịch bản gần thời gian thực (concurrent planning) — Demand Planner và Supply Planner cùng nhìn thấy tác động của một thay đổi dự báo lên khả năng cung ứng gần như ngay lập tức.

Luồng dữ liệu tổng quát

Dữ liệu bán hàng lịch sử (từ ERP) → nạp vào APS → APS chạy các mô hình thống kê đã học (trend regression, seasonal regression, Holt-Winters, ARIMA, kết hợp dự báo) → ra dự báo thống kê nền (statistical baseline) → Demand Planner điều chỉnh bằng thông tin định tính mà mô hình không nắm bắt được → dự báo đồng thuận (consensus forecast, xem quy trình S&OP ngay sau đây) → đẩy ngược lại ERP làm đầu vào cho MRP (Material Requirements Planning), lập kế hoạch sản xuất và mua hàng. Toàn bộ kỹ thuật ở Chương 1–5 của khóa học chính là phần "APS chạy mô hình thống kê"trong luồng này — hiểu vị trí này giúp thấy rõ vì sao thành thạo Excel/Python không đủ, mà còn cần hiểu bối cảnh hệ thống doanh nghiệp mà dự báo được vận hành trong đó.

6.8 Dự báo Xác suất (Probabilistic Forecasting): khóa học này đang ở đâu so với phần mềm hàng đầu?

Toàn bộ khóa học từ Chương 1 đến đây dạy **dự báo điểm** (point forecasting, hay deterministic forecasting): với mỗi kỳ tương lai, mô hình đưa ra MỘT con số dự báo tốt nhất (ví dụ SES, Holt-Winters, ARIMA, hồi quy), sau đó dùng độ lệch chuẩn của sai số lịch sử để tính thêm một "lớp đệm"(Safety Stock, mục trước) nhằm phòng ngừa rủi ro dự báo sai. Đây là cách tiếp cận chuẩn mực, được dạy trong hầu hết chương trình Demand Planning trên thế giới suốt nhiều thập kỷ — và cũng là nền tảng bắt buộc trước khi học bất cứ điều gì phức tạp hơn.

Nhưng thị trường phần mềm hoạch định cao cấp nhất hiện nay (2025) đang được đánh giá bằng một tiêu chuẩn khác: **Dự báo Xác suất** (Probabilistic Forecasting) — thay vì một con số duy nhất, mô hình đưa ra TOÀN BỘ phân phối xác suất của các kết quả nhu cầu có thể xảy ra (ví dụ: "15% khả năng bán 80 chiếc, 40% khả năng bán 100 chiếc, 10% khả năng bán 150 chiếc..."), rồi những phân phối này (cả nhu cầu LẪN lead time) được đưa thẳng vào một lớp tối ưu hoá để ra quyết định vận hành cụ thể (đặt bao nhiêu, phân bổ về đâu, giá bán bao nhiêu) — mà KHÔNG cần quy về một tham số "mức phục vụ mong muốn"hay "Safety Stock"do con người áp đặt.

Ba cấp độ "xác suất"theo đánh giá của Lokad (12/2025)

Bài viết “The State of ‘Probabilistic’ Forecasting in Supply Chain” (Joannès Vermorel, nhà sáng lập Lokad, đăng 05/12/2025) — một trong những bài phân tích thị trường phần mềm forecasting/APS được chia sẻ nhiều nhất năm 2025 — phân loại các nhà cung

cấp phần mềm thành ba cấp:
(1) "Genuine"(Xác suất thực thụ): mô hình hoá đầy đủ phân phối xác suất của cả nhu cầu và lead time, kết hợp nhất quán với nhau, rồi một lớp tối ưu hoá xuất thẳng ra quyết định (đơn hàng, phân bổ, giá) — KHÔNG dựa vào tham số Safety Stock/mức phục vụ do con người đặt.
(2) "Semi-genuine"(Nửa xác suất): có mô hình hoá phân phối xác suất thật sự (ví dụ ước lượng phân phối nhu cầu cho hàng rời rạc/long-tail), nhưng kết quả cuối cùng vẫn được "quy đổi ngược"về các chính sách Safety Stock / mức phục vụ (service level) quen thuộc để vận hành.
(3) "Marketing-level"(Chỉ ở mức tiếp thị): dùng từ "xác suất"/"probabilistic"trong tài liệu quảng bá, nhưng vận hành thực tế vẫn xoay quanh phân khúc mức phục vụ, Safety Stock động, và các chính sách xác định (deterministic) được tinh chỉnh bằng Machine Learning.
Tác giả đưa ra 6 tiêu chí cụ thể để phân định "genuine": (i) mô hình hoá đầy đủ phân phối của CẢ nhu cầu và lead time; (ii) đầu ra là quyết định tối ưu hoá (đơn hàng/phân bổ/giá), không phải tham số Safety Stock; (iii) không cho phép con người "sửa tay"hình dạng phân phối; (iv) xử lý đúng đuôi dài (heavy-tail) của nhu cầu rời rạc thay vì giả định phân phối chuẩn; (v) đo lường bằng các thước đo xác suất đúng chuẩn (proper scoring rules như pinball loss, CRPS) thay vì MAPE; (vi) minh bạch về cách phân phối được kết hợp và chuyển hoá thành quyết định.

Phần mềm / Nền tảng	Cấp độ	Nhận định (theo Lokad, 12/2025)
Lokad	Genuine	Phân phối nhu cầu và lead time được kết hợp và đưa thẳng vào lớp tối ưu hoá; không dùng khung Safety Stock/mức phục vụ.
ToolsGroup	Semi-genuine	Truyền thông rõ ràng về phân phối nhu cầu đầy đủ và xử lý đuôi dài, nhưng các phân phối này nuôi một MEIO (Multi-Echelon Inventory Optimization) theo mức phục vụ.
Smart Software / Epicor IP&O	Semi-genuine	Có engine ước lượng phân phối nhu cầu-lead time đáng tin cho hàng rời rạc, nhưng vận hành hoá qua chính sách Safety Stock/mức phục vụ cổ điển.
SAP IBP (lõi SmartOps)	Semi-genuine	MEIO ngẫu nhiên (stochastic) để đạt mục tiêu mức phục vụ — lớp "xác suất"là một add-on bên trong quy trình hoạch định xác định (deterministic).
GAINS; E2open; Coupa/LLamasoft	Semi-genuine	Có xét đến bất định (uncertainty) trong tính toán, nhưng vẫn vận hành hoá qua Safety Stock/mức phục vụ theo từ vựng MEIO cổ điển.
Kinaxis (RapidResponse)	Marketing-level	Có tính phân vị (quantile) và phần mở rộng MEIO (Wahupa), nhưng vẫn diễn đạt qua tham số mức phục vụ/Safety Stock trong một quy trình nặng về kịch bản (scenario).
Blue Yonder; o9 Solutions; RELEX; Infor; Anaplan	Marketing-level	Tài liệu tiếp thị dùng từ "xác suất/tự động", nhưng mô hình vận hành cốt lõi xoay quanh phân khúc mức phục vụ và Safety Stock động được tinh chỉnh bằng ML.

Lưu ý khi đọc bảng này

Bảng trên tóm tắt đánh giá của MỘT bên — Lokad, chính là nhà cung cấp được xếp ở cấp cao nhất trong bảng do chính họ đưa ra — nên cần đọc với sự cân nhắc: đây là góc nhìn của một đơn vị có lợi ích trực tiếp trong cách định nghĩa "xác suất thực thụ". Tuy vậy, sáu tiêu chí kỹ thuật cụ thể mà tác giả đưa ra (phân phối đầy đủ, đầu ra là quyết định thay vì tham số, khả năng chống can thiệp thủ công, xử lý đuôi dài, thước đo xác suất đúng chuẩn, minh bạch) là những tiêu chí có cơ sở học thuật vững chắc và đáng để bất kỳ Demand Planner nào dùng làm khung tham chiếu khi đánh giá phần mềm — không cần đồng ý với thứ hạng cụ thể của từng vendor để vẫn thấy hữu ích ở BỘ TIÊU CHÍ này.

6.8.1 Vậy học xong 10 buổi này, bạn đang ở đâu?

Nói thẳng và trung thực: khóa học này trang bị nền tảng **dự báo điểm cổ điển** (SES, Holt, Holt-Winters, ARIMA, hồi quy tuyến tính/đa biến, Croston cho hàng rời rạc) cùng toàn bộ kỹ năng đo lường sai số, phát hiện thiên lệch (Tracking Signal), và quy đổi ra quyết định vận hành bằng công thức Safety Stock cổ điển (giả định phân phối chuẩn). Đây CHÍNH LÀ lớp nền tảng toán học/thống kê mà ngay cả các nền tảng ở cấp "Semi-genuine"và phần lớn "Marketing-level"trong bảng trên vẫn đang vận hành bên trong (nhiều nền tảng APS thương mại, kể cả SAP IBP, vẫn dùng chính họ mô hình như Holt-Winters/ARIMA/hồi quy làm *statistical baseline* — xem lại mục Kiến trúc ERP/APS phía trên). Nói cách khác: khóa học không dạy bạn xây một hệ thống ngang tầm Lokad, nhưng dạy bạn HIỂU và VẬN HÀNH được đúng lớp kỹ thuật nằm bên dưới hầu hết phần mềm APS bạn sẽ gặp trong sự nghiệp, và đủ ngôn ngữ chuyên môn để trao đổi hiệu quả với đội triển khai phần mềm hoặc nhà tư vấn.

Khóa học KHÔNG (chưa) dạy: (1) mô hình hoá toàn bộ phân phối xác suất của nhu cầu và lead time một cách đồng thời; (2) xuất thẳng quyết định tối ưu hoá (đơn hàng/phân bổ/giá) từ phân phối xác suất mà không quy về Safety Stock/mức phục vụ; (3) các thước đo xác suất đúng chuẩn như pinball loss hay CRPS (khoá học dùng MAPE/MAE/MSE — các thước đo cho dự báo ĐIỂM); (4) mô phỏng Monte Carlo kết hợp đồng thời bất định của nhu cầu VÀ lead time.

6.8.2 Lộ trình học tiếp theo, nếu muốn tiến lên cấp "Semi-genuine"trở lên

- **Lý thuyết nền:** Gneiting & Katzfuss, “Probabilistic Forecasting”, *Annual Review of Statistics and Its Application*, 2014 — bài tổng quan kinh điển định nghĩa và hệ thống hoá lĩnh vực này.
- **Thước đo xác suất đúng chuẩn (proper scoring rules):** Pinball Loss (Quantile Loss) và CRPS (Continuous Ranked Probability Score) — thay thế MAPE/MAE khi đánh giá một dự báo PHÂN PHỐI thay vì một dự báo ĐIỂM.
- **Hồi quy phân vị (Quantile Regression):** mở rộng trực tiếp từ mục Hồi quy tuyến tính đã học (Chương 5) — thay vì dự báo giá trị trung bình, dự báo nhiều phân vị (ví dụ P10, P50, P90) cùng lúc; có sẵn trong `statsmodels.regression.quantile_regression` (Python).
- **Thư viện Python chuyên dụng:** GluonTS (Amazon), StatsForecast/NeuralForecast (Nixtla), PyMC hoặc Stan cho mô hình hoá Bayesian đầy đủ.

- **Mô phỏng Monte Carlo:** kết hợp đồng thời phân phối nhu cầu VÀ phân phối lead time (thay vì công thức Safety Stock giả định phân phối chuẩn đã học ở Chương 6) để ước lượng trực tiếp xác suất hết hàng trong các kịch bản phức tạp.
- **Tài liệu công khai của chính Lokad:** kênh "Lokad Lectures" và sách "Introduction to Supply Chain" (2025) — đọc với tinh thần phản biện như đã lưu ý ở trên, vì đây là tài liệu của một vendor, không phải giáo trình trung lập.

6.9 S&OP: quy trình thống nhất một con số duy nhất

Sales & Operations Planning (S&OP) là quy trình họp định kỳ (thường hàng tháng) để thống nhất MỘT con số forecast duy nhất giữa các phòng ban — giải pháp trực tiếp cho vấn đề Bullwhip vừa nêu, vì loại bỏ tình trạng mỗi mắt xích tự dự phòng theo cách riêng.

- **Bước 1 — Data Gathering & Demand Review:** đội Demand Planning chạy các mô hình đã học (Chương 3–5) để có con số baseline KHÁCH QUAN, rồi Sales/Marketing điều chỉnh theo thông tin mà mô hình thống kê không biết được (kế hoạch khuyến mãi mới, khách hàng lớn sắp đặt đơn) — kết quả là "unconstrained demand forecast".
- **Bước 2 — Supply Review:** bộ phận Sản xuất/Supply Chain/Mua hàng đối chiếu dự báo nhu cầu với năng lực sản xuất, tồn kho hiện có, khả năng nhà cung cấp — xác định điểm nghẽn.
- **Bước 3 — Financial Reconciliation (Pre-S&OP):** bộ phận Tài chính (FP&A) quy đổi kế hoạch nhu cầu–cung ứng ra số liệu tài chính (doanh thu, chi phí, lợi nhuận dự kiến), xử lý chênh lệch giữa các phòng ban trước khi trình ban lãnh đạo — đây chính là bước Tài chính đối chiếu tác động của Safety Stock lên Vòng quay tồn kho đã học ở mục trước.
- **Bước 4 — Executive S&OP Meeting:** ban lãnh đạo phê duyệt kế hoạch cân đối cuối cùng, chốt MỘT con số duy nhất ("one number"), toàn công ty cùng sử dụng.
- **Bước 5 — Execution:** kế hoạch được đẩy xuống ERP để thực thi — sinh đơn mua hàng, lệnh sản xuất, kế hoạch phân phối. Đây là bước khép lại vòng lặp: từ dự báo thống kê (APS) quay về hệ thống giao dịch (ERP).

Forecast thống kê đóng ba vai trò trong quy trình này: (1) baseline khách quan, không bị ảnh hưởng bởi áp lực doanh số hay lạc quan thái quá; (2) điểm khởi đầu để tranh luận có căn cứ — khi Sales muốn điều chỉnh tăng, câu hỏi trở thành "vì sao lệch khỏi baseline thống kê"thay vì tranh luận cảm tính; (3) công cụ đo lường và cải thiện liên tục — so sánh forecast đã điều chỉnh (consensus) với forecast thống kê thuần để biết đội ngũ đang thêm giá trị hay đang làm xấu đi.

6.9.1 Ví dụ minh hoạ: từ Baseline đến Kế hoạch bị giới hạn

Ví dụ minh hoạ số liệu tổng quát sau làm rõ cơ chế năm bước trên bằng một dòng số cụ thể (không phải số liệu của một SKU cụ thể trong khóa học):

Bước	Giá trị	Diễn giải
Baseline thống kê	100.000 chiếc	Điểm khởi đầu từ mô hình, chưa phải câu trả lời cuối
Demand Review (+)	+20.000 / +10.000	Thêm điểm bán, kích hoạt marketing
Demand Review (−)	−5.000 / −8.000	Tăng giá, sản phẩm cuối vòng đời
Nhu cầu không bị giới hạn	**117.000 chiếc**	Tổng hợp toàn bộ điều chỉnh Demand Review
Supply Review	105.000 chiếc	Giới hạn CÔNG SUẤT — không phải dự báo nhu cầu mới
Khoảng cách	**12.000 chiếc**	Nơi S&OP trở thành quy trình quản trị thực sự

Lưu ý quan trọng

Khi năng lực cung ứng (105.000) thấp hơn nhu cầu không giới hạn (117.000), nhu cầu THẬT vẫn là 117.000 — công suất chỉ là một RÀNG BUỘC, không phải dự báo mới. Sai lầm phổ biến là "âm thầm"hạ dự báo xuống bằng công suất để hai con số khớp nhau — điều này CHE GIẤU mất quy mô cơ hội bị bỏ lỡ. Cách làm đúng: giữ nguyên cả hai con số, đưa khoảng cách 12.000 ra bàn Consensus Meeting để ban lãnh đạo quyết định hành động cạnh tranh (tăng ca, ưu tiên khách hàng, đẩy nhanh nguồn cung, hoặc chấp nhận mất một phần doanh số).

6.9.2 Forecast Value Added: con người có đang thêm giá trị?

Mỗi bước điều chỉnh trong quy trình S&OP — Sales, Marketing, ban lãnh đạo — đều TỐN thời gian và nguồn lực. Câu hỏi cần trả lời định kỳ: những điều chỉnh đó có thực sự làm forecast CHÍNH XÁC HƠN, hay chỉ đang làm forecast SAI KHÁC ĐI theo hướng khác? **Forecast Value Added** (FVA) là chỉ số đo lường trực tiếp câu hỏi này, bằng cách so sánh độ chính xác SAU và TRƯỚC khi con người can thiệp:

$$\text{FVA} = \text{MAPE}_{\text{baseline thống kê}} - \text{MAPE}_{\text{sau điều chỉnh}}$$

FVA DƯƠNG nghĩa là bước điều chỉnh đó THỰC SỰ cải thiện độ chính xác — con người đang thêm giá trị thật, ví dụ Sales biết trước một hợp đồng lớn mà mô hình thống kê không thể biết. FVA ÂM là tín hiệu cảnh báo: bước điều chỉnh đó đang làm forecast TỆ ĐI so với baseline khách quan — có thể do thiên lệch lạc quan hệ thống (Sales luôn có xu hướng đẩy số lên để đạt chỉ tiêu) hoặc can thiệp theo cảm tính không có căn cứ.

Lưu ý thực hành

Áp dụng FVA định kỳ (hàng quý hoặc hàng năm) cho TỪNG bước trong quy trình S&OP — Demand Review của Sales, của Marketing, Consensus Meeting — giúp nhận diện CHÍNH XÁC bước nào đang thêm giá trị và bước nào cần cải thiện quy trình, thay vì đánh giá cảm tính "con người luôn biết rõ hơn máy"hoặc ngược lại.

6.10 Ma trận ABC/XYZ: ưu tiên nguồn lực hoạch định

Ma trận Pegels ở Chương 1 trả lời câu hỏi "dùng phương pháp nào cho một SKU". Với danh mục hàng trăm SKU, câu hỏi tiếp theo là: nên đầu tư thời gian phân tích vào SKU nào trước? Ma trận ABC/XYZ là công cụ hai chiều trả lời đúng câu hỏi này.

- **Chiều ABC — giá trị kinh tế:** phân loại SKU theo mức đóng góp doanh thu hoặc lợi nhuận, áp dụng nguyên tắc Pareto 80/20 — A (đóng góp cao), B (trung bình), C (thấp).
- **Chiều XYZ — độ dự đoán được:** sử dụng lại chính hệ số biến thiên CV đã học ở Chương 1, không cần khái niệm mới — X (CV thấp, dễ dự đoán), Y (trung bình), Z (CV cao, khó dự đoán).

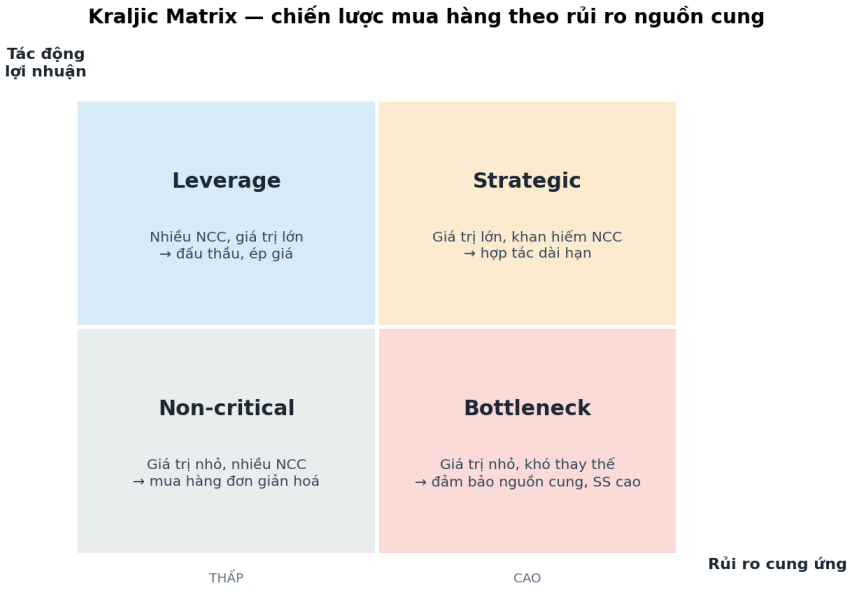
Nhóm	Đặc điểm	Khuyến nghị đầu tư nguồn lực
AX	Giá trị cao, dễ dự đoán	Đầu tư tự động hoá kỹ lưỡng — độ chính xác cao ở đây tạo giá trị lớn và ổn định
AZ	Giá trị cao, khó dự đoán	Cần nhiều sự chú ý quản lý nhất — rủi ro sai sót gây thiệt hại lớn nhưng khó tự động hoá hoàn toàn
CZ	Giá trị thấp, khó dự đoán	Đầu tư nguồn lực hoạch định khổng lồ để cố hoàn thiện forecast tại đây tạo RẤT ÍT giá trị kinh doanh

Lưu ý thực hành

Phân loại ABC (giá trị) cần dữ liệu doanh thu/lợi nhuận THẬT của từng SKU — không thể suy ra từ đặc điểm thống kê của chuỗi thời gian như CV. ABC/XYZ KHÔNG thay thế việc chọn đúng phương pháp dự báo (Pegels) — mà là lớp quyết định BỔ SUNG về mức độ đầu tư thời gian phân tích.

6.11 Kraljic Matrix: chiến lược mua hàng theo rủi ro nguồn cung

ABC/XYZ (mục trước) trả lời câu hỏi "SKU này đáng đầu tư công sức DỰ BÁO đến mức nào". **Kraljic Matrix** trả lời một câu hỏi khác, dành cho bộ phận Mua hàng (Procurement): SKU này cần chiến lược ĐÀM PHÁN và QUAN HỆ NHÀ CUNG CẤP như thế nào? Ma trận phân loại mặt hàng mua vào theo hai trục: Tác động lợi nhuận (Profit Impact) và Rủi ro cung ứng (Supply Risk).



Bảng dưới đây trình bày chi tiết đặc điểm và khuyến nghị chiến lược cho từng nhóm:

	Rủi ro cung ứng THẤP	Rủi ro cung ứng CAO
Tác động lợi nhuận CAO	**Leverage** — nhiều nhà cung cấp, giá trị lớn → đấu thầu, ép giá	**Strategic** — giá trị lớn, khan hiếm nhà cung cấp → hợp tác dài hạn, dự trữ chiến lược
Tác động lợi nhuận THẤP	**Non-critical** — giá trị nhỏ, nhiều nhà cung cấp → mua hàng đơn giản hoá (e-procurement)	**Bottleneck** — giá trị nhỏ nhưng khó thay thế → đảm bảo nguồn cung, tồn kho an toàn cao

Ví dụ minh hoạ

Một cảm biến đặc chủng chỉ một hãng sản xuất, giá trị mua THẤP nhưng thiếu là dừng cả dây chuyền → xếp vào nhóm **Bottleneck**, cần giữ Safety Stock CAO hơn nhiều so với giá trị tiền của nó — khác hẳn logic "giá trị thấp thì tồn kho thấp"thông thường mà phân loại ABC/XYZ đơn thuần có thể gợi ý sai.

Kraljic quyết định CÁCH mua (chiến lược đàm phán, số lượng nhà cung cấp, độ dài hợp đồng) — đầu vào quan trọng để ước lượng độ biến động lead time (σ_L), một thành phần thường bị bỏ sót trong công thức Safety Stock cơ bản đã học ở mục trước (vốn chỉ tính đến biến động NHU CẦU). Với hàng nhóm Bottleneck có lead time biến động mạnh, công thức Safety Stock mở rộng cần cộng thêm phương sai của lead time, khiến Safety Stock thực tế thường cao hơn đáng kể so với khi chỉ tính riêng biến động nhu cầu.

6.12 Nhu cầu rời rạc: họ phương pháp Croston

Bốn SKU xuyên suốt giáo trình có ba SKU (Nồi cơm điện, Bếp từ đôi, Áo khoác mùa đông) áp dụng được các phương pháp đã học ở Chương 3–5. SKU thứ tư — Phụ tùng thay thế X12

— có 61,1% số tháng bằng 0 (Chương 1) và không phương pháp nào trong số đó cho kết quả đáng tin cậy. Mục này trình bày đầy đủ họ phương pháp chuyên biệt cho dạng nhu cầu này: Croston (1972), SBA (Syntetos & Boylan, 2005) và TSB (Teunter, Syntetos & Babai, 2011).

6.12.1 Vì sao Exponential Smoothing thất bại với nhu cầu rời rạc

Simple Exponential Smoothing (Chương 3) san bằng trực tiếp trên chuỗi Y_t, bao gồm cả các kỳ bằng 0:

$$F_{t+1} = \alpha Y_t + (1-\alpha)F_t$$

Mỗi khi gặp một kỳ $Y_t = 0$, số hạng αY_t bằng 0 kéo F_{t+1} giảm về gần 0. Khi nhu cầu đột ngột xuất hiện trở lại, mô hình lại "giật mình"điều chỉnh tăng vọt. Hệ quả là dự báo luôn trễ nhịp và không phản ánh đúng tốc độ tiêu thụ trung bình thực sự của SKU — sai số MAPE tại các kỳ có nhu cầu thường vượt 50–100%.

TỆP ĐÍNH KÈM — Croston / SBA / TSB

Python: `Buoi6/Buoi6_04_Croston_XuLyRoiRac.py` (cài đặt đầy đủ cả 3 biến thể, chạy trên SKU X12 thật). **Excel:** sheet `Croston_XuLyRoiRac` trong `ERP_4SKU_DapAn_Buoi1.xlsx` (công thức Croston/SBA đầy đủ, kéo-dãn được). **Slide:** `Buoi6_TuForecastDenQuyetDinh.pptx`, slide 20–25.

6.12.2 Croston (1972): tách kích thước và khoảng cách nhu cầu

Thay vì mô hình hoá trực tiếp Y_t, Croston tách chuỗi thành hai thành phần độc lập, **mỗi thành phần chỉ cập nhật khi có nhu cầu phát sinh** ($Y_t > 0$):

Quy mô nhu cầu (demand size):

$$z_t = \alpha y_t + (1-\alpha)z_{t-1} \qquad \text{(chỉ khi } y_t > 0\text{)}$$

Khoảng cách phát sinh (inter-arrival time):

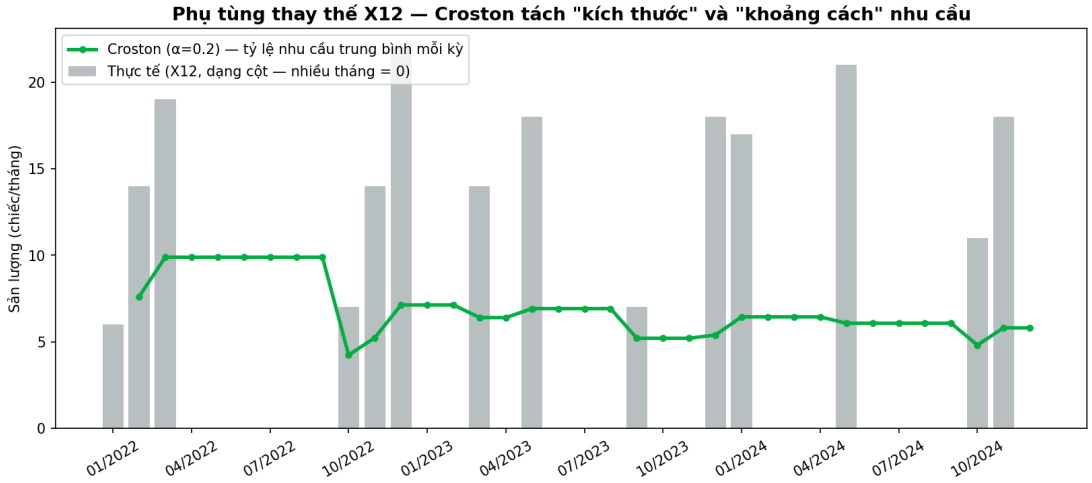
$$p_t = \alpha q + (1-\alpha)p_{t-1} \qquad \text{(chỉ khi } y_t > 0\text{)}$$

trong đó q là số kỳ đã trôi qua kể từ lần phát sinh nhu cầu dương gần nhất. Nếu $y_t = 0$: cả z_t và p_t đều giữ nguyên giá trị trước đó ($z_t = z_{t-1}$, $p_t = p_{t-1}$), chỉ có bộ đếm q tăng thêm 1.

Dự báo:

$$\hat{y}_{t+1} = \frac{z_t}{p_t}$$

Cả z_t và p_t đều được làm mượt bằng đúng công thức Simple Exponential Smoothing đã học ở Chương 3 — Croston không phải một kỹ thuật hoàn toàn mới, mà là cách áp dụng SES cho hai chuỗi phụ thay vì một chuỗi chính. Vì z và p chỉ thay đổi khi có nhu cầu, tỷ số z_t/p_t giữ ổn định trong suốt các kỳ im lặng, không dao động về 0 rồi bật ngược như SES thuần.



Kết quả thật

Trên SKU X12, đường Croston giữ nguyên mức dự báo suốt 6 tháng liên tục không phát sinh (04–09/2022), rồi cập nhật ngay khi nhu cầu quay lại vào 10/2022 — hoàn toàn khác hành vi "kéo về 0 rồi giật ngược"của SES thuần.

6.12.3 Thiên lệch của Croston gốc và bản sửa lỗi SBA

Syntetos và Boylan (2001) chứng minh bằng giải tích rằng z_t/p_t là một ước lượng **thiên lệch dương** (positively biased) của tỷ số kỳ vọng thật $E[z]/E[p]$, vì kỳ vọng của một tỷ số không bằng tỷ số của hai kỳ vọng ($E[z/p] \neq E[z]/E[p]$ nói chung). Hệ quả thực tiễn: Croston gốc có xu hướng dự báo cao hơn nhu cầu thật một cách có hệ thống, dẫn đến tồn kho an toàn bị tính dư.

Syntetos và Boylan (2005) đề xuất bản xấp xỉ sửa lỗi, gọi tắt là SBA (Syntetos-Boylan Approximation):

$$\hat{y}_{t+1} = \left(1 - \frac{\alpha}{2}\right) \frac{z_t}{p_t}$$

Hệ số $(1 - \alpha/2) < 1$ được suy ra từ phân tích kỳ vọng của ước lượng san bằng mũ, có tác dụng chiết giảm phần thiên lệch dương. Với $\alpha = 0{,}2$ (giá trị phổ biến), hệ số này xấp xỉ 0,9 — SBA dự báo thấp hơn Croston gốc khoảng 10%. SBA vẫn giữ nguyên hành vi "duy trì mức dự báo trong các kỳ im lặng"giống Croston gốc.

6.12.4 TSB: theo dõi xác suất phát sinh thay vì khoảng cách

Teunter, Syntetos và Babai (2011) đề xuất một cơ chế khác hẳn: thay vì theo dõi *khoảng cách* p (chỉ cập nhật khi có nhu cầu), TSB theo dõi trực tiếp **xác suất phát sinh nhu cầu** mỗi kỳ, và xác suất này được cập nhật ở **mọi kỳ**, kể cả các kỳ bằng 0:

$$\text{prob}_t = \beta \cdot \mathbb{1}[y_t > 0] + (1 - \beta)\,\text{prob}_{t-1}$$

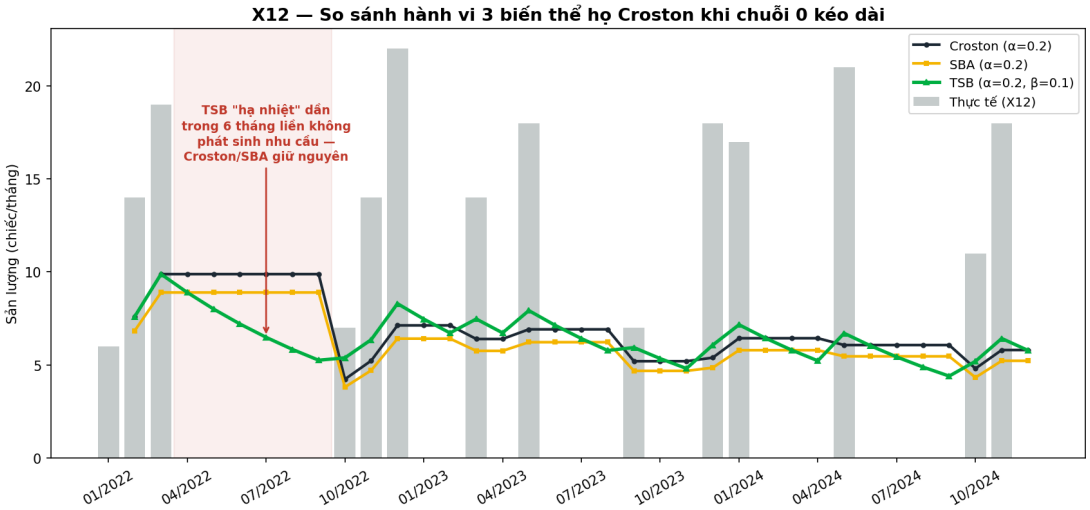
trong đó $\mathbb{1}[y_t > 0]$ bằng 1 nếu kỳ đó có phát sinh nhu cầu, bằng 0 nếu không. Thành phần quy mô z_t vẫn cập nhật như Croston, chỉ khi $y_t > 0$. Dự báo:

$$\hat{y}_{t+1} = \text{prob}_t \times z_t$$

Vì prob_t được cập nhật ở *mọi* kỳ, nếu chuỗi có một giai đoạn dài liên tục không phát sinh nhu cầu, prob_t sẽ giảm dần một cách tự nhiên về 0, kéo theo dự báo cũng giảm dần theo — TSB "hạ nhiệt"khi nhu cầu ngày càng thưa. Đây là khả năng mà Croston và SBA không có: cả hai đều giữ nguyên mức dự báo bất kể giai đoạn im lặng kéo dài bao lâu, vì chúng chỉ "nhìn thấy"dữ liệu tại các kỳ có phát sinh.

Sơ đồ dưới đây tóm tắt trình tự các bước cập nhật của họ phương pháp Croston / SBA / TSB khi có một lần nhu cầu mới phát sinh, trên một ví dụ minh hoạ:



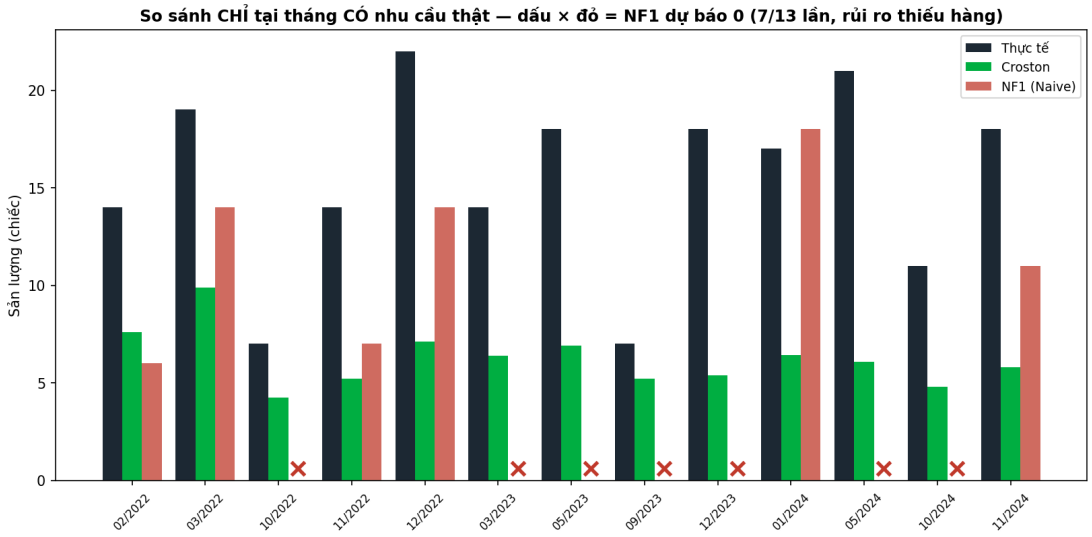


Kết quả thật

Trong giai đoạn 6 tháng liên tục không phát sinh nhu cầu (04–09/2022), Croston và SBA giữ nguyên hoàn toàn mức dự báo (khoảng 9,9 và 8,9), trong khi TSB giảm liên tục từ 8,9 xuống còn 5,3 — thể hiện đúng cơ chế "hạ nhiệt"lý thuyết.

6.12.5 Vì sao Naive Forecast thất bại nghiêm trọng hơn cả ba phương pháp trên

Một so sánh quan trọng về mặt vận hành: tại 13 kỳ SKU X12 thực sự có phát sinh nhu cầu, NF1 (dự báo bằng giá trị kỳ trước, Chương 2) dự báo đúng bằng 0 tới 7/13 lần — vì với một chuỗi có 61% kỳ bằng 0, xác suất "kỳ trước cũng bằng 0"là rất cao. Croston, SBA và TSB không bao giờ dự báo đúng bằng 0 trong các trường hợp này, vì cả ba đều duy trì một mức nền dựa trên lịch sử phát sinh, không phụ thuộc vào giá trị của riêng một kỳ liền trước.



Ý nghĩa thực tiễn

Với phụ tùng thay thế, một dự báo bằng 0 sai lầm tại đúng kỳ có nhu cầu thật có thể dẫn đến thiết bị phải ngừng hoạt động vì thiếu linh kiện. Đây là lý do vận hành quan trọng nhất để ưu tiên họ Croston thay vì Naive cho nhóm SKU rời rạc, không chỉ vì chỉ số sai số trung bình thấp hơn.

6.12.6 SBA hay TSB? Ma trận quyết định

Ba biến thể đều xây dựng trên cùng một nguyên lý (san bằng mũ), nhưng SBA và TSB dựa trên hai giả định khác nhau về bản chất của giai đoạn im lặng: SBA giả định nhu cầu chỉ tạm hoãn rồi sẽ quay lại; TSB giả định giai đoạn im lặng kéo dài là dấu hiệu đáng ngờ, cần được phản ánh vào dự báo.

Tiêu chí	SBA	TSB
Loại SKU phù hợp nhất	Phụ tùng bảo trì định kỳ, thiết bị vẫn đang hoạt động bình thường	Linh kiện máy cũ, hàng có rủi ro hết vòng đời
Khi nhu cầu = 0 kéo dài	Giữ nguyên mức dự báo (giả định chỉ tạm hoãn)	Hạ dần về 0 (giả định nhu cầu đang suy giảm)
Độ phức tạp vận hành	Đơn giản — chỉ 1 tham số α, dễ chạy hàng loạt	Phức tạp hơn — 2 tham số α (quy mô) và β (xác suất)
Rủi ro vận hành	Tồn kho chết nếu SKU đã ngừng dùng mà vẫn giữ Safety Stock	Hụt hàng nếu SKU đột ngột có nhu cầu lớn trở lại

Nguyên tắc bắt buộc

Quy tắc phân loại Syntetos-Boylan dùng hai chỉ số định lượng: ADI (khoảng cách trung bình giữa hai lần phát sinh) và CV^2 (bình phương hệ số biến thiên của quy mô nhu cầu). Nếu $ADI \geq 1{,}32$ và $CV^2 < 0{,}49$, nhu cầu được xem là "rời rạc đều"và nên ưu tiên SBA. Nếu tần suất phát sinh có xu hướng giảm rõ rệt trong 6–12 kỳ gần nhất, nên chuyển sang TSB để phản ánh đúng rủi ro suy giảm.

6.13 Mười chỉ số Demand & Supply Planner cần nắm

Toàn bộ giáo trình đến nay tập trung vào các chỉ số phía **Demand Planning** (dự báo nhu cầu). Trong công việc thực tế, forecast tốt chỉ là điểm khởi đầu của một chuỗi chỉ số vận hành rộng hơn, trải dài sang phía **Supply Planning** (hoạch định cung ứng). Bảng dưới đây tổng hợp mười chỉ số phổ biến nhất mà một Demand hoặc Supply Planner cần nắm, đối chiếu với những gì giáo trình đã trang bị:

Chỉ số	Công thức	Đã học ở đâu trong giáo trình
Phía Demand Planner		
MAPE	trung bình($\lvert e_t/Y_t \rvert$) $\times$ 100%	Chương 2 — chỉ số trung tâm xuyên suốt khoá
WMAPE	$\sum \lvert e_t \rvert / \sum Y_t \times 100\%$	Chương 2 — mục vừa học ở trên
Forecast Bias	trung bình(e_t)	Chương 2 (ME) và Chương 6 (Tracking Signal)
FVA	$\text{MAPE}_{\text{baseline}} - \text{MAPE}_{\text{sau điều chỉnh}}$	Chương 6, mục S&OP
Actual Sales vs. Assumptions	(Chuyển đổi thực tế / Giả định bán hàng) $\times$100%	Liên quan Forecast Value Added — đối chiếu forecast với kế hoạch Sales gốc
Phía Supply Planner (giới thiệu tổng quan)		
OTIF	(Đơn giao đúng hạn & đủ số lượng / Tổng đơn) $\times$100%	Ngoài phạm vi khoá — đo hiệu suất GIAO HÀNG, không phải độ chính xác dự báo
Inventory Turnover	Giá vốn hàng bán / Tồn kho bình quân	Liên hệ trực tiếp Safety Stock (Chương 6) — Safety Stock thấp hơn giúp vòng quay tồn kho nhanh hơn
Perfect Order	(Số đơn hoàn hảo / Tổng đơn) $\times$100%	Ngoài phạm vi khoá — tổng hợp từ nhiều chỉ số vận hành khác (giao hàng, chứng từ, chất lượng)
Order Fulfillment Time	Tổng thời gian chu kỳ thực tế / Tổng số đơn	Ngoài phạm vi khoá — đo tốc độ xử lý đơn hàng
Obsolescence Rate	Giá trị tồn kho lỗi thời / Tổng giá trị tồn kho	Liên hệ trực tiếp ABC/XYZ (mục trước) — SKU nhóm CZ có rủi ro lỗi thời cao nhất

Lưu ý về phạm vi giáo trình

Năm chỉ số phía Demand Planner đã được trang bị ĐẦY ĐỦ qua các chương trước. Năm chỉ số phía Supply Planner — OTIF, Inventory Turnover, Perfect Order, Order Fulfillment Time, Obsolescence Rate — thuộc phạm vi vận hành kho vận và logistics, NẰM NGOÀI trọng tâm "dự báo nhu cầu"của giáo trình này, nên chỉ giới thiệu tổng quan để người học có bức tranh đầy đủ về vai trò của forecast trong chuỗi chỉ số vận hành rộng hơn. Muốn đi sâu vào nhóm chỉ số Supply, nên tham khảo thêm giáo trình chuyên về Logistics & Operations.

6.14 Case Study Thực Tế: Hiệu ứng Bullwhip của P&G — vì sao đơn hàng tã giấy dao động dữ dội hơn cả nhu cầu thật?

Ngành: Hàng tiêu dùng nhanh (FMCG / CPG)

Đầu thập niên 1990, các quản lý chuỗi cung ứng của Procter & Gamble (P&G) với sản phẩm tã giấy Pampers nhận thấy một nghịch lý: nhu cầu tiêu dùng thực tế của các em bé gần như ổn định quanh năm (trẻ sơ sinh không có "mùa cao điểm"), nhưng đơn đặt hàng từ nhà phân phối lên nhà máy lại dao động cực mạnh — và biến động đơn hàng từ nhà cung cấp nguyên liệu thô cho P&G còn lớn hơn nữa. Giáo sư Hau Lee (Stanford) cùng cộng sự đặt tên hiện tượng này là "Bullwhip Effect" (Hiệu ứng roi da) trong bài báo kinh điển trên *MIT Sloan Management Review* (1997), chỉ ra ba nguyên nhân chính: mỗi mắt xích tự dự báo riêng lẻ, đặt hàng theo lô lớn, và tâm lý "phòng thủ" khi thiếu hàng.

Bài học liên hệ chương này: case này giải thích trực tiếp vì sao khóa học nhấn mạnh S&OP (mục sau) — một quy trình thống nhất MỘT con số dự báo cho toàn bộ chuỗi cung ứng, thay vì để mỗi phòng ban (Sales, Supply, Tài chính) tự dự báo riêng rồi cộng dồn sai số qua từng tầng — chính là cách công nghiệp thực tế đã dùng để kiềm chế hiệu ứng Bullwhip suốt hơn 25 năm qua.

Nguồn: Hau L. Lee, V. Padmanabhan, Seungjin Whang, "The Bullwhip Effect in Supply Chains", MIT Sloan Management Review, 1997.

6.15 Tổng kết chương: bản đồ ảnh hưởng liên phòng ban

Toàn bộ Chương 6 xoay quanh MỘT ý tưởng cốt lõi: đầu ra của mô hình dự báo (μ, σ đã học ở đầu chương) không dừng lại ở một con số trên màn hình — nó LAN TRUYỀN thành quyết định cụ thể ở nhiều phòng ban khác nhau. Bảng dưới đây tổng hợp lại toàn bộ chuỗi liên kết đó, đi từ đầu ra mô hình đến hành động cuối cùng:

Đầu ra từ mô hình dự báo	Phòng ban	Quyết định cụ thể
μ — dự báo điểm	Sản xuất, Mua hàng	Kế hoạch sản xuất, khối lượng đặt hàng cơ bản ($\bar{d}$ trong công thức ROP)
σ — sai số dự báo (Chương 2)	Kho vận, Supply Planning	Tính Safety Stock, phân loại XYZ
Phân loại theo giá trị (ABC)	Kế hoạch, Kiểm soát tồn kho	Mức độ ưu tiên review, tần suất kiểm kê
Rủi ro nguồn cung (Kraljic)	Mua hàng, Quan hệ NCC	Chiến lược đàm phán, số lượng nhà cung cấp, độ dài hợp đồng, ước lượng σ_L
ROP / Safety Stock	Kho vận, Vận hành	Thời điểm và số lượng đặt hàng lại
Vòng quay tồn kho	Tài chính (FP&A)	Đánh giá hiệu quả sử dụng vốn lưu động, bước Financial Reconciliation trong S&OP
Dự báo đồng thuận (consensus, qua FVA)	Ban điều hành	Phê duyệt kế hoạch S&OP "một con số", đẩy xuống ERP để Execution

Kết luận chương

Một Demand Planner giỏi không chỉ chạy đúng mô hình (Chương 1–5) — mà còn hiểu được con số μ, σ mình tạo ra sẽ đi qua bao nhiêu phòng ban, ảnh hưởng đến bao nhiêu quyết định, trước khi trở thành một đơn hàng thực tế trên hệ thống ERP. Đây chính là khác biệt giữa "biết chạy mô hình thống kê"và "hiểu forecasting trong bối cảnh vận hành doanh nghiệp thật– mục tiêu xuyên suốt của chương này.

CHƯƠNG 7

Kiểm Tra Quá Khớp Và Ôn Tập

TỆP ĐÍNH KÈM — Chương 7

Python: `Buoi7/Buoi7_01_BieuDo.py`, `Buoi7/Buoi7_02_ExcelSheet_CaseBepTuDoi.py`.
Excel: sheet `Case_BepTuDoi`. **Slide:** `Buoi7_OnTapGiuaKhoa.pptx`.

Chương này trình bày hiện tượng quá khớp (overfitting) — rủi ro kỹ thuật quan trọng nhất khi lựa chọn mô hình dựa đơn thuần vào chỉ số sai số, cùng công cụ định lượng để phát hiện hiện tượng này.

7.1 Hiện tượng quá khớp (Overfitting)

Quá khớp xảy ra khi một mô hình có số lượng tham số quá lớn so với số lượng quan sát, khiến mô hình có đủ "bậc tự do" để khớp gần như hoàn hảo với toàn bộ dữ liệu lịch sử — kể cả những biến động chỉ là nhiễu ngẫu nhiên không mang quy luật. Hậu quả là mô hình đạt chỉ số sai số rất thấp trên dữ liệu lịch sử (in-sample) nhưng mất khả năng dự báo chính xác cho dữ liệu tương lai (out-of-sample), vì mô hình đã "học thuộc lòng" nhiễu thay vì học được quy luật thật.

7.2 Adjusted R-squared

$$R^2_{\text{adj}} = 1 - (1 - R^2)\frac{n-1}{n-k-1}$$

trong đó n là số quan sát, k là số biến giải thích (không tính hệ số chặn). So với R^2 thông thường, Adjusted R^2 áp dụng một hệ số điều chỉnh làm giảm giá trị khi số biến k tăng lên tương đối so với số quan sát n — qua đó "phạt" các mô hình sử dụng quá nhiều tham số. Một hệ quả quan trọng: Adjusted R^2 có thể nhận giá trị ÂM khi mô hình có quá nhiều tham số so với lượng dữ liệu, và giá trị âm được diễn giải là mô hình còn kém hơn việc dự báo bằng chính giá trị trung bình của dữ liệu.

7.2.1 Bảng tính tay: hai mô hình cùng số tham số, kết luận trái ngược

Mô hình	n	k	R^2	Tính R^2_{adj}
Nồi cơm điện (Regression)	36	13	0,988	$1-(1-0{,}988)\frac{35}{22} = \mathbf{0{,}981}$
Bếp từ đôi (Regression)	36	13	0,259	$1-(1-0{,}259)\frac{35}{22} = \mathbf{-0{,}18}$

Cả hai mô hình có CÙNG cấu trúc (13 tham số, 36 quan sát) nhưng kết luận hoàn toàn trái ngược: với Nồi cơm điện, R^2 cao (0,988) VÀ R^2_{adj} vẫn cao (0,981) — các biến giải thích thực sự nắm bắt quy luật thật. Với Bếp từ đôi, R^2 trông chấp nhận được (0,259) nhưng R^2_{adj} ÂM — 13 tham số đang "khớp nhiễu"chứ không học được quy luật nào, vì bản thân SKU này gần như không có cấu trúc trend/mùa vụ để mô hình hoá (đã xác nhận bằng CV thấp ở Chương 1).

7.3 Quy tắc kinh nghiệm và ví dụ thực nghiệm

Quy tắc kinh nghiệm phổ biến trong thống kê ứng dụng: cần tối thiểu 10 quan sát cho mỗi tham số được ước lượng để đảm bảo độ tin cậy hợp lý. Với 36 quan sát, số tham số an toàn tối đa chỉ vào khoảng 3-4, không phải 10-13 như các mô hình phức tạp đôi khi sử dụng.

Phương pháp (Bếp từ đôi)	MAPE	Số tham số	Adjusted R^2 hoặc đánh giá
Holt-Winters	2.45%	10	Nghi ngờ quá khớp (10 tham số / 36 quan sát)
Regression	2.45%	13	Adjusted R^2 = -0.128 (ÂM — quá khớp xác nhận)
SES	3.05%	1	Đáng tin cậy — đơn giản, đúng cấu trúc Ổn định

Kết luận chương

khi hai mô hình cho chỉ số sai số gần bằng nhau, mô hình có ÍT tham số hơn và có bằng chứng thống kê vững chắc hơn (Adjusted R^2 dương, F p-value nhỏ) nên được ưu tiên lựa chọn, dù MAPE có thể cao hơn đôi chút.

7.4 Train/Test Split — tiêu chuẩn vàng để kiểm tra quá khớp

Adjusted R^2 là một phép *hiệu chỉnh thống kê*: nó suy luận khả năng quá khớp từ tỷ lệ giữa số tham số và số quan sát, mà không cần thêm dữ liệu nào ngoài dữ liệu đã dùng để fit mô hình. Train/Test Split là cách tiếp cận trực tiếp hơn — *tiêu chuẩn vàng* trong thống kê và học máy để kiểm tra một mô hình có thực sự dự báo tốt hay không.

TỆP ĐÍNH KÈM — Chương 7 — Train/Test Split

Python: `Buoi7/Buoi7_03_TrainTestSplit.py`, `Buoi7/Buoi7_04_WalkForwardValidation.py` (Random vs Chronological Split, Walk-Forward). **Excel:** sheet `Train_Test_Split` trong `ERP_4SKU_DapAn_Buoi1.xlsx`. **Slide:** `Buoi7_OnTapGiuaKhoa.pptx`, slide 12–18.

7.4.1 Vấn đề: mọi MAPE trong giáo trình đến nay đều tính trong mẫu

Từ Chương 2 đến Chương 6, mọi chỉ số MAPE được trình bày — của NF1, NF2, SES, Holt, Holt-Winters, SARIMA, Regression — đều được tính theo quy trình: fit (ước lượng tham số) mô hình trên *toàn bộ* dữ liệu lịch sử, rồi đo sai số cũng trên *chính* dữ liệu đó. Đây là sai số **trong mẫu** (in-sample) — phản ánh mô hình khớp quá khứ tốt đến đâu, không phải phản ánh mô hình sẽ dự báo tương lai chính xác đến đâu. Một mô hình có đủ tham số luôn có thể khớp rất sát dữ liệu lịch sử, kể cả khi phần lớn những gì nó "học"được chỉ là nhiễu ngẫu nhiên — đây chính là bản chất của quá khớp đã trình bày ở đầu chương.

7.4.2 Cách làm đúng: chia dữ liệu trước khi làm bất kỳ điều gì khác

$$\text{Train} = \{Y_1, \ldots, Y_{n_{\text{train}}}\} \qquad \text{Test} = \{Y_{n_{\text{train}}+1}, \ldots, Y_n\}$$

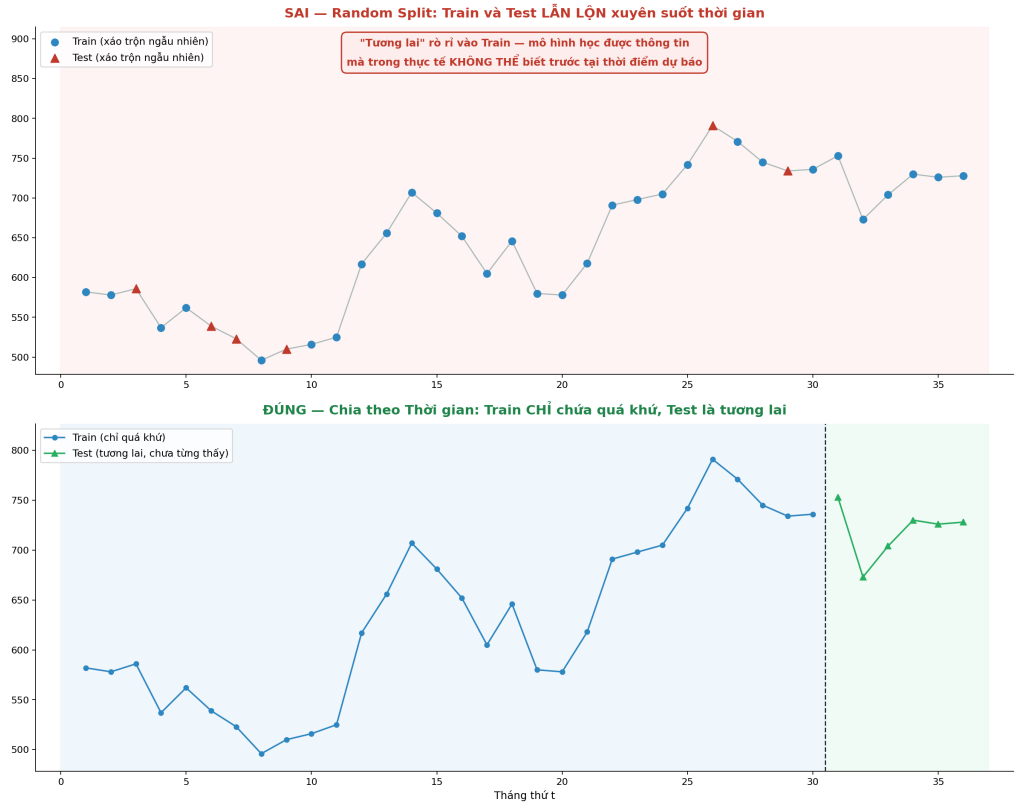
Nguyên tắc: **mọi** bước ước lượng tham số — tối ưu α, β, γ bằng Solver, chọn order $(p,d,q)(P,D,Q)_s$ bằng grid search AIC, ước lượng hệ số hồi quy bằng OLS — chỉ được thực hiện trên tập Train. Tập Test bị giấu hoàn toàn cho đến bước cuối cùng: so sánh giá trị dự báo với giá trị thực tế *chưa từng được mô hình nhìn thấy.*

Nguyên tắc bắt buộc

Nếu bất kỳ bước chọn tham số nào (kể cả việc chọn order ARIMA bằng grid search AIC) vô tình sử dụng thông tin từ giai đoạn Test, đây là lỗi **rò rỉ dữ liệu** (data leakage) — kết quả đánh giá trên Test không còn đáng tin, dù bản thân con số MAPE trông vẫn hợp lý.

7.4.3 Cạm bẫy thường gặp: Random Split cho chuỗi thời gian

Một thói quen rất phổ biến khi chuyển từ Machine Learning thông thường (Classification, Regression trên dữ liệu độc lập) sang Time Series là dùng hàm chia ngẫu nhiên — `sklearn.train_test_split()` trong Python, `sample()` hoặc `caret::createDataPartition()` trong R — để xáo trộn rồi chia dữ liệu, ví dụ 80% Train, 20% Test. Với dữ liệu ĐỘC LẬP (các dòng không phụ thuộc thứ tự), cách này hoàn toàn hợp lý. Nhưng với CHUỖI THỜI GIAN, thời gian chính là một phần cấu trúc của dữ liệu — xáo trộn ngẫu nhiên phá vỡ cấu trúc đó.



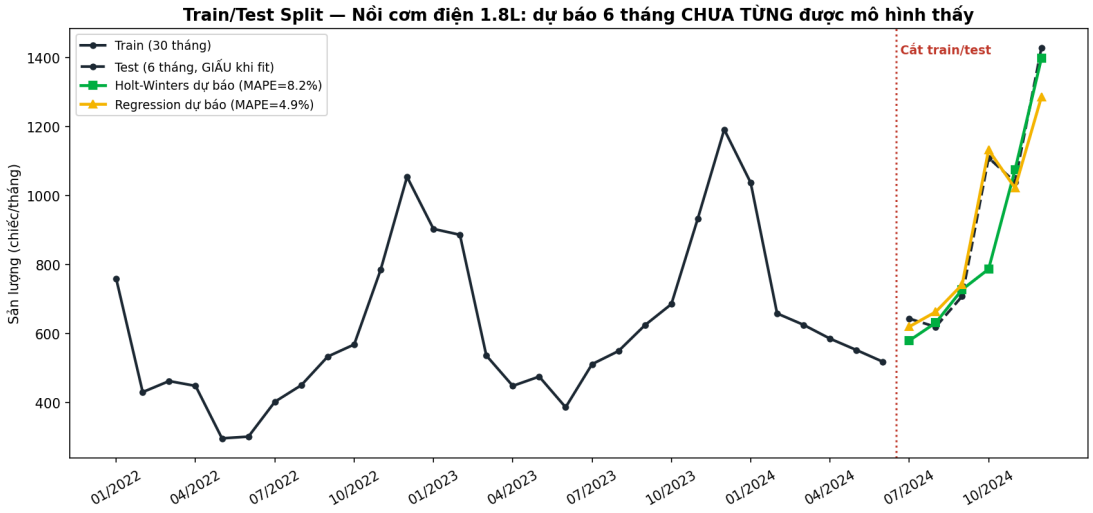
Nếu random split dữ liệu ba năm 2022–2024, tập Train hoàn toàn có thể chứa vài tháng của năm 2024 trong khi tập Test lại chứa vài tháng của năm 2022 hoặc 2023. Mô hình khi đó được HUẤN LUYỆN bằng thông tin TƯƠNG LAI, rồi quay lại "dự báo"QUÁ KHỨ — điều không thể xảy ra trong vận hành thực tế. Đây là một dạng rò rỉ dữ liệu đặc thù của chuỗi thời gian, gọi là **look-ahead bias** (thiên lệch nhìn trước) — kết quả đánh giá có thể đẹp một cách đáng ngờ, vì mô hình đã "nhìn thấy"những mẫu hình thuộc về tương lai.

Quy tắc bắt buộc

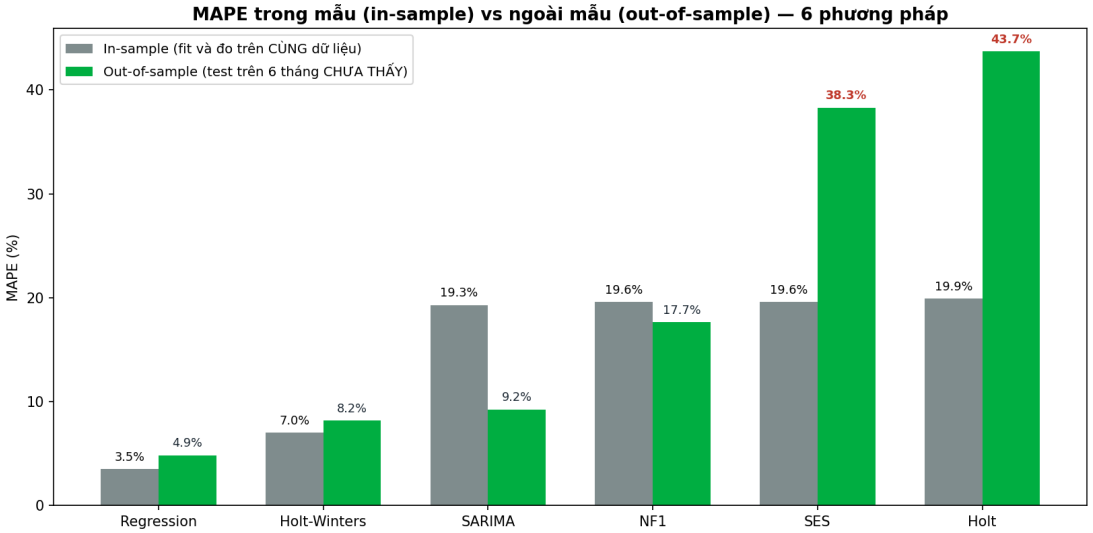
KHÔNG BAO GIỜ dùng hàm chia ngẫu nhiên (`train_test_split()`, `sample()`, `createDataPartition()`) cho dữ liệu chuỗi thời gian. LUÔN chia theo đúng thứ tự thời gian — Train là đoạn liên tục ở đầu (quá khứ), Test là đoạn liên tục ở cuối (tương lai) — đúng như công thức đã nêu ở đầu mục này.

7.4.4 Kết quả thật: chia 30 tháng Train, 6 tháng Test trên Nồi cơm điện

Áp dụng đúng bảy phương pháp đã học vào SKU chính của giáo trình, với 30 tháng đầu (01/2022–06/2024) làm Train và 6 tháng cuối (07/2024–12/2024) hoàn toàn bị giấu khi ước lượng tham số:



Phương pháp	In-sample	Out-of-sample	Chênh lệch	Kết luận
Regression (biết Promo)	3,5%	4,85%	+1,35 điểm	Ổn định — đáng tin
Holt-Winters	7,0%	8,19%	+1,19 điểm	Ổn định — đáng tin
SARIMA	19,3%	9,25%	−10,05 điểm	Cải thiện ngoài mẫu
NF1	19,6%	17,67%	−1,93 điểm	Ổn định (không có tham số để quá khớp)
SES	19,6%	38,29%	+18,69 điểm	**SỤP ĐỔ — không đáng tin**
Holt	19,9%	43,71%	+23,81 điểm	**SỤP ĐỔ — không đáng tin**

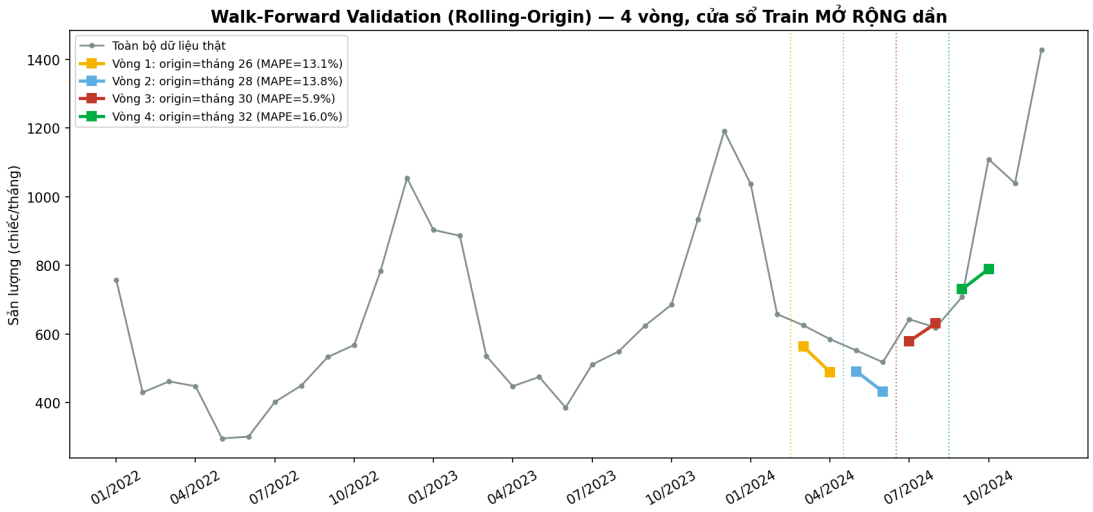


Kết quả thật

Holt-Winters và Regression — hai phương pháp đã "thắng"xuyên suốt Chương 3 và Chương 5 — giữ được độ chính xác gần như nguyên vẹn khi kiểm tra trên dữ liệu hoàn toàn chưa thấy, xác nhận rằng thành tích trong mẫu của chúng KHÔNG đến từ quá khớp. Ngược lại, SES và Holt — vốn đã không tốt trong mẫu (khoảng 20%) — sụp đổ hoàn toàn ngoài mẫu (38–44%), vì cả hai không có cơ chế nắm bắt mùa vụ nên hoàn toàn lạc nhịp khi dự báo tiến về phía trước nhiều kỳ liên tiếp.

7.4.5 Walk-Forward Validation: đánh giá qua nhiều vòng

Một lần chia Train/Test duy nhất — như vừa thực hiện ở trên — chỉ cho MỘT "lát cắt"đánh giá. Kết quả có thể may mắn hoặc không may mắn tuỳ thuộc đúng 6 tháng nào rơi vào Test. **Walk-Forward Validation** (còn gọi là rolling-origin) đánh giá đáng tin cậy hơn: lặp lại việc chia Train/Test qua NHIỀU điểm xuất phát (origin), mỗi vòng mở rộng cửa sổ Train thêm vài kỳ, dự báo một đoạn ngắn phía trước, rồi tiếp tục mở rộng.



Kết quả thật

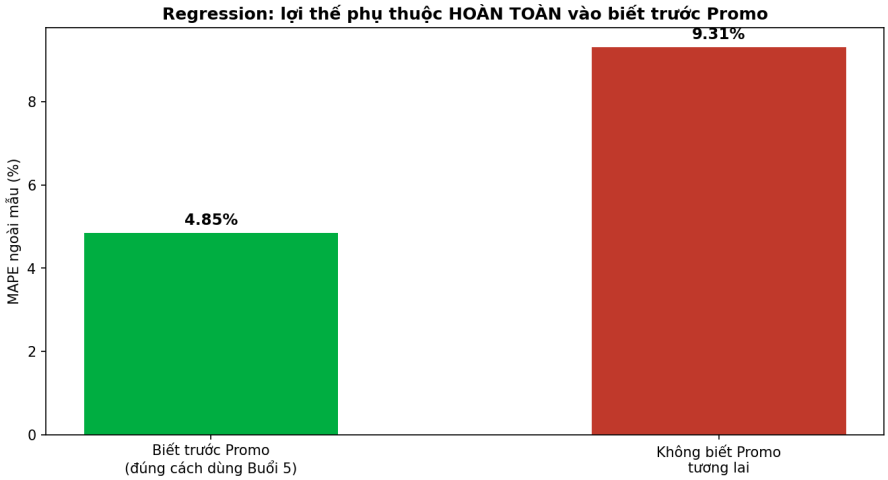
Áp dụng Walk-Forward Validation với 4 vòng (origin lần lượt là tháng 26, 28, 30, 32) trên Holt-Winters cho MAPE dao động từ 5,9% đến 16,0% tuỳ vòng — trung bình 12,2%. Con số này CAO HƠN đáng kể so với 8,19% thu được từ một lần chia duy nhất (30 tháng Train, 6 tháng Test) ở mục trước — cho thấy lần chia đơn lẻ đó phần nào "may mắn". Walk-Forward Validation, dù tốn nhiều tính toán hơn, cho một ước lượng THẬT SỰ đáng tin cậy về hiệu suất kỳ vọng của mô hình khi triển khai lâu dài, thay vì phụ thuộc vào một đoạn dữ liệu cụ thể.

Lưu ý thực hành

Với công việc THẬT, nên ưu tiên Walk-Forward Validation hơn một lần chia Train/Test đơn lẻ khi có đủ dữ liệu lịch sử (tối thiểu 4–5 chu kỳ mùa vụ) và đủ thời gian tính toán — đặc biệt quan trọng trước khi trình bày một con số MAPE duy nhất cho ban lãnh

đạo như một cam kết về độ chính xác tương lai.

7.4.6 Trường hợp đặc biệt: lợi thế của Regression phụ thuộc vào biết trước biến giải thích



Kết quả 4,85% ở trên giả định người dự báo *biết trước* tháng 10/2024 có khuyến mãi — đúng với giới hạn cốt lõi của Regression đã nêu ở Chương 5 (biến giải thích cần biết trước giá trị tương lai). Nếu không có thông tin này, MAPE ngoài mẫu của Regression tăng lên 9,31% — vẫn tốt hơn phần lớn các phương pháp khác, nhưng không còn vượt trội rõ rệt so với Holt-Winters. Đây là minh chứng thực nghiệm trực tiếp cho nguyên tắc đã học: giá trị của Regression gắn chặt với chất lượng thông tin đầu vào về tương lai.

Lưu ý thực hành

Các chỉ số MAPE trình bày xuyên suốt Chương 2 đến Chương 6 của giáo trình này là chỉ số trong mẫu, hữu ích để so sánh TƯƠNG ĐỐI giữa các phương pháp trên cùng một bộ dữ liệu, nhưng không nên xem là ước lượng cuối cùng cho độ chính xác dự báo thực tế. Trước khi triển khai bất kỳ mô hình nào cho công việc thật, nên lặp lại quy trình Train/Test Split trên chính SKU của bạn.

7.5 Case Study Thực Tế: Zillow Offers — khi mô hình định giá nhà "quá khớp" với quá khứ sụp đổ trước tương lai (2021)

Ngành: Bất động sản / Công nghệ (Real Estate / PropTech)

Zillow Offers là mảng kinh doanh "iBuying" của Zillow: dùng thuật toán Zestimate để tự động định giá và MUA đứt hàng chục nghìn căn nhà, sau đó sửa chữa và bán lại. Trong giai đoạn thị trường nhà đất Mỹ biến động mạnh do đại dịch 2020–2021, công ty đã trả giá cao hơn cả dự báo của chính thuật toán ở nhiều thời điểm để cạnh tranh

mua nhà. Tháng 11/2021, Zillow tuyên bố đóng cửa hoàn toàn mảng này, công bố khoản giảm giá trị hàng tồn kho lên tới **569 triệu USD** — trung bình khoảng 30.000 USD MỖI căn nhà đang nắm giữ — và cắt giảm khoảng 25% nhân sự. CEO Rich Barton thừa nhận: *"mức độ khó lường của việc dự báo giá nhà vượt xa những gì chúng tôi dự tính"*. Nghiên cứu sau đó của Stanford GSB chỉ ra: mô hình được huấn luyện tốt trên các căn nhà "kiểu mẫu" trong điều kiện thị trường ổn định, nhưng khi thị trường đổi chế độ (regime shift) và con người can thiệp trả giá cao hơn cả mô hình đề xuất, sai số ngoài mẫu (out-of-sample) tăng vọt.

Bài học liên hệ chương này: đây là minh hoạ sống động cho lằn ranh giữa "mô hình khớp tốt với dữ liệu lịch sử" và "mô hình còn đáng tin khi áp dụng cho dữ liệu MỚI, đặc biệt khi hoàn cảnh thay đổi" — đúng là lý do chương này dạy Train/Test Split và cảnh báo Overfitting: một mô hình luôn cần được kiểm tra trên dữ liệu nó CHƯA từng thấy, và luôn cần đi kèm nhận thức về giới hạn của chính nó, thay vì được xem là "sự thật tuyệt đối" để ra quyết định hàng trăm triệu USD.

Nguồn: Stanford Graduate School of Business, "Flip Flop: Why Zillow's Algorithmic Home Buying Venture Imploded"; Zillow Group, thông báo kết quả kinh doanh quý 3/2021, tháng 11/2021.

CHƯƠNG 8

Xử Lý Dữ Liệu Khó Trong Thực Tế

TỆP ĐÍNH KÈM — Chương 8

Python: `Buoi8/Buoi8_01_BieuDo.py`, `Buoi8/Buoi8_02_ExcelSheet_XuLyDuLieu.py`. **Excel:** sheet `Xu_Ly_Du_Lieu`. **Slide:** `Buoi8_XuLyDuLieuKho.pptx`.

Chương này trình bày các kỹ thuật xử lý hai vấn đề dữ liệu phổ biến nhất trong thực tế: giá trị bất thường (outlier) và dữ liệu bị thiếu, cần được xử lý trước khi áp dụng bất kỳ phương pháp nào ở các chương trước.

8.1 Phân loại outlier: lỗi dữ liệu và sự kiện thật

Trước khi xử lý một điểm dữ liệu bất thường, cần xác định bản chất của nó. Nếu là lỗi nhập liệu (ví dụ gõ nhầm thêm một chữ số 0), điểm dữ liệu cần được sửa hoặc thay thế. Nếu là sự kiện thật có căn cứ kinh doanh (ví dụ một đợt khuyến mãi lớn đã thực sự diễn ra), điểm dữ liệu cần được GIỮ NGUYÊN và đánh dấu bằng một biến giải thích riêng (tương tự biến Promo ở Chương 5), không nên loại bỏ hay làm mượt đi.

8.2 Phương pháp IQR (Interquartile Range)

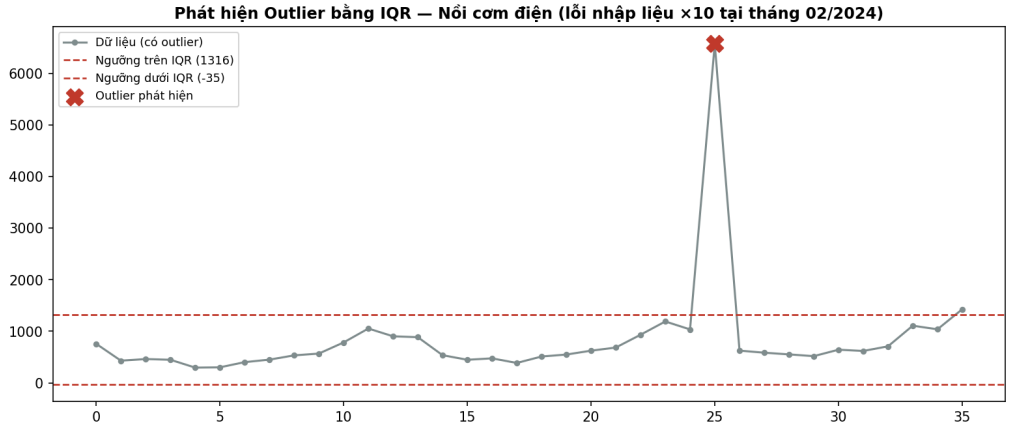
$$IQR = Q_3 - Q_1 \qquad \text{Ngưỡng} = [\,Q_1 - 1.5 \cdot IQR,\;\; Q_3 + 1.5 \cdot IQR\,]$$

Q1 và Q3 lần lượt là phân vị thứ 25 và thứ 75 của dữ liệu. Bất kỳ giá trị nào nằm ngoài khoảng ngưỡng trên được coi là outlier. Phương pháp này không yêu cầu giả định phân phối chuẩn và tương đối ổn định khi dữ liệu có độ lệch (skewness).

8.2.1 Bảng tính tay: ngưỡng IQR trên 36 tháng Nồi cơm điện

Đại lượng	Giá trị / Cách tính
Q_1 (phân vị 25)	471,8
Q_3 (phân vị 75)	809,5
$IQR = Q_3 - Q_1$	$809{,}5 - 471{,}8 = 337{,}8$
Ngưỡng dưới	$471{,}8 - 1{,}5 \times 337{,}8 = -34{,}9$
Ngưỡng trên	$809{,}5 + 1{,}5 \times 337{,}8 = 1.316{,}1$

Với dữ liệu bẩn mô phỏng (một giá trị 6.580 do lỗi nhập liệu ×10 tại tháng 02/2024), giá trị này vượt XA ngưỡng trên 1.316,1 — bị gắn cờ outlier ngay lập tức, đúng như minh hoạ ở biểu đồ dưới đây.



8.3 Phương pháp Z-score

$$z = \frac{x - \mu}{\sigma}$$

Một điểm dữ liệu thường được coi là outlier khi $|z| > 3$, tức là cách giá trị trung bình hơn ba độ lệch chuẩn. Phương pháp này trực quan nhưng có nhược điểm: bản thân outlier cực đoan có thể làm lệch cả trung bình lẫn độ lệch chuẩn dùng để tính z-score, làm giảm độ nhạy phát hiện. Khi cả hai phương pháp IQR và Z-score cùng xác nhận một điểm nghi ngờ, độ tin cậy phát hiện outlier tăng lên đáng kể.

8.3.1 Bảng tính tay: Z-score cho điểm nghi ngờ

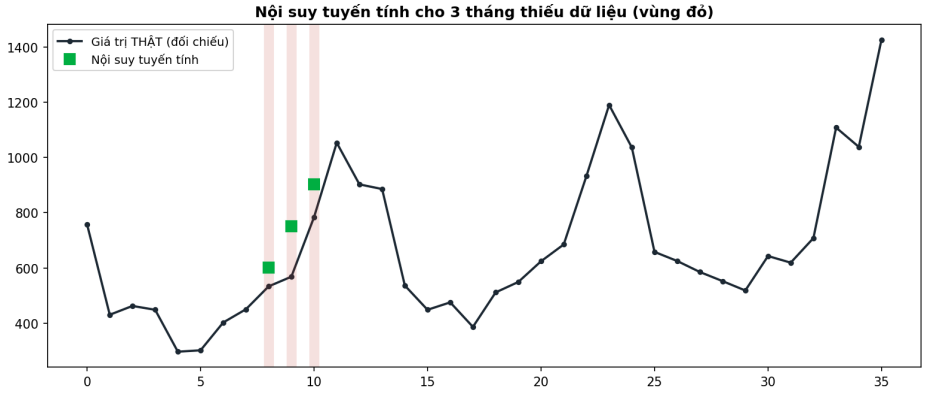
Đại lượng	Giá trị
Trung bình μ (36 tháng)	670,4
Độ lệch chuẩn σ	263,7
Giá trị nghi ngờ x	6.580 (lỗi nhập liệu ×10)
$z = (x - \mu)/\sigma$	$(6.580 - 670{,}4)/263{,}7 = \mathbf{22{,}41}$

$z = 22{,}41$ vượt xa ngưỡng $|z| > 3$ hàng chục lần — cả hai phương pháp IQR và Z-score đều xác nhận đây chắc chắn là outlier, không cần thêm bằng chứng nào khác.

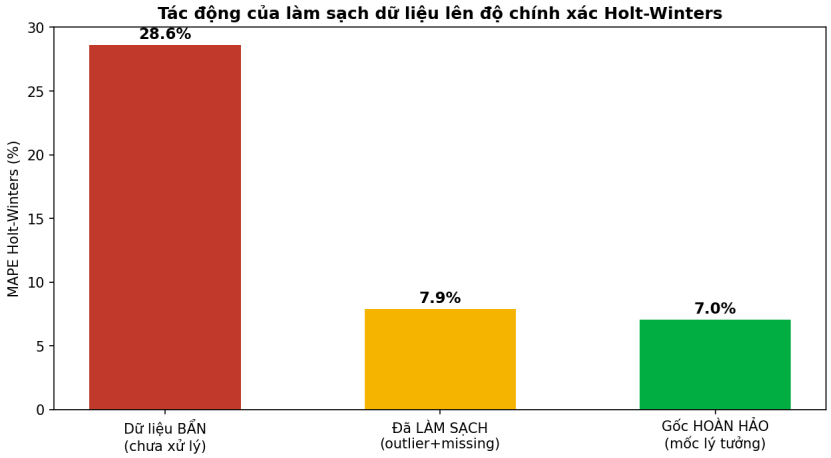
8.4 Xử lý dữ liệu thiếu bằng nội suy

Hai kỹ thuật nội suy phổ biến: nội suy tuyến tính (linear interpolation) ước lượng giá trị thiếu bằng trung bình có trọng số của hai điểm liền kề trước và sau; nội suy theo mùa (seasonal

interpolation) ước lượng dựa trên giá trị cùng kỳ ở các năm lân cận. Kết quả thực nghiệm trong khóa học cho thấy không có phương pháp nào vượt trội tuyệt đối trong mọi trường hợp — điều quan trọng hơn là việc THỰC HIỆN xử lý, thay vì bỏ qua dữ liệu thiếu hoặc để trống.



8.5 Tác động định lượng của việc làm sạch dữ liệu



Kịch bản	MAPE (Holt-Winters, Nồi cơm điện)
Dữ liệu bẩn (1 outlier + 3 kỳ thiếu, xử lý thô)	39.0%
Dữ liệu đã làm sạch (nội suy tuyến tính)	8.0%
Dữ liệu đã làm sạch (nội suy theo mùa)	8.6%
Dữ liệu gốc hoàn hảo (mốc lý tưởng)	7.0%

Kết luận chương

chỉ với việc xử lý đúng 4 trên tổng số 36 điểm dữ liệu (khoảng 11%), sai số dự báo giảm từ 39% xuống gần bằng mốc lý tưởng — minh chứng rằng chất lượng dữ liệu đầu vào có

tác động lớn hơn nhiều so với việc lựa chọn phương pháp mô hình hoá.

8.6 Case Study Thực Tế: Cú sốc giấy vệ sinh 2020 — khi một outlier không phải lỗi dữ liệu, mà là sự kiện có thật

Ngành: Bán lẻ / Hàng tiêu dùng (Retail / FMCG), đa quốc gia

Tháng 3/2020, khi COVID-19 được công bố đại dịch toàn cầu, doanh số giấy vệ sinh tại Mỹ và nhiều nước tăng đột biến khoảng 700–900% so với cùng kỳ chỉ trong vài tuần — mức tăng mà bất kỳ mô hình dự báo nào huấn luyện trên dữ liệu lịch sử bình thường cũng sẽ ghi nhận là outlier cực đoan. Điều đáng nói: đây KHÔNG phải do nhu cầu SỬ DỤNG giấy vệ sinh thực tế tăng lên, mà do tâm lý "mua tích trữ phòng thủ" (panic buying) lan truyền qua mạng xã hội và truyền thông, khiến hành vi mua hàng tách rời hoàn toàn khỏi nhu cầu tiêu dùng thật — hiện tượng được phân tích kỹ trong nhiều nghiên cứu học thuật sau đó về chuỗi cung ứng thời đại dịch.

Bài học liên hệ chương này: đây là ví dụ hoàn hảo cho ranh giới vừa học — outlier do LỖI DỮ LIỆU (cần sửa hoặc loại bỏ, ví dụ nhập nhầm đơn vị) hoàn toàn khác outlier do SỰ KIỆN THẬT (cần giữ lại trong lịch sử kèm chú thích, nhưng loại khỏi tập huấn luyện khi dự báo cho một kỳ "bình thường" sắp tới). Một Demand Planner áp dụng máy móc IQR hoặc Z-score để "làm sạch" mọi điểm bất thường mà không hỏi "điều gì đã thực sự xảy ra ngoài đời" có thể xoá mất chính tín hiệu quan trọng nhất của giai đoạn đó.

Nguồn: "Strategies for Managing the Impacts of Disruptions During COVID-19: an Example of Toilet Paper", Global Journal of Flexible Systems Management, Springer, 2020; Supply & Demand Chain Executive, "Tracing Toilet Paper Supply & Demand Challenges During COVID-19".

CHƯƠNG 9

Trình Bày Kết Quả Forecast Hiệu Quả

TỆP ĐÍNH KÈM — Chương 9

Python: `Buoi9/Buoi9_01_BieuDo.py`, `Buoi9/Buoi9_02_ExcelSheet_TomTatDieuHanh.py`.
Excel: sheet `Tom_Tat_Dieu_Hanh`. **Slide:** `Buoi9_TrinhBayKetQua.pptx`.

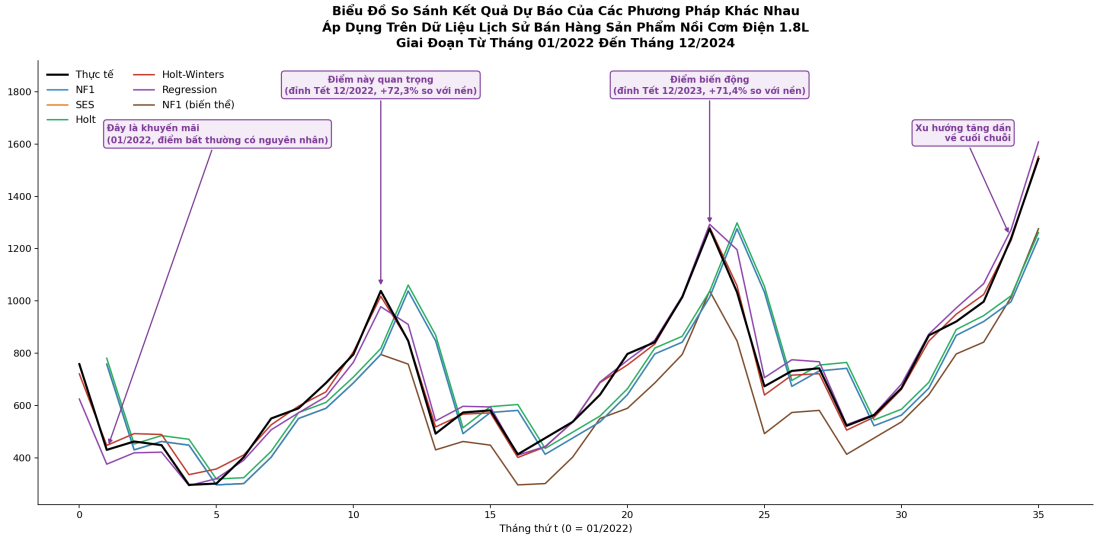
Chương này trình bày các nguyên tắc giao tiếp kết quả phân tích định lượng cho đối tượng không chuyên kỹ thuật — kỹ năng quyết định mức độ ảnh hưởng thực tế của một phân tích forecast, bất kể độ chính xác kỹ thuật của mô hình.

9.1 Nguyên tắc kim tự tháp ngược

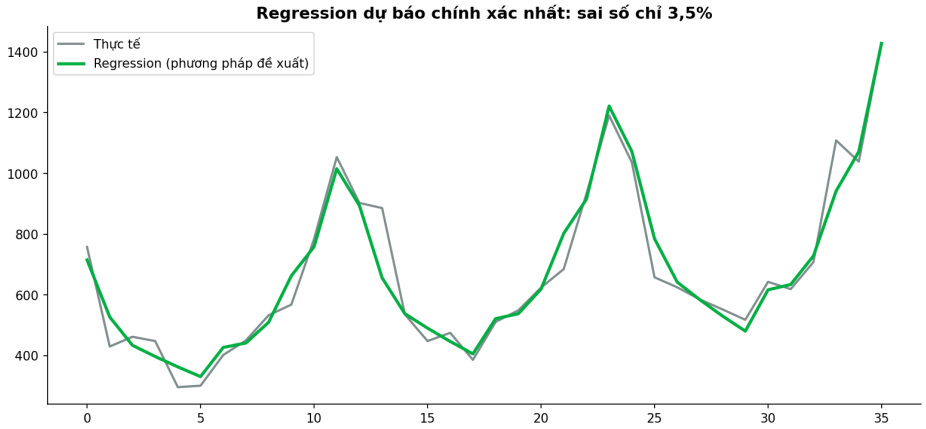
Cấu trúc trình bày thông thường theo trình tự thực hiện công việc (dữ liệu → phương pháp → công thức → kết luận) không phù hợp với đối tượng người nghe bận rộn, đặc biệt là cấp quản lý. Nguyên tắc kim tự tháp ngược (inverted pyramid) đảo ngược trình tự: trình bày KẾT LUẬN và KHUYẾN NGHỊ trước tiên trong một câu ngắn gọn, tiếp theo là bằng chứng chính (thường 1-2 biểu đồ), và cuối cùng là chi tiết kỹ thuật — chỉ trình bày khi được yêu cầu, không mặc định đưa vào phần trình bày chính.

9.2 Biểu đồ TỆ và biểu đồ TỐT: cùng dữ liệu, khác cách trình bày

Hai biểu đồ dưới đây dùng CHÍNH XÁC cùng một bộ dữ liệu và kết quả phân tích, chỉ khác cách trình bày — minh hoạ trực tiếp nguyên tắc kim tự tháp ngược áp dụng vào thiết kế biểu đồ.



Năm lỗi kinh điển trong biểu đồ trên: quá nhiều đường cùng lúc (mắt người chỉ xử lý tốt 2–3 đường), tiêu đề mô tả thay vì kết luận, chú thích chồng chéo khó đọc, chú giải (legend) chiếm quá nhiều diện tích, và không có phân cấp màu sắc để dẫn mắt người xem.



Phiên bản tốt áp dụng năm nguyên tắc ngược lại: tiêu đề LÀ kết luận, chỉ giữ hai đường (thực tế và phương pháp đề xuất), màu xám cho nền và màu thương hiệu nổi bật cho điểm nhấn, loại bỏ mọi chi tiết không phục vụ thông điệp chính, và số liệu quan trọng nhất nằm ngay trong chú giải.

9.3 Dịch thuật ngữ kỹ thuật sang ngôn ngữ kinh doanh

Thuật ngữ kỹ thuật	Diễn đạt cho người không chuyên
MAPE = 3.5%	Dự báo sai lệch trung bình chỉ 3.5% — rất đáng tin cậy
Adjusted R^2 âm	Mô hình có vẻ khớp tốt nhưng thực chất chỉ đang học thuộc dữ liệu cũ, không đáng tin
Tracking Signal vượt ±4	Mô hình dự báo đã lỗi thời, cần xây dựng lại

9.4 Nguyên tắc thiết kế biểu đồ hiệu quả

- Tiêu đề biểu đồ nên LÀ kết luận, không chỉ mô tả nội dung — ví dụ "Regression giảm sai số dự báo từ 20% xuống 3.5%" thay vì "Biểu đồ so sánh các phương pháp dự báo".
- Giới hạn số lượng đường/chuỗi dữ liệu trong một biểu đồ ở mức 2-3, ưu tiên phần dữ liệu phục vụ trực tiếp cho thông điệp chính.
- **Sử dụng phân cấp màu sắc rõ ràng:** một màu nổi bật cho phần cần nhấn mạnh, các phần còn lại dùng màu trung tính.
- Loại bỏ các yếu tố trang trí không phục vụ thông điệp (đường viền thừa, lưới dày đặc, chú thích chồng chéo).

9.5 Cấu trúc kể chuyện bằng số liệu

Cấu trúc bốn bước Tình huống – Vấn đề – Giải pháp – Kết quả (Situation – Complication – Solution – Result) là khung kể chuyện hiệu quả để trình bày một dự án phân tích: mô tả bối cảnh ban đầu, nêu rõ vấn đề cụ thể, trình bày giải pháp đã áp dụng, và định lượng kết quả đạt được. Cấu trúc này tận dụng cơ chế ghi nhớ tự nhiên của não bộ đối với câu chuyện có mạch logic nhân-quả, hiệu quả hơn đáng kể so với trình bày rời rạc các con số.

9.6 Case Study Thực Tế: Biểu đồ Challenger — khi cách trình bày dữ liệu liên quan tới sinh mạng

Ngành: Hàng không vũ trụ / Kỹ thuật (Aerospace)

Đêm trước vụ phóng tàu con thoi Challenger ngày 28/1/1986, các kỹ sư của Morton Thiokol (nhà thầu chế tạo tên lửa đẩy) đã có cuộc họp khẩn với NASA để cảnh báo nguy cơ vòng đệm cao su (O-ring) bị hỏng ở nhiệt độ thấp bất thường dự kiến vào sáng hôm phóng. Nhà thống kê Edward Tufte, trong các phân tích nổi tiếng về trực quan hoá dữ liệu, chỉ ra rằng các bảng số liệu nhóm kỹ sư trình bày đêm đó liệt kê dữ liệu rời rạc mà KHÔNG vẽ rõ mối quan hệ giữa nhiệt độ và mức độ hư hỏng O-ring trên cùng một trục — khiến các nhà quản lý khó nhận ra ngay xu hướng nguy hiểm, và tàu vẫn được phép phóng, dẫn tới thảm hoạ khiến 7 phi hành gia thiệt mạng. (Cần lưu ý: các phân tích học thuật sau này, ví dụ trên Online Ethics/University of Virginia, chỉ ra vụ việc phức tạp hơn một câu chuyện đơn giản "biểu đồ xấu gây ra thảm hoạ" — còn có yếu tố áp lực tổ chức và thời hạn phóng tàu — nhưng bài học về trình bày dữ liệu vẫn được giảng dạy rộng rãi như một ví dụ kinh điển trong ngành visualization.)

Bài học liên hệ chương này: đây là lý do chương này phân biệt rõ "biểu đồ TỆ" (chỉ liệt kê số liệu) và "biểu đồ TỐT" (làm nổi bật đúng mối quan hệ/xu hướng cần người xem hành động) — một bộ số liệu dù đầy đủ và chính xác đến đâu cũng có thể trở nên vô dụng, thậm chí nguy hiểm, nếu cách trình bày không làm rõ được thông điệp quan trọng nhất cho người ra quyết định.

Nguồn: Edward R. Tufte, Visual Explanations (1997), chương về thảm hoạ Challenger; Online Ethics/University of Virginia, "Representation and Misrepresentation: Tufte and the Morton Thiokol Engineers on the Challenger".

CHƯƠNG 10

Framework Tổng Hợp Và Bảng Công Thức

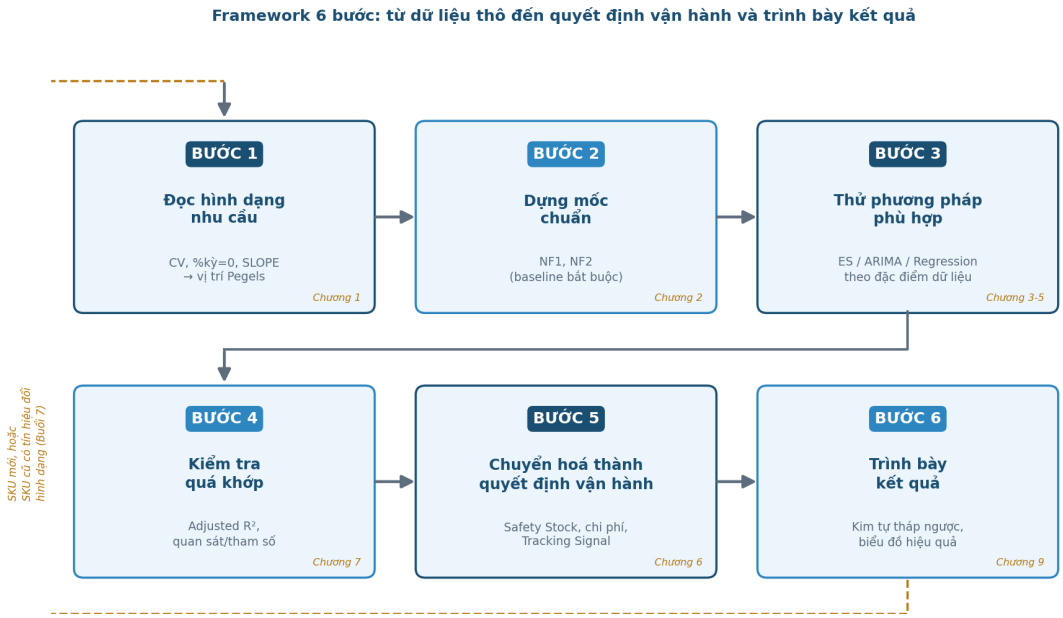
TỆP ĐÍNH KÈM — Chương 10

Python: `Buoi10/Buoi10_01_BieuDo.py`, `Buoi10/Buoi10_02_ExcelSheet_BangCongThuc.py`, `Buoi10/Buoi10_03_ExcelSheet_KetHopDuBao.py`. **Excel:** sheet `Bang_Cong_Thuc_TongHop`, `Ket_Hop_Du_Bao`. **Slide:** `Buoi10_BaoVeVaTongKet.pptx`. Toàn bộ tệp trên nằm trong `03_CodePython_10Buoi/`, `02_Excel_10Buoi/`, `01_Slides_10Buoi/` — xem mục *General Docs* để biết cấu trúc đầy đủ.

Chương cuối cùng tổng hợp toàn bộ kiến thức thành một quy trình sáu bước có thể áp dụng cho bất kỳ SKU nào trong thực tế công việc, cùng bảng tra cứu nhanh toàn bộ công thức đã trình bày.

10.1 Framework sáu bước

- **Bước 1 — Đọc hình dạng nhu cầu:** tính CV, %kỳ=0, SLOPE, xác định vị trí trong ma trận Pegels (Chương 1).
- **Bước 2 — Dựng mốc chuẩn:** tính NF1, NF2 làm baseline tối thiểu bắt buộc (Chương 2).
- **Bước 3 — Thử các phương pháp phù hợp:** lựa chọn trong số Exponential Smoothing, ARIMA, Regression theo đặc điểm dữ liệu đã xác định ở Bước 1 (Chương 3-5).
- **Bước 4 — Kiểm tra quá khớp:** tính Adjusted R^2 hoặc tỷ lệ quan sát/tham số cho các mô hình nhiều biến (Chương 7).
- **Bước 5 — Chuyển hoá thành quyết định vận hành:** tính Safety Stock, quy đổi chi phí, thiết lập Tracking Signal giám sát (Chương 6).
- **Bước 6 — Trình bày kết quả:** áp dụng nguyên tắc kim tự tháp ngược, dịch thuật ngữ kỹ thuật, thiết kế biểu đồ hiệu quả (Chương 9).



Mũi tên vòng bên trái nhắc lại: framework này không chỉ chạy MỘT LẦN cho một SKU rồi kết thúc — mỗi khi có SKU mới, hoặc khi Tracking Signal (Bước 5) hay bài kiểm tra ngoài mẫu (Chương 7) phát tín hiệu một SKU cũ đã ĐỔI hình dạng, quy trình quay lại đúng Bước 1 để đọc lại đặc điểm dữ liệu, thay vì giữ nguyên phương pháp cũ theo quán tính.

10.2 Kỹ thuật nâng cao: kết hợp nhiều phương pháp dự báo

Thay vì chọn đúng MỘT phương pháp "tốt nhất"duy nhất, kỹ thuật Combining Forecasts kết hợp dự báo từ nhiều phương pháp đã học thành một dự báo tổng hợp, dựa trên nguyên lý toán học: dự báo kết hợp không bao giờ tệ hơn phương pháp tốt nhất trong số các phương pháp thành phần, khi được ước lượng đúng cách.

$$\hat{Y} = b_0 + b_1 F_1 + b_2 F_2 + \cdots + b_m F_m$$

trong đó $F_1, \ldots, F_m$ là các dự báo THÀNH PHẦN từ những phương pháp đã học (ví dụ Regression và Holt-Winters), và các hệ số b_i được ước lượng bằng hồi quy tuyến tính CỦA GIÁ TRỊ THỰC TẾ THEO CÁC DỰ BÁO THÀNH PHẦN — khác với Regression ở Chương 5 vốn hồi quy theo thời gian và biến giải thích, ở đây biến giải thích chính là các dự báo đã có sẵn. Trong Excel, thực hiện bằng hàm LINEST với các cột dự báo thành phần làm biến X.

10.2.1 Bảng tính tay: kết hợp Regression và Holt-Winters

Với hệ số ước lượng $b_0 = -5{,}71$, $b_1 = 0{,}874$ (trọng số Regression), $b_2 = 0{,}135$ (trọng số Holt-Winters):

Tháng	Y_t	F_1 (Reg.)	F_2 (H-W)	$\hat{Y} = b_0 + b_1F_1 + b_2F_2$
01/2022	758	786,5	715,3	$-5{,}7+0{,}874(786{,}5)+0{,}135(715{,}3) = 777{,}9$
02/2022	430	436,0	527,0	$-5{,}7+0{,}874(436{,}0)+0{,}135(527{,}0) = 446{,}2$
03/2022	462	428,2	434,0	$-5{,}7+0{,}874(428{,}2)+0{,}135(434{,}0) = 426{,}9$
04/2022	448	380,9	397,1	$-5{,}7+0{,}874(380{,}9)+0{,}135(397{,}1) = 380{,}5$

Trọng số $b_1 = 0{,}874$ lớn hơn nhiều so với $b_2 = 0{,}135$ — mô hình TỰ HỌC được rằng Regression đáng tin hơn Holt-Winters trên SKU này, mà không cần người dùng tự chỉ định tỷ trọng.

Kết quả thật

Kết hợp Regression (MSE=834, MAPE=3,5%) và Holt-Winters (MSE=4266, MAPE=7,0%) trên Nồi cơm điện cho MSE kết hợp = 756 — THẤP HƠN cả hai mô hình gốc, đúng như lý thuyết dự đoán. Tuy nhiên MAPE kết hợp chỉ đạt khoảng 3,6%, gần bằng chứ không thấp hơn Regression riêng lẻ — vì LINEST tối ưu hoá MSE, không phải MAPE, hai chỉ số có thể không cải thiện đồng thời. Đây là minh chứng thực nghiệm cho nguyên tắc Chương 2: luôn chọn chỉ số đánh giá phù hợp với mục tiêu thực tế, không có chỉ số nào "vạn năng".

10.3 Bảng tra cứu công thức toàn khóa học

Chương	Công thức	Diễn giải
1	CV = σ/μ	Hệ số biến thiên — ngưỡng ổn định: CV < 0.5
1	%kỳ=0 = n(Y_t=0)/n	Tỷ lệ kỳ rời rạc
1	SLOPE hồi quy tuyến tính	Độ dốc xu hướng theo thời gian
2	et = Y_t - F_t	Sai số dự báo
2	MAPE = trung bình(|et/Y_t|)×100%	Sai số phần trăm trung bình
2	$F_t \pm z\sqrt{\text{MSE}}$	Khoảng tin cậy dự báo
3	F_t+1 = αYt + (1-α)F_t	SES — san bằng đơn giản
4	ADF test, p<0.05	Kiểm định tính dừng
4	AIC = $2k - 2\ln(\hat{L})$	Tiêu chí chọn mô hình ARIMA
5	Y = b0+b1X1+...+bkXk+ε	Hồi quy tuyến tính đa biến
6	$SS = z\sqrt{\text{MSE} \times L}$	Tồn kho an toàn
6	TS = ΣError/MAD	Tracking Signal — ngưỡng cảnh báo ±4
7	R^2adj = 1-(1-R^2)(n-1)/(n-k-1)	R^2 điều chỉnh — phát hiện quá khớp
8	IQR = Q3-Q1	Phát hiện outlier

10.4 Bảng tổng hợp: hình dạng nhu cầu nào dùng phương pháp nào

Bảng dưới đây tổng hợp toàn bộ quy tắc lựa chọn phương pháp đã học qua mười chương, tổ chức theo *đặc điểm cấu trúc biến động* của chính chuỗi dữ liệu — đây là bảng tra cứu nên dùng đầu tiên khi gặp một SKU mới trong công việc thực tế.

Hình dạng dữ liệu	Đặc điểm (CV, %kỳ=0, SLOPE)	Mô hình khuyến nghị	Mốc đối chiếu
Ổn định	$CV < 0{,}5$; %kỳ=0 ≈ 0; không trend, không mùa vụ	SES (Chương 3); Moving Average làm mốc tham chiếu nhanh	NF1 ($F_{t+1} = Y_t$)
Có xu hướng	SLOPE $\neq 0$ có ý nghĩa; không mùa vụ	Holt, ưu tiên bản Damped Trend để tránh ngoại suy phi thực tế khi dự báo xa (Chương 3)	NF1
Mùa vụ + Xu hướng	Chu kỳ 12 tháng lặp lại rõ, kèm SLOPE khác 0	Holt-Winters — chọn biến thể Nhân nếu biên độ mùa vụ phình theo mức nền, Cộng nếu biên độ cố định (Chương 3); SARIMA nếu có $\geq$36–48 kỳ và cấu trúc tự tương quan phức tạp (Chương 4)	NF2 (naive có hiệu chỉnh mùa vụ)
Bị chi phối bởi kế hoạch kinh doanh	Có biến cố khuyến mãi/giá/marketing đã biết trước lịch trình	Regression đa biến với biến giả mùa vụ và biến sự kiện ngoại sinh (Chương 5) — tách được phần tăng thêm THẬT SỰ do khuyến mãi, không quy về nhiễu ngẫu nhiên	Holt-Winters
Rời rạc (Intermittent)	%kỳ=0 $>$ 30–50%; SKU thường là phụ tùng/linh kiện bảo trì	Croston/SBA cho nhu cầu rời rạc đều; TSB nếu tần suất phát sinh đang suy giảm rõ rệt (Chương 6)	NF1 (thường dự báo sai bằng 0)

Lưu ý thực hành

Bảng trên nên dùng SAU khi đã hoàn thành ba chỉ số phân loại (CV, %kỳ=0, SLOPE) và xác định vị trí trong ma trận Pegels (Chương 1) — không nên chọn phương pháp chỉ dựa vào *loại sản phẩm* một cách cảm tính, vì cùng một ngành hàng vẫn có thể có SKU thuộc nhiều hình dạng khác nhau.

10.5 Case Study Thực Tế: Nate Silver và 50/50 bang — sức mạnh của việc KẾT HỢP nhiều dự báo

Ngành: Truyền thông / Thống kê ứng dụng (Media / Applied Statistics)

Trong cuộc bầu cử Tổng thống Mỹ năm 2012, hầu hết các hãng thăm dò riêng lẻ và bình luận viên chính trị đều cho rằng cuộc đua giữa Obama và Romney "quá sít sao để đoán". Nhà thống kê Nate Silver, qua trang FiveThirtyEight, thay vì tin vào một cuộc thăm dò đơn lẻ, đã xây dựng mô hình KẾT HỢP có trọng số hàng chục cuộc thăm dò khác nhau ở từng bang, điều chỉnh theo độ tin cậy lịch sử của từng đơn vị thăm dò. Kết quả: mô hình của ông dự đoán ĐÚNG kết quả thắng-thua ở toàn bộ 50 bang — thành tích được giới truyền thông (CNN Money, Forbes, IEEE Spectrum) ca ngợi là "sự minh oan cho dữ liệu" (the vindication of data).

Bài học liên hệ chương này: đây là minh chứng thực tế cho nguyên lý "kết hợp nhiều phương pháp dự báo" (Forecast Combination) vừa học, và cũng là phát hiện lặp lại nhất quán qua các cuộc thi M-Competitions (đã nhắc ở Chương 3): một TỔ HỢP nhiều dự báo có chất lượng vừa phải, mỗi cái có sai số và điểm mù RIÊNG, thường đáng tin cậy hơn hẳn việc đặt cược toàn bộ vào MỘT dự báo "hay nhất". Đây cũng là triết lý vận hành cốt lõi của một Demand Planner giỏi: không tìm kiếm "một mô hình đúng tuyệt đối", mà xây dựng một QUY TRÌNH đủ vững để liên tục đối chiếu, kết hợp và điều chỉnh nhiều góc nhìn dự báo theo thời gian — đúng tinh thần xuyên suốt toàn bộ 10 buổi học của khóa này.

Nguồn: IEEE Spectrum, "Election 2012: The Vindication of Data"; Forbes, "Nate Silver Nailed It, Predicting Correct Presidential Election Results In All 50 States" (2012).

10.6 Kết luận giáo trình

Nguyên tắc xuyên suốt toàn bộ mười chương của giáo trình này là: không tồn tại một phương pháp dự báo "tối ưu tuyệt đối" áp dụng cho mọi loại dữ liệu. Giá trị cốt lõi mà người học cần tiếp thu không phải là ghi nhớ từng công thức riêng lẻ, mà là năng lực đánh giá đặc điểm dữ liệu một cách khách quan, lựa chọn phương pháp phù hợp có căn cứ kiểm chứng, và chuyển hoá kết quả phân tích thành quyết định vận hành có giá trị thực tiễn, được trình bày theo cách mà người ra quyết định có thể hiểu và tin tưởng.

— Hết —

Code & Demo

Các bạn có thể truy cập full bài giảng, link github và Web demo thực hành theo các liên kết dưới đây:

- **Full bài giảng gồm code Python và VBA:** Link Drive
- **GitHub repository:** Link GitHub
- **Web demo thực hành:** Forecasting Lab